

Statistique Exploratoire Multidimensionnelle

Thomas Papastergiou MCF

M2 de mathématiques

Mathématiques des Données

M2 en Informatique

Exploration Informatique des données et décisionnel (EID^2)

Généralités sur les cours

Objectifs du cours SEM

- Ce cours n’a pas pour but d’étudier en détail les concepts théoriques de l’Analyse des données et de la Statistique
- Les objectifs du cours sont :
  - D’apprendre à **explorer** et **exploiter** *l’information contenue dans les bases de données* à l’aide des méthodologies statistiques
  - D’apprendre à utiliser et à développer des programmes d’analyse de données avec un outil : **le langage R.**

Plan général du cours SEM

- Introduction
- Principe de base sous R
- Les Analyses Factorielles
- Les Classifications
- La régression linéaire
- Les Tests Statistiques
- La régression logistique

Contrôle des connaissances

- Un mini projet (sujet fourni)
  - Prise en charges des données en R
    - Création et manipulations de tables
    - Création et recodage des variables
    - Création de visualisations en R
- Production de statistiques descriptives
  - Statistiques sur les variables
  - Mesure des liaisons entre variables
- Analyses factorielles et classifications
- Modélisations et prédictions

Motivation

Quelles sont les questions auxquelles la statistique permet de répondre ?

Quelques cas d’usage classiques

Prévision de désabonnement (Churn Prediction)

– Un client va-t-il résilier son abonnement ?



Système CRM
Données relatives aux clients

- Données démographiques
- Comportement
- Revenus
- etc



Modèle



- Prévision de désabonnement
- Probabilité de vente incitative
- Propension à l'achat
- Gestion des campagnes
- Segmentation de la clientèle
- …

Segmentation de la clientèle (Customer Segmentation)

- quels sont les groupes de clients que je sers ?
- quelles sont leurs caractéristiques ?



Système CRM
Données relatives aux clients

- Données démographiques
- Comportement
- Revenus
- etc



Modèle

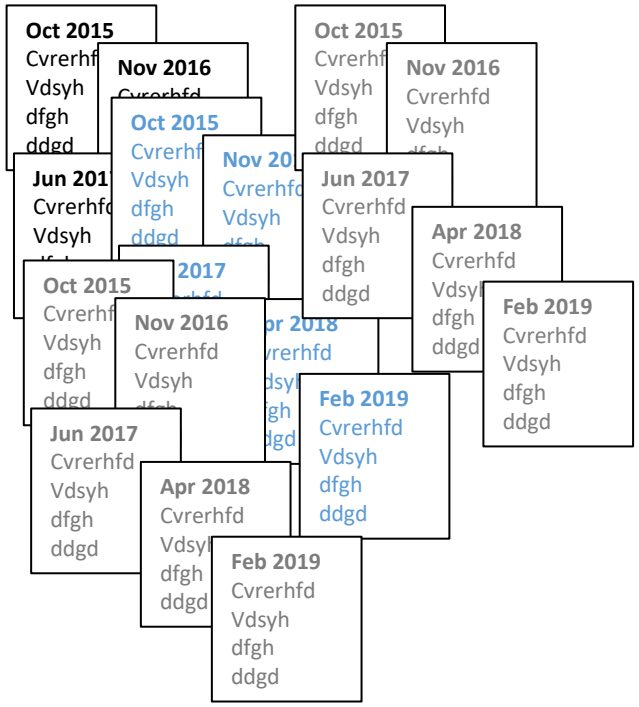


- Prévision de désabonnement
- Probabilité de vente incitative
- Propension à l'achat
- Gestion des campagnes
- Segmentation de la clientèle
- …

Évaluation du risque (Risk Assessment)

– Cette personne va-t-elle rembourser le prêt ?

Historique du client





Modèle

Risque Pronostic

- High Risk
- Low Risk
- High Risk
- Very High Risk
- Very Low Risk
- Medium Risk
- …



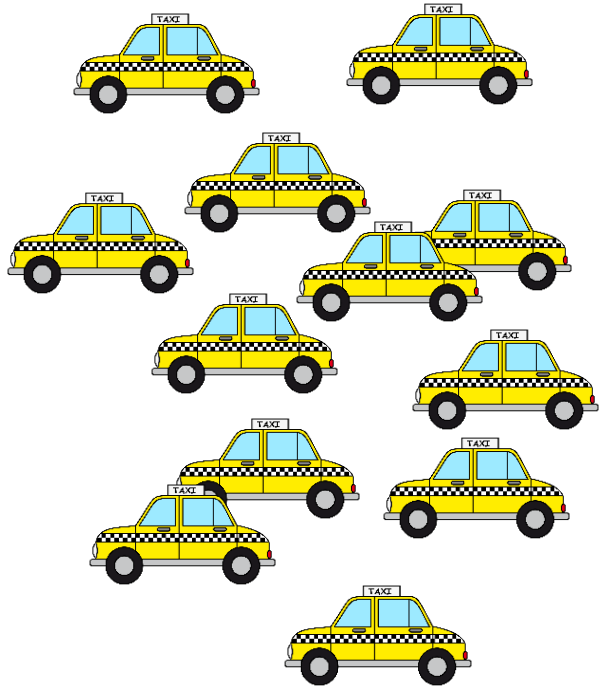
Prévision de demande (Demand Prediction)

- De combien de taxis ai-je besoin à New York le mercredi à midi ?
- Combien de kW seront nécessaires demain à 6 heures du matin à Londres ?
- Combien de clients viendront ce soir dans mon restaurant ?





Modèle



Détection des frauds (Fraud Detection)

– Cette transaction est-elle légitime ou s'agit-il d'une fraude ?

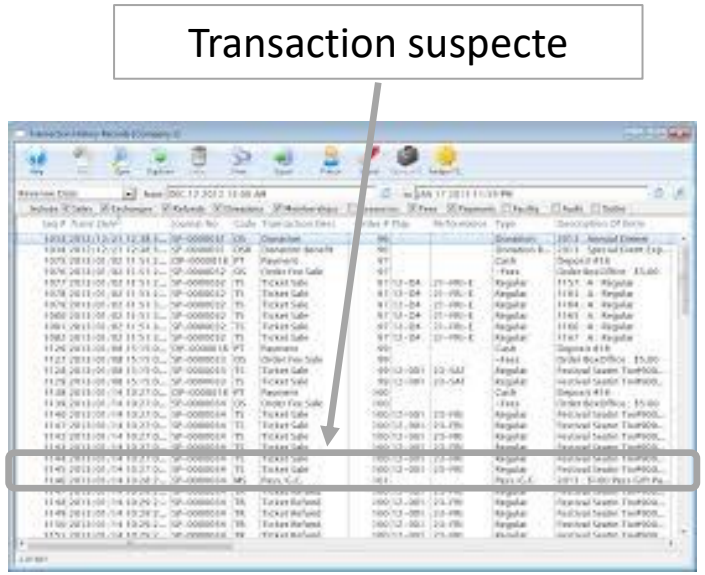


Transactions

- Trx 1
- Trx 2
- Trx 3
- Trx 4
- Trx 5
- Trx 6
- …



Modèle



Analyse de sentiments (Sentiment Analysis)

– Puis-je savoir automatiquement (sans intervention humaine) comment les gens se sentent ?



Samsung

Samsung Galaxy S7 Edge G935A 32GB Unlocked - Gold Platinum

★★★★☆ 125 customer reviews | 606 answered questions

★★★★★ **Beautiful phone from a wonderful seller!**

By Atheism-the-Buddhist-Way on May 29, 2017

Color: Gold | **Verified Purchase**

This practically new beautiful phone well exceeded my expectations!



★☆☆☆☆ **One Star**

By Christopher white on August 3, 2016

Color: Black Onyx | **Verified Purchase**

Very bad experience



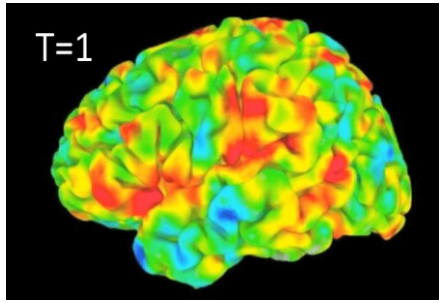
D’où viennent les données ?



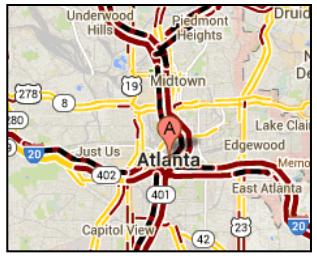
Cybersécurité



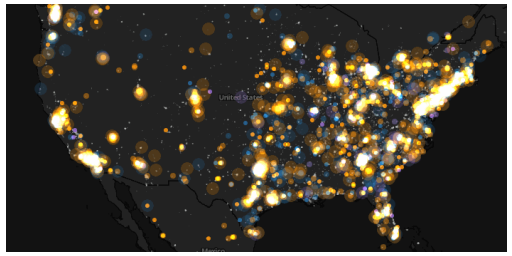
E-Commerce



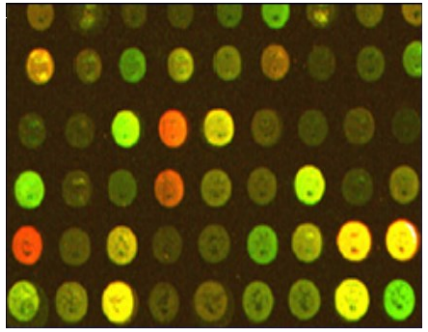
Données IRMf du cerveau



Modèles de circulation



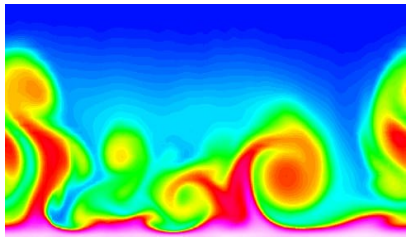
Réseaux sociaux : Twit



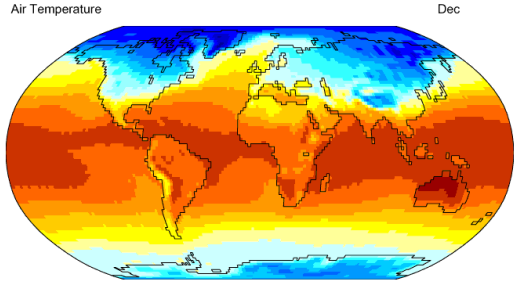
Données d'expression génétique



Réseaux de capteurs



Simulations numériques



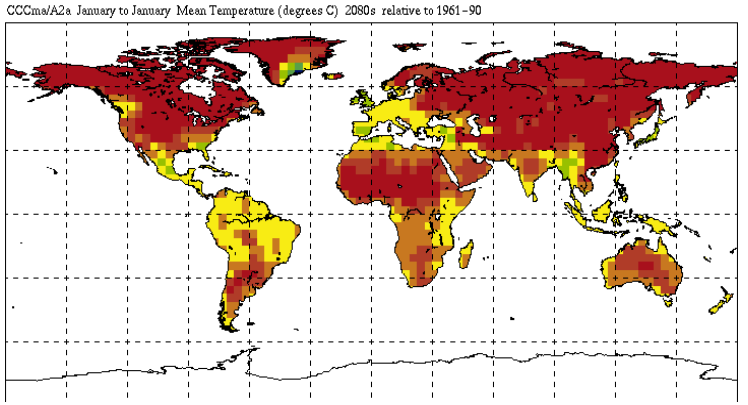
Température de surface de la Terre

Est-ce qu'on peut sauver le monde ?

Non, main on peut contribuer à son amélioration en analysant des données multidimensionnelles :-P



Améliorer les soins de santé et réduire les dépenses



Prévoir l'impact du changement climatique



Trouver des sources d'énergie alternatives/vertes



Réduire la faim et la pauvreté en augmentant la production agricole

Introduction

Données vs. Connaissance (Data vs. Knowledge)

Les données

- se réfèrent à des instances uniques (objets uniques, personnes, événements, moments dans le temps, etc.)
- décrivent des propriétés individuelles
- sont souvent disponibles en grandes quantités (bases de données, archives)
- sont souvent faciles à collecter ou à obtenir (par exemple : les caissières de scanner dans les supermarchés, Internet)
- **ne permettent pas de faire des prédictions ou des prévisions**

La connaissance

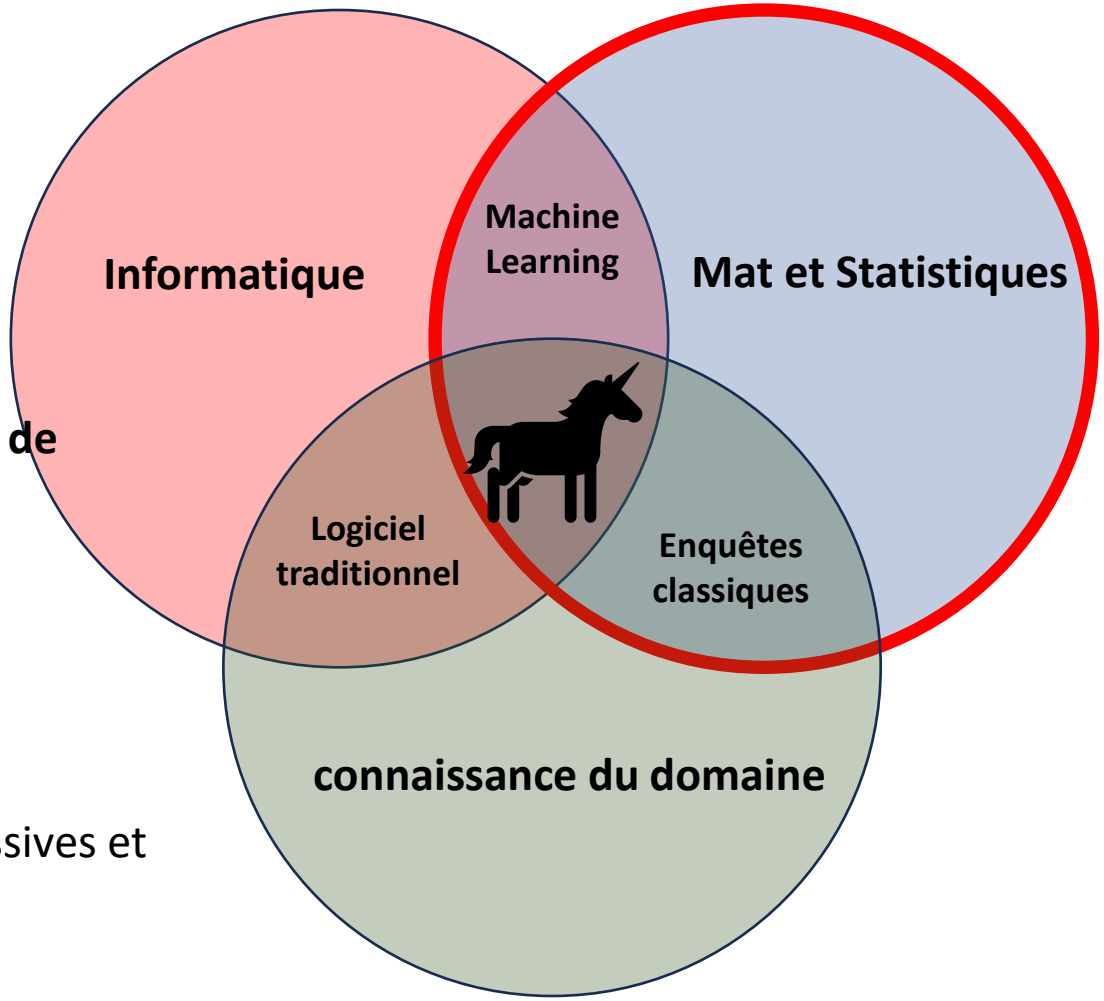
- se réfère à des classes d'instances (ensembles d'objets, de personnes, d'événements, de moments dans le temps, etc.)
- décrit des modèles généraux, des structures, des lois, des principes, etc.
- contiens le moins d'affirmations possible
- est souvent difficile et longue à trouver ou à obtenir (par exemple, les lois naturelles, l'éducation)
- permet de faire des prédictions et des prévisions

Comment évaluer des connaissances

- **exactitude** (probabilité, réussite des tests)
- **la généralité** (domaine et conditions de validité)
- **l'utilité** (pertinence, pouvoir prédictif)
- **compréhensibilité** (simplicité, clarté, parcimonie (esprit d'économie))
- **nouveauté** (précédemment inconnu, inattendu)

Sur quoi allons-nous nous concentrer dans ce cours ?



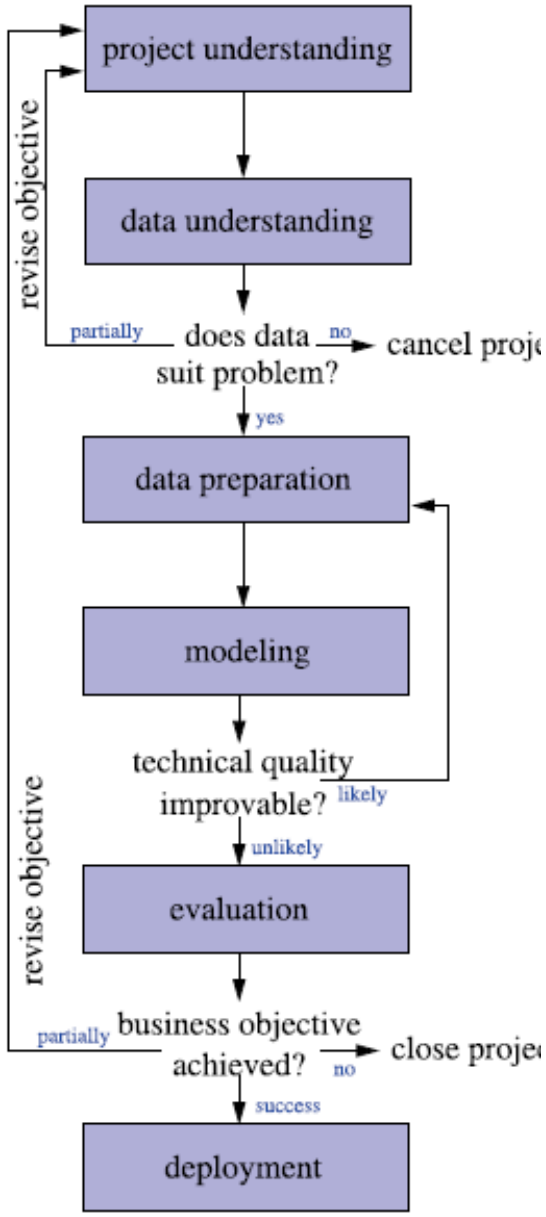


La science des données est l'étude de l'extraction automatisée de connaissance à partir de grands ensembles de données.

Plus précisément, la science des données est un **domaine interdisciplinaire** qui utilise des méthodes, des processus, des algorithmes et des systèmes scientifiques **pour extraire des connaissances et des idées à partir de nombreuses données structurées ou non** . Elle est souvent associée aux données massives et à l'analyse des données.

Elle utilise des techniques et des théories tirées de nombreux domaines dans le contexte des **mathématiques**, des **statistiques**, de **l'informatique**, de la **théorie et des technologies de l'information** […]

Le processus de la science des données



Quel est le problème exactement ?
À quoi devrait ressembler une solution ?
Que savons-nous du domaine d'application ?

Les données sont-elles pertinentes par rapport au problème ?
Sont-elles valables ? Reflètent-elles nos attentes ?
La qualité, la quantité et la récurrence des données sont-elles suffisantes ?

Sur quelles données devons-nous nous concentrer ?
Comment transformer au mieux les données pour la modélisation ?
Comment améliorer la qualité des données ?

Quel type de modélisation devrions-nous utiliser ?
Quelles sont les performances techniques du modèle ?

Quelle est la performance du modèle par rapport aux exigences du projet ?
Qu'avons-nous appris du projet ?

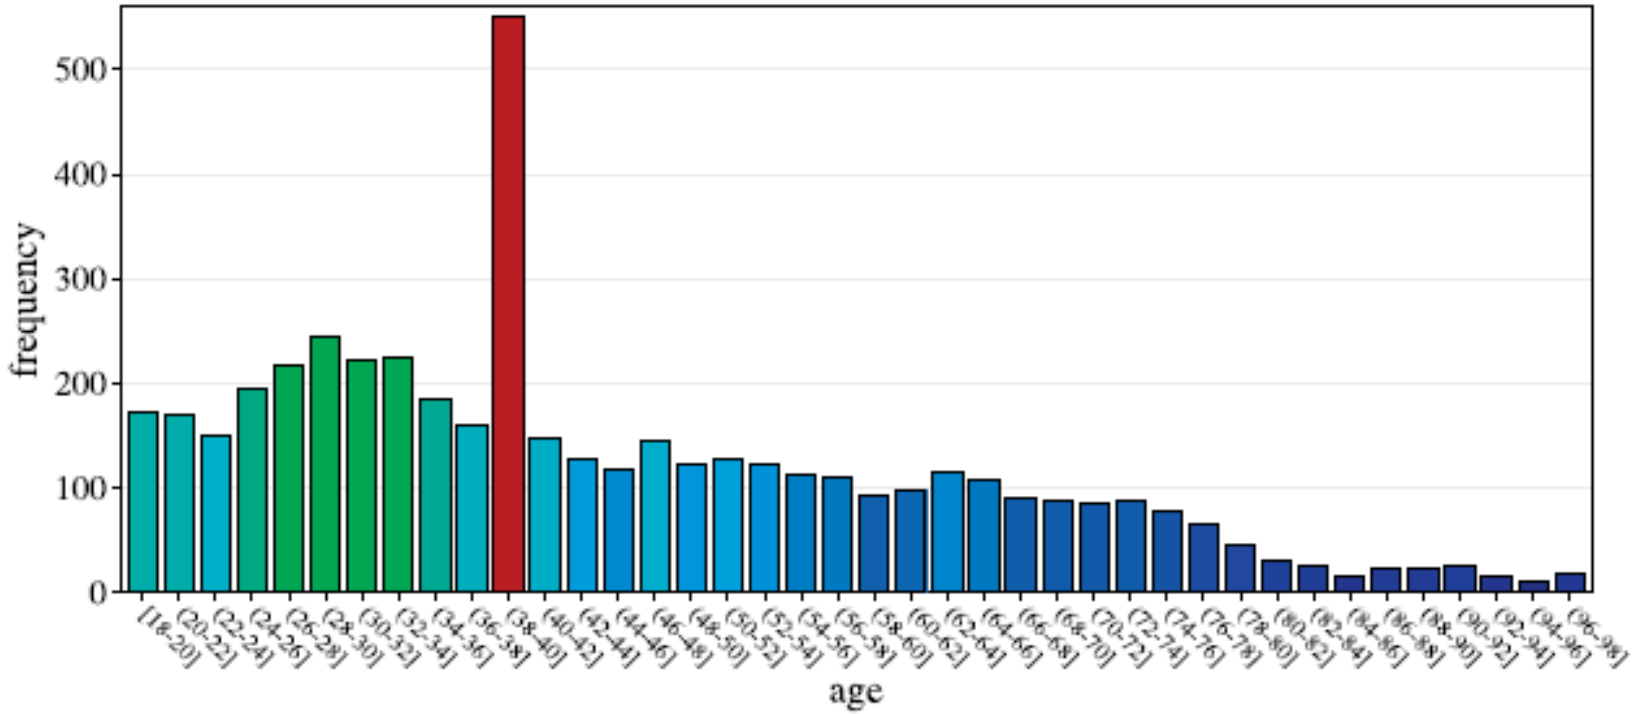
Quelle est la meilleure façon de déployer le modèle ?
Comment savoir si le modèle est toujours valable ?

Introduction à la statistique exploratoire

Compréhension des données

- **Le défi de la phase de compréhension des données**
  - Obtenir des informations générales sur les données qui seront potentiellement utiles pour les étapes suivantes du processus d'analyse des données.
- **La raison ?**
  - Ne faites jamais confiance à des données tant que vous n'avez pas effectué de simples contrôles de plausibilité.

Jeu de données d'une chaîne de supermarchés



- Avons-nous vérifié que la tranche d'âge est comprise entre 18 et 100 ans ?
- Avons-nous vérifié que il n’existent pas de valeurs « bizarres »
  - Ici, la valeur par défaut dans le cas où l'âge n’a pas été connu a été est fixée à 40 ans

Éléments de vocabulaire

Variables, attributs (Attributes, features, variables)
- *Mesure qui associe à chaque individu « une » valeur*

No	Sexe	Age	Tension artérielle	Hauteur	Medic ament
1	male	20	normal	175,0	A
2	female	73	normal	172,2	B
3	female	37	high	163,8	A
4	male	33	low	171,4	B
5	female	48	high	165,9	A
6	male	29	normal	182,3	A
7	female	52	normal	167,2	B
8	male	42	low	177,2	B
9	male	61	normal	168,4	B
10	female	30	normal	174,9	A

Individus, observations (*Instances*)
- *Unité de base sur laquelle on effectue un certain nombre de mesures*
- *La ligne du tableau ou de la matrice des données.*

La population : l'ensemble des individus
La population étudiée : l'échantillon
La population de référence : La population sur laquelle nous faisons des inférences

- Les données peuvent généralement être décrites sous forme de **tableaux** ou de **matrice**.
- Parfois, les données sont réparties dans différents tableaux qu'il faut réunir (join).

Types de variables

Nominale | Ordinale | Numérique

No	Sexe	Age	Tension artérielle	Hauteur	Medic ament
1	male	20	normal	175,0	A
2	female	73	normal	172,2	B
3	female	37	high	163,8	A
4	male	33	low	171,4	B
5	female	48	high	165,9	A
6	male	29	normal	182,3	A
7	female	52	normal	167,2	B
8	male	42	low	177,2	B
9	male	61	normal	168,4	B
10	female	30	normal	174,9	A

Numérique | Nominale

Types de variables

- **Qualitatives :** les valeurs sont des modalités
  - **Nominales** :
    - représentent des catégories
  - **Ordinales** :
    - représentent des catégories naturellement ordonnées.
    - La distance entre deux valeurs consécutives n'a pas de sens.
- **Quantitatives :** les valeurs sont des nombres réels
  - **Variables d'intervalles :**
    - La distance entre deux valeurs consécutives a toujours la même valeur
  - **Variables de ratios ou de rapport**
    - Il existe un zéro naturel qui signifie l'absence de l'élément.

Variables nominales

Nominale

No	Sexe	Age	Tension artérielle	Hauteur	Medic ament
1	male	20	normal	175,0	A
2	female	73	normal	172,2	B
3	female	37	high	163,8	A
4	male	33	low	171,4	B
5	female	48	high	165,9	A
6	male	29	normal	182,3	A
7	female	52	normal	167,2	B
8	male	42	low	177,2	B
9	male	61	normal	168,4	B
10	female	30	normal	174,9	A

Nominale

- Les variables nominales (categorical) **ont un ensemble fini de valeurs possibles.**
- **La granularité doit être prise en compte**
  - Structure hiérarchique des catégories
  - par exemple, subdivision superficielle : aliments, non-aliments, boissons... subdivision plus détaillée pour les boissons : eau, bière, vin...
  - Quel est le niveau de granularité approprié ?
- **Domaine dynamique**
  - Certaines variables ont un domaine fixe (par exemple, les mois).
  - Pour d'autres variables, le domaine peut changer au fil du temps (par exemple, les produits d'un catalogue).
  - Ces variables doivent être identifiées et traitées
- **Nous pouvons faire de comparaisons de égalité/inégalité**

Variables ordinales

Ordinale

No	Sexe	Age	Tension artérielle	Hauteur	Medic ament
1	male	20	normal	175,0	A
2	female	73	normal	172,2	B
3	female	37	high	163,8	A
4	male	33	low	171,4	B
5	female	48	high	165,9	A
6	male	29	normal	182,3	A
7	female	52	normal	167,2	B
8	male	42	low	177,2	B
9	male	61	normal	168,4	B
10	female	30	normal	174,9	A

- Les variables ordinales ont un ordre linéaire supplémentaire offert par le domaine
- L'ordre ne fournit pas la distance entre deux objets

Par exemple, pour une variable contenante des diplômes universitaires, nous pouvons affirmer qu'un doctorat est un diplôme plus élevé qu'une maîtrise et qu'il est plus élevé qu'une licence.

- **On peut faire de comparaisons mais on ne peut pas faire l’addition des variables.**

Variables numériques

Numérique continue

No	Sexe	Age	Tension artérielle	Hauteur	Medic ament
1	male	20	normal	175,0	A
2	female	73	normal	172,2	B
3	female	37	high	163,8	A
4	male	33	low	171,4	B
5	female	48	high	165,9	A
6	male	29	normal	182,3	A
7	female	52	normal	167,2	B
8	male	42	low	177,2	B
9	male	61	normal	168,4	B
10	female	30	normal	174,9	A

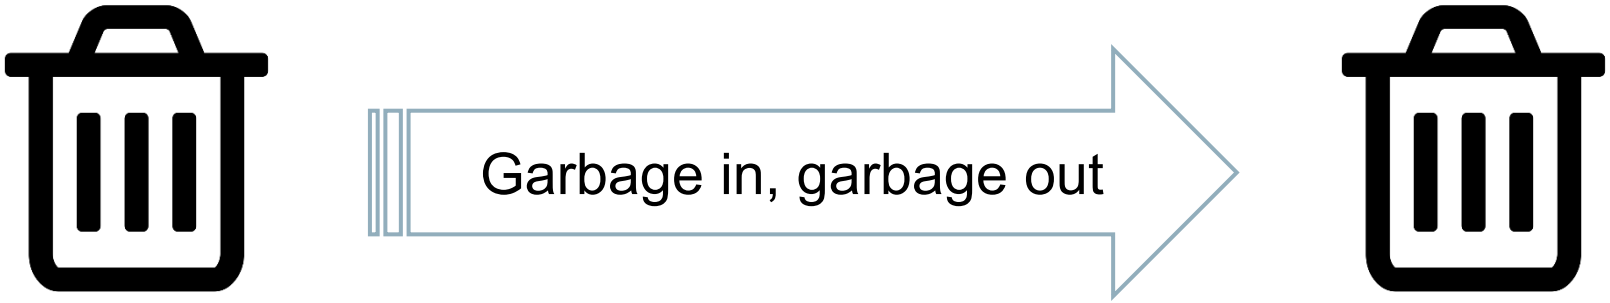
Numérique discrète

- Le domaine des variables numériques est celui des nombres. Elles peuvent être :
- **Discrètes**
  - par exemple, l'âge, le compte…
  - Sont représentées par des nombres entiers
- **Continues**
  - par exemple, la taille, le poids, la distance...
  - Représentées comme des valeurs réelles
  - La précision (arrondi) doit être gérée
- **L'échelle des variables numériques peut être :**
  - Echelle d'intervalle: e.g. une date, des températures Celsius
    - **On peut faire l'addition mais pas la multiplication entre les valeurs de la variable**
    - *Hier il faisait 2 fois plus de froid qu'aujourd'hui ?*
  - Échelle de rapport, par exemple la distance, avec une valeur zéro canonique
    - **On peut faire l'additions et la multiplication entre des valeurs de la variable**
    - **Il existe une origine (zéro) que signifie l'absence de l'élément.**

Récapitulatif des types de variables

	Quantitative (categorical)		Qualitative (numeric)	
Définition	**Nominales**	**Ordinales**	**Variables d'intervalles**	**Variables de ratios ou de rapport**
	représentent des catégories que l'on nomme avec un nom.	sont des catégories qui sont naturellement ordonnées. Un intervalle de « 1 » n'a pas toujours la même signification.	sont similaires aux variables ordinales sauf que l'intervalle entre deux catégories à toujours la même valeur, la même signification. Le zéro ne correspond pas l'absence de l'élément.	Les variables de ratios sont des variables d'intervalles avec un zéro naturel.
Exemples	Codes postales, no de téléphones, sexe, Vrais – Faux	échelle de Likert, grades académiques, ampleur des tremblements de terre	Température en degrés Celsius ou Fahrenheit, dates du calendrier, latitudes	Âge, température en Kelvin, nombre, longueur, poids
Opérations (logiques, numériques)	=, ≠	=, ≠, <, ≤, >, ≥	=, ≠, <, ≤, >, ≥, +, -	=, ≠, <, ≤, >, ≥, +, -, ×, ÷

La qualité des données



- La qualité des données fait référence à l'adéquation des données à l'usage auquel elles sont destinées..
- Il existe plusieurs dimensions de la qualité des données
  - La précision (Accuracy)
  - L’exhaustivité (Completeness)
  - Données déséquilibrées (Unbalanced Data)
  - Actualité (Timeliness)

La précision (Accuracy)

La précision est définie comme la proximité entre la valeur des données et la valeur réelle.

Syntaxique

- La valeur n’est pas correcte, mais elle n’appartient pas au domaine de l'attribut correspondant.
- **Facile à détecter** : vérifier les valeurs qui se trouvent dans le domaine

e.g. "fmale" pour la variable « Gender » et « -15 » pour la variable « weight » ne respectent pas la précision syntaxique.

Sémantique

- La valeur peut se trouver dans le domaine de l'attribut correspondant, mais elle n'est pas correcte.
- **Difficile ou impossible à détecter** : double vérification avec d'autres sources ou vérification des "règles de gestion".

e.g. « 2090 » pour la variable « YearOfBirth » est (du moins pour le moment) certainement incorrect, et donc contraire à la précision sémantique.

L’exhaustivité

- Exhaustivité en ce qui concerne les **variables**
  - Toutes les variables ont une valeur associée
  - **Au contraire** : certaines variables peuvent avoir des **valeurs manquantes**
    - **Attention** : Les valeurs manquantes ne sont pas toujours explicitement indiquées.
- Exhaustivité des **enregistrements** (records)
  - Le jeu de données contient les données nécessaires pour l'analyse.
  - **Au contraire** : Certaines lignes peuvent avoir été perdues pour diverses raisons (par exemple, lors de la migration de la base de données).
    - Parfois, les données relatives à une situation spécifique **n'existent tout simplement pas** (par exemple, les données relatives à une défaillance qui ne s'est encore jamais produite).
  - ***Il est difficile d'obtenir un ensemble de données raisonnablement large contenant toutes les combinaisons possibles de données.***

Données déséquilibrées et Actualité de données

Données déséquilibrées

- Les données relatives à une certaine situation peuvent être sous-représentées.
- Par exemple, en médecine : les exemples qui représentent une maladie sont significativement moins nombreux que les cas normaux.

Actualité de données

- Les données disponibles sont trop anciennes pour fournir des informations à jour.
- Problème fréquent dans les domaines à évolution dynamique, où les données plus anciennes peuvent indiquer des tendances qui ont disparues, e.g. réseaux sociaux (tendances sur un sujet particulier)

Statistique

La statistique est l'art **d'acquérir des données**, de les **représenter**, de les **analyser** et de les **interpréter** afin **d'acquérir de nouvelles connaissances**.

Les **concepts** et **procédures statistiques** peuvent être grosso modo divisés en deux catégories correspondant **aux deux principaux domaines de la statistique** :

- **les statistiques descriptives**
- **les statistiques inférentielles**

Statistiques descriptives vs. statistiques inférentielles

Les **statistiques descriptives** visent à rendre les données plus **compréhensibles** et **interprétables** en les représentant dans des **tableaux**, des **graphiques** et des **diagrammes**, et de les **résumer** en calculant certaines mesures caractéristiques.

- Indicateurs (moyennes, écart-types…)
- Graphiques « simples » (histogrammes, nuage de points…)
- Méthodes de synthèse de l'information (représentations factorielles, regroupement, segmentation…)

Dans les **statistiques inférentielles**, par contraire, on essaie **de tirer des conclusions sur le processus de génération des données**, comme **l'estimation des paramètres du processus** ou **la sélection d'un modèle qui s'y ajuste**.

- Tests, intervalle de confiance
- Modélisation
- Prédictions

La théorie des probabilités est à la base de nombreuses procédures de statistiques inférentielles.

Cadre des méthodes inférentielles

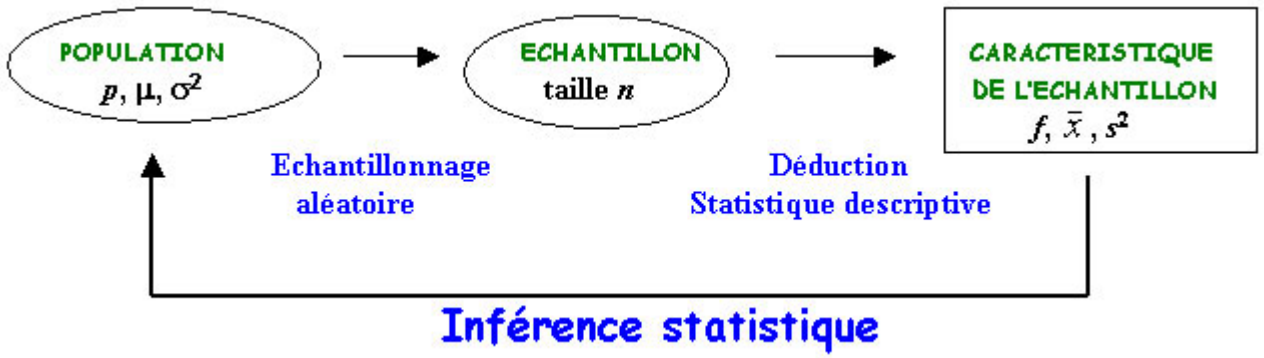
- L'étude porte sur une **population de référence** constituée par **de nombreux individus** dont on mesure **certains paramètres**.

- La population étant **trop importante** pour effectuer **un recensement**, on prélève **un échantillon** sur lequel on va effectuer l'analyse.

- On fait ensuite **une inférence à l'ensemble de la population** des résultats obtenus sur l'échantillon.

Schéma des statistiques inférentielles

- Un phénomène est complètement identifié si l'on connaît la loi de probabilité suivie par la variable aléatoire en fonction de la population..
  - soit **la loi de probabilité suivie par X** est connue a priori et on vérifie **a posteriori** que les observations faites à partir d'un échantillon sont en accord avec elle en effectuant e.g. un test d'ajustement
  - soit la **loi de probabilité suivie par X est inconnue** mais suggérée par la description de l'échantillon (nature de la variable, forme de la distribution des fréquences, valeurs des paramètres descriptifs)
- L'inférence statistique à partir d'un échantillon
  - Estimation de paramètres de la population (espérance, variance, probabilité de succès) à partir des données d'échantillon.
    - Il y a toujours un intervalle de confiance attaché à l'estimation
  - Test d'hypothèses
    - Il y a toujours **une probabilité attachée à l'inférence (valeur p)**



Exemples

- Exemples de population de reference
  - Ensemble des personnes qui sont traitées avec le médicament A ou B
  - Ensemble de la population française
  - Ensemble des abonnés à un opérateur de téléphonie mobile
  - Ensemble des champs cultivés en blé
- Exemple de paramètres mesurés sur les individus
  - Taille, poids, acuité visuelle, réponse au traitement…
  - Temps de communication, type d'abonnement…
  - Prix de vente, nombre d'unités au paquet…
  - Rendement, résistance aux maladies…
  - Production, quantité d'effluents rejetés…

L’échantillonnage

Le but est de créer un échantillon de la population

- Il existe plusieurs types d’échantillonnage suivant la connaissance que l’on a de la population de référence :
  - Sondage aléatoire
  - Sondage par quotas
  - …
- **L’échantillonnage aléatoire**
  - Les individus sont pris au hasard dans la population de référence incluse dans la base de sondage.
  - L’échantillon obtenu s’appelle échantillon aléatoire.
  - L’échantillonnage peut être avec ou sans remise (un individu peut apparaître plusieurs fois ou non)

Statistiques descriptives

- Représentations tabulaires (tableau de contingence)
- tableau de fréquence
  - Représente une variable
  - Fréquences absolues (f_k), relatives (r_k), absolues cumulées, relatives cumulées
- tableau de contingence
  - Représente deux variables nominales (mais peut aussi être utilisé avec des variable numériques)
  - Représente les fréquences (absolues ou relatives) des combinaisons des valeurs des variables
  - On peut avoir des tableaux de contingence multidimensionnelles

a_k	f_k	r_k	$\sum_{i=1}^{k} f_i$	$\sum_{i=1}^{k} r_i$
1	2	$\frac{2}{25} = 0.08$	2	$\frac{2}{25} = 0.08$
2	6	$\frac{6}{25} = 0.24$	8	$\frac{8}{25} = 0.32$
3	9	$\frac{9}{25} = 0.36$	17	$\frac{17}{25} = 0.68$
4	5	$\frac{5}{25} = 0.20$	22	$\frac{22}{25} = 0.88$
5	3	$\frac{3}{25} = 0.12$	25	$\frac{25}{25} = 1.00$

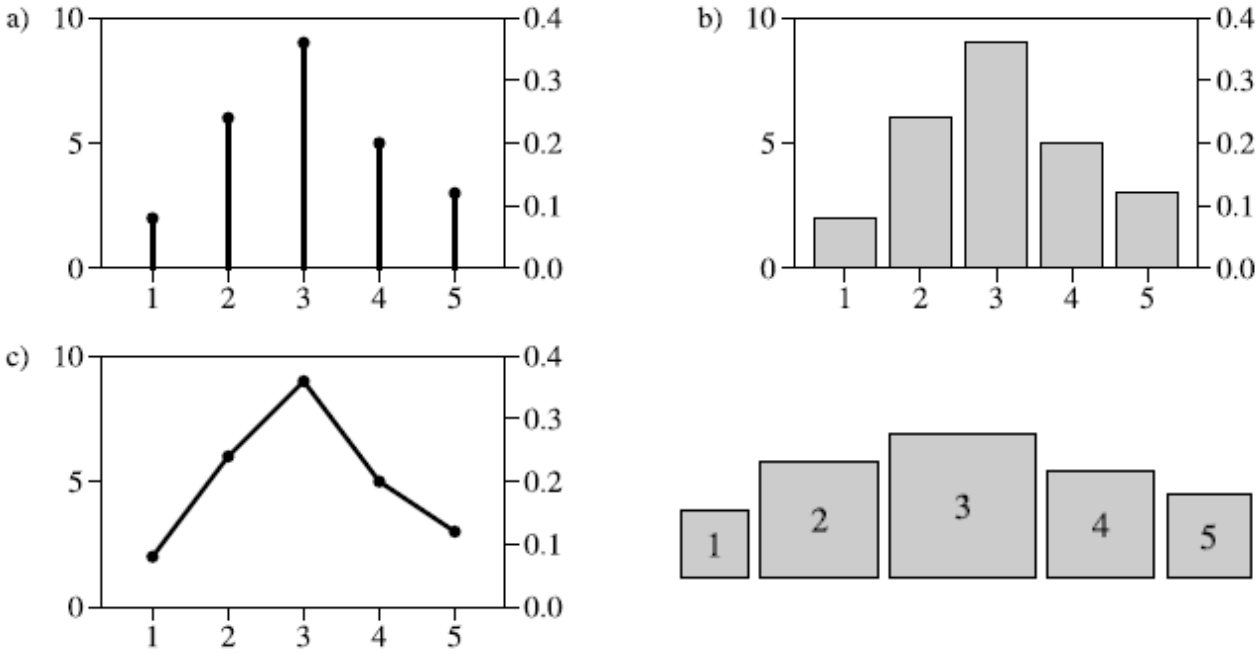
	a_1	a_2	a_3	a_4	$\sum$
b_1	8	3	5	2	18
b_2	2	6	1	3	12
b_3	4	1	2	7	14
$\sum$	14	10	8	12	44

Exemple

	Résultat				
Régime alimentaire	Cancers	Maladie cardiaque mortelle	Maladie cardiaque non mortelle	En bonne santé	somme
AHA	15	24	25	239	303
Méditerranéen	7	14	8	273	302
somme	22	38	33	512	605

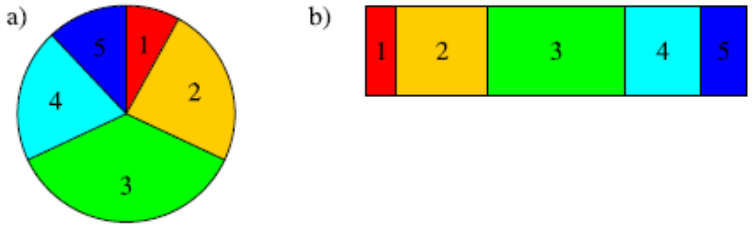
- Une enquête sur un échantillon de 605 personnes ayant survécu à une crise cardiaque
  - La moitié des personnes ont suivi un régime alimentaire proposé par la Association américaine de cardiologie (AHA) et les autres ont suivi un régime Méditerranéen
  - Deux variables: le « régime », le « résultat » à la fin des 4 ans
- Question à répondre
  - Est-ce le régime Méditerranéen supérieur d'un régime pauvre en graisses proposé par la AHA ?

Représentations graphiques d'une variable



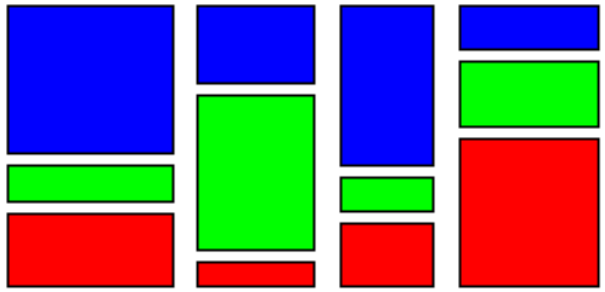
(a) Graphique en bâtons
(b) Graphique en barres
(c) Polygones de fréquence
(d) Graphique de surface

a_k	f_k	r_k	$\sum_{i=1}^{k} f_i$	$\sum_{i=1}^{k} r_i$
1	2	$\frac{2}{25} = 0.08$	2	$\frac{2}{25} = 0.08$
2	6	$\frac{6}{25} = 0.24$	8	$\frac{8}{25} = 0.32$
3	9	$\frac{9}{25} = 0.36$	17	$\frac{17}{25} = 0.68$
4	5	$\frac{5}{25} = 0.20$	22	$\frac{22}{25} = 0.88$
5	3	$\frac{3}{25} = 0.12$	25	$\frac{25}{25} = 1.00$

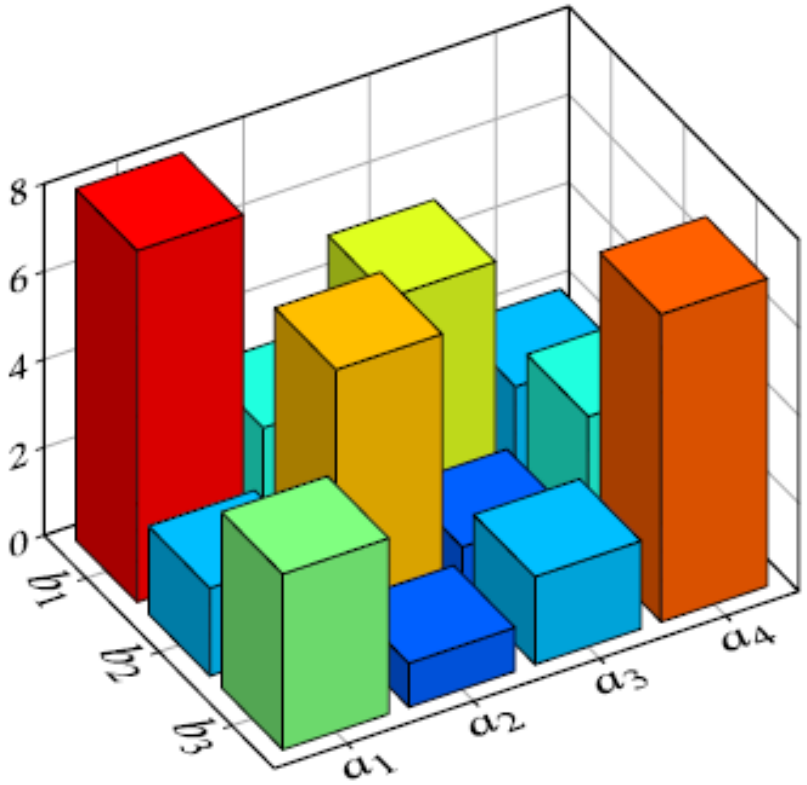


(a) diagramme à secteurs
(b) diagramme à bandes

Représentations graphiques de deux variables



	a_1	a_2	a_3	a_4	$\sum$
b_1	8	3	5	2	18
b_2	2	6	1	3	12
b_3	4	1	2	7	14
$\sum$	14	10	8	12	44



(a) Graphique en mosaïque
(b) Graphique en barres

Histogramme - Nuage de points

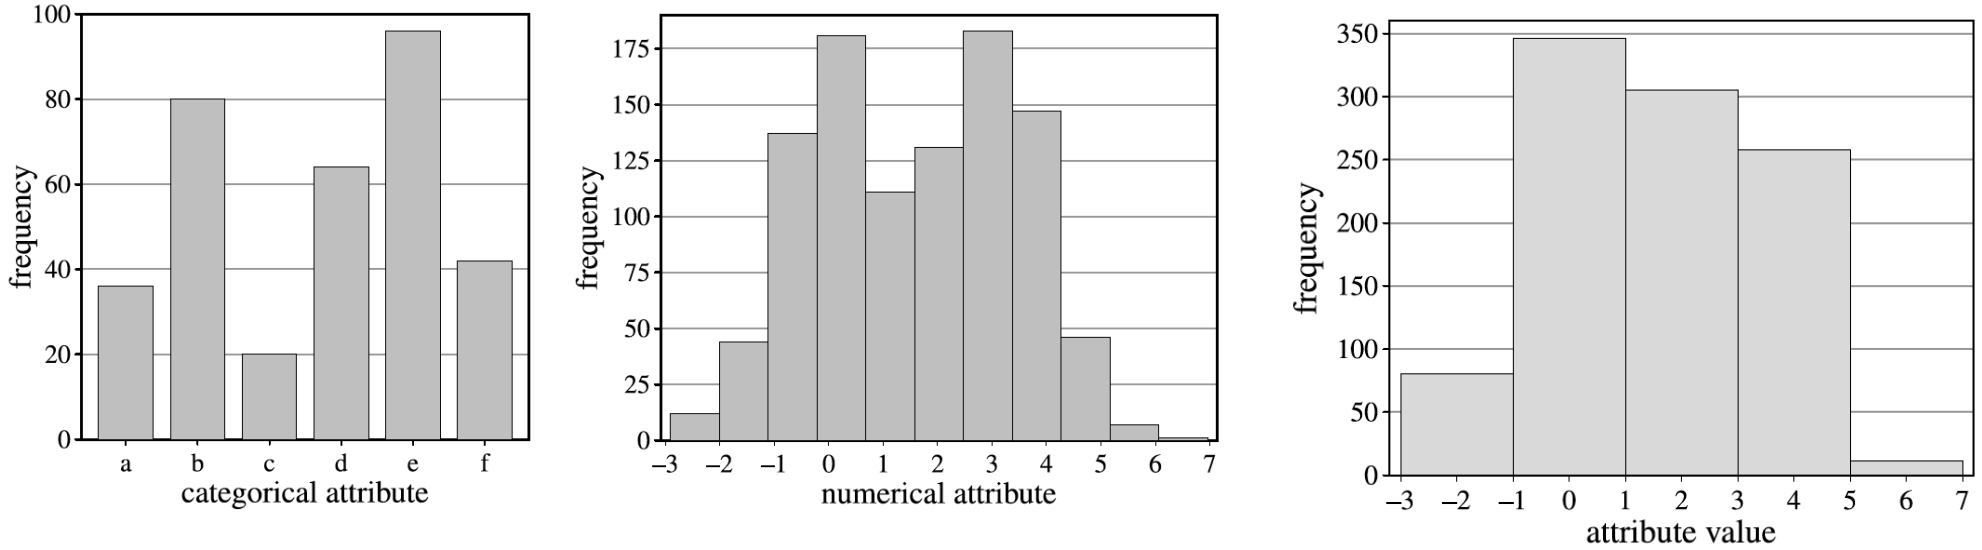
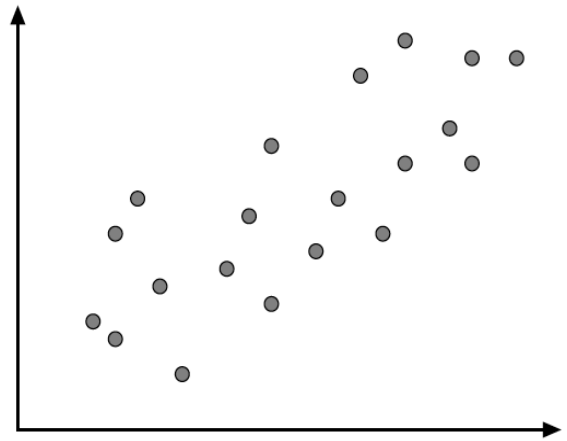


Fig. 4.2 A bar chart (categorical attribute, *left*) and a histogram (numerical attribute, *right*)



Nuage de points (scatter plot) 2D de deux variables

- Un histogramme représente **la répartition** (distribution) **empirique** d'une variable aléatoire.
- Si on a des variables numériques **le nombre de catégories (bins)** doit être spécifié en **précisant les intervalles des catégories** (bins)
- La distribution des mêmes données semble bimodale en utilisant des intervalles fins et unimodale en utilisant des intervalles plus larges.

Indicateurs de position (mesures de tendance centrale)

- **La Valeur modale** (Mode)
  - la valeur la plus fréquente dans l'échantillon
- **La Médiane** (Median)
  - c’est la valeur de variable, qui divise la distribution en deux: la moitié des cas sont inférieurs et l’autre moitié supérieurs à cette valeur.
- **Le quantile d’ordre p (p-quantile)**
  - c’est une valeur de variable telle qu'une certaine proportion p (0 <p< 1) des valeurs (ordonées) de l'échantillon est inférieure à cette valeur de variable.
  - La médiane, en particulier, est le 1/2-quantile (empirique) d’un ensemble de données.
- **La Moyenne**
  - est égale à la somme des valeurs de données divisée par leur nombre $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$

Indicateurs de dispersion

Ils mesurent la variabilité des valeurs d'une série statistique sont toujours positif et d'autant plus grand que les valeurs de la série sont étalées.

- **Plage, intervalle** (range)**:** $R = x_{max} - x_{min}$
- **L'écart interquartile** (Interquartile Range IQR) est la différence entre le troisième et le premier quartile (0.25-quantile).
- **L'écart absolu moyen (The average absolute deviation)** est la moyenne arithmétique des valeurs absolues des écarts à la médiane ou à la moyenne.

$$d_{\tilde{x}} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \tilde{x}| \qquad d_{\bar{x}} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \bar{x}|$$

Indicateurs de dispersion

- **Variance et écart-type :** Par analogie avec l'écart absolu, on peut également calculer l'écart quadratique moyen

Variance

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - \frac{1}{n}\left(\sum_{i=1}^{n} x_i\right)^2\right)$$

écart-type

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2},$$

Quelle est la différence entre les deux formules la variance ?
Quelle serait votre préférence si vous disposiez d'un grand ensemble de données ?

Mesures de forme

- Le **coefficient d'asymétrie** (**skewness)** L'asymétrie indique si une distribution diffère d'une distribution symétrique et, si oui, de combien.
- **La kurtosis** (aplatissement) décrit l'intensité de la courbure d'une distribution en forme de cloche et donc l'inclinaison du pic (par rapport à la courbe en cloche gaussienne idéale).



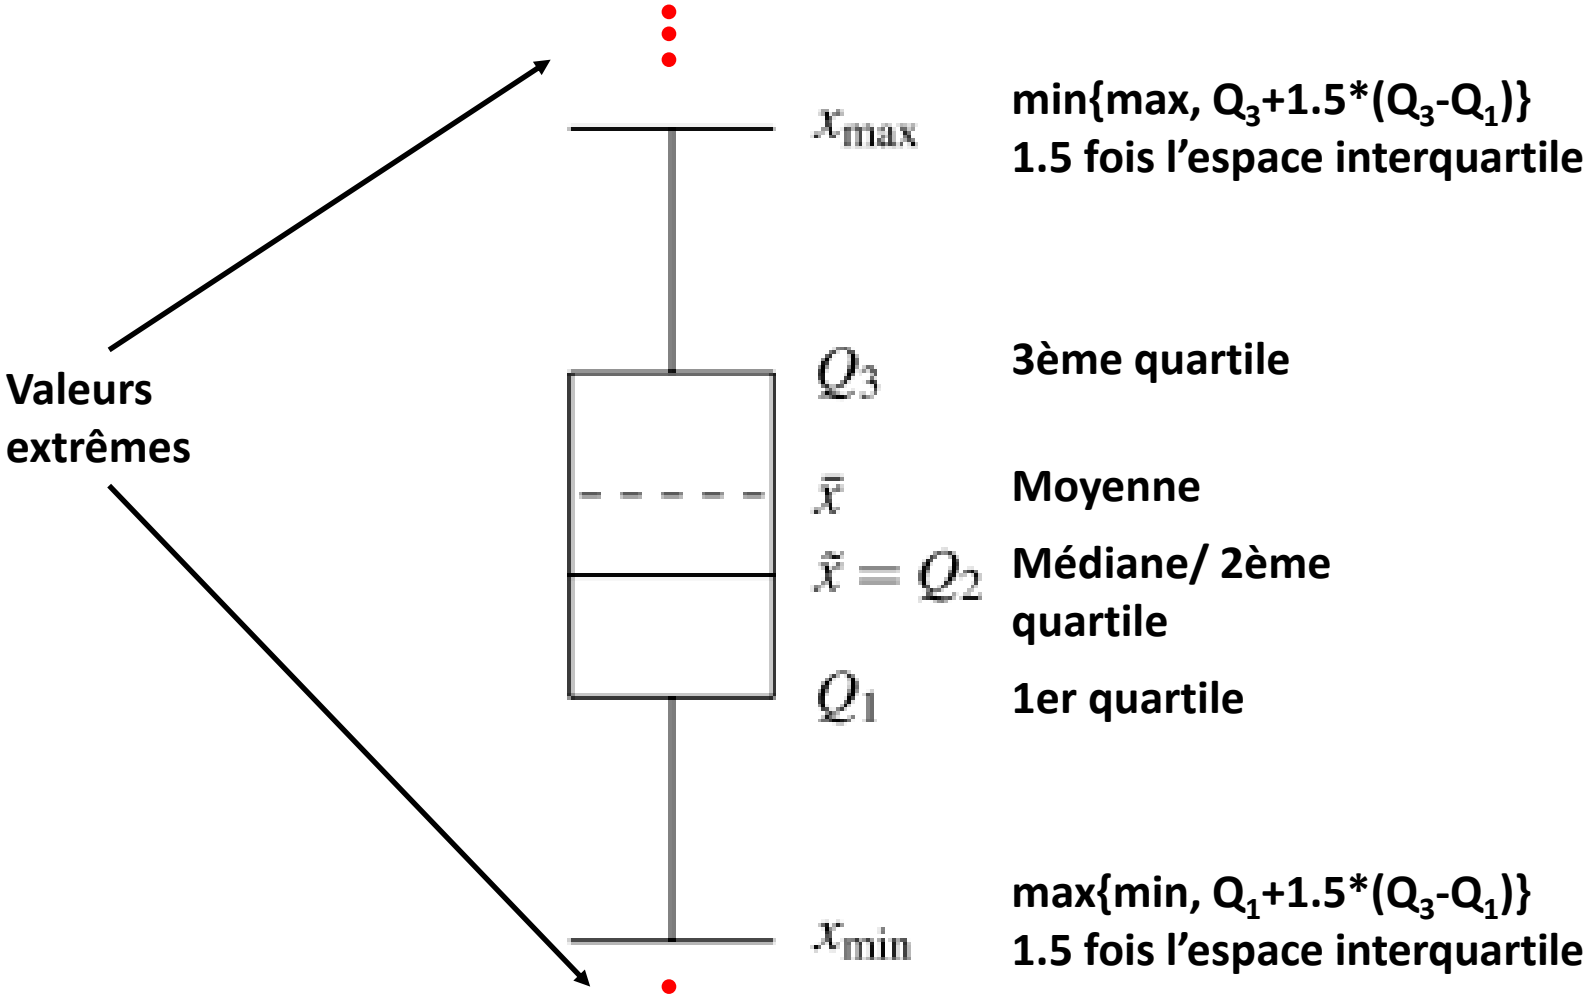
Fig. A.7 Illustration of the shape measure *skewness*



Fig. A.8 Illustration of the shape measure *kurtosis*

La boîte à moustache (Box Plot)

Un diagramme box plot, est un diagramme simple qui présente les plus importantes caractéristiques d'une variable



min{max, Q_3+1.5*(Q_3-Q_1)}
1.5 fois l'espace interquartile

3ème quartile

Moyenne

Médiane/ 2ème quartile

1er quartile

max{min, Q_1+1.5*(Q_3-Q_1)}
1.5 fois l'espace interquartile

Characteristic Measures for Multidimensional Data

La moyenne pour des données multidimensionnelles devient la moyenne vectorielle des points de données. Par exemple, pour des données bidimensionnelles, nous avons

$$\overline{(x, y)} = \frac{1}{n}\sum_{i=1}^{n}(x_i, y_i) = (\bar{x}, \bar{y}).$$

La covariance fournit des informations sur la puissance de la dépendance (linéaire) des deux attributs.

$$\Sigma = \frac{1}{n-1}\sum_{i-1}^{n}\left(\begin{pmatrix} x_i \\ y_i \end{pmatrix} - \begin{pmatrix} \bar{x} \\ \bar{y} \end{pmatrix}\right)\left(\begin{pmatrix} x_i \\ y_i \end{pmatrix} - \begin{pmatrix} \bar{x} \\ \bar{y} \end{pmatrix}\right)^{\top} = \begin{pmatrix} s_x^2 & s_{xy} \\ s_{xy} & s_y^2 \end{pmatrix}$$

$$s_x^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right)$$ **Variance de x**

$$s_y^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} y_i^2 - n\bar{y}^2\right)$$ **Variance de y**

$$s_{xy} = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}\right)$$ **Covariance de x, y**

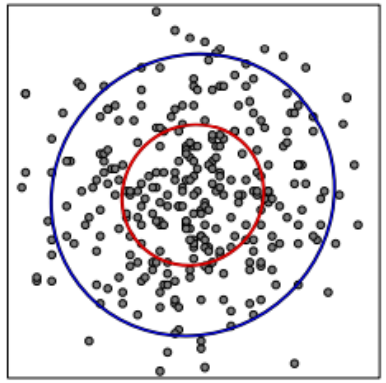
Corrélation

Le coefficient de corrélation produit-moment de Pearson

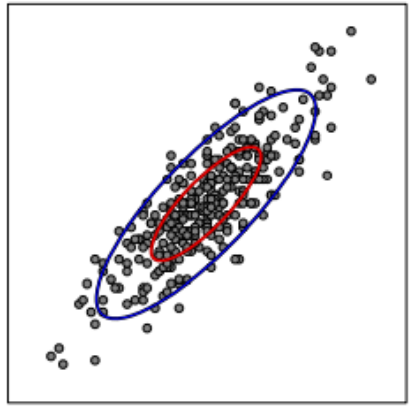
$$r = \frac{s_{xy}}{s_x s_y}.$$

Le coefficient de corrélation a une valeur entre -1 et +1 et caractérise la force de l'association linéaire entre deux variables.

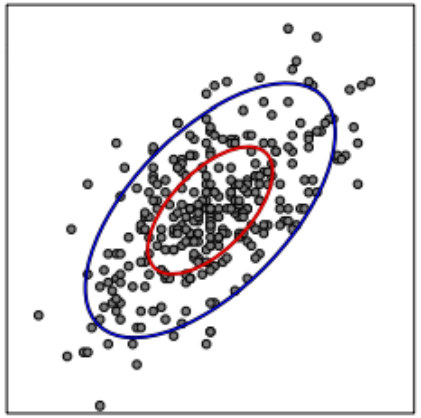
pas de corrélation



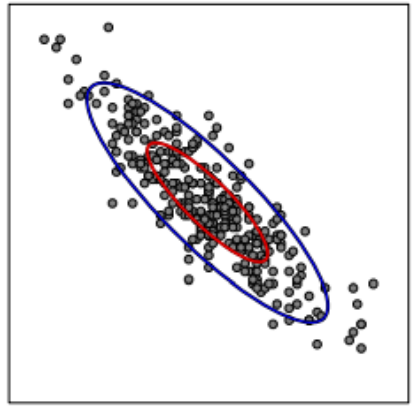
Forte corrélation positive



corrélation positive faible



Forte corrélation négative



Un dernier mot de prudence

Corrélation ⇏ Causalité

Corrélation et causalité

Hypothèse : Les cigognes apportent des bébés

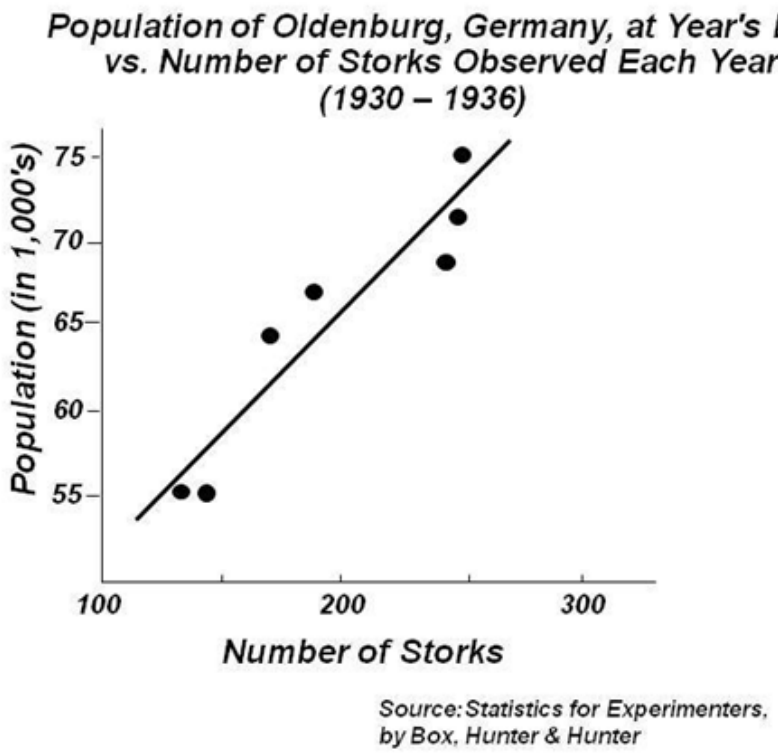
Le statisticien pionnier George Udny Yule, auteur en 1911 du fameux **Introduction to the Theory of Statistics** (Introduction à la théorie des statistiques), a expliqué **les facteurs de confusion** en se référant à la reproduction.



Udny Yule

Corrélation et causalité

Hypothèse: Les cigognes apportent des bébés



Dans les villages alsaciens

le **nombre de nouveau-nés** humains est **en corrélation** avec le **nombre de cigognes** qui nichent dans la région.

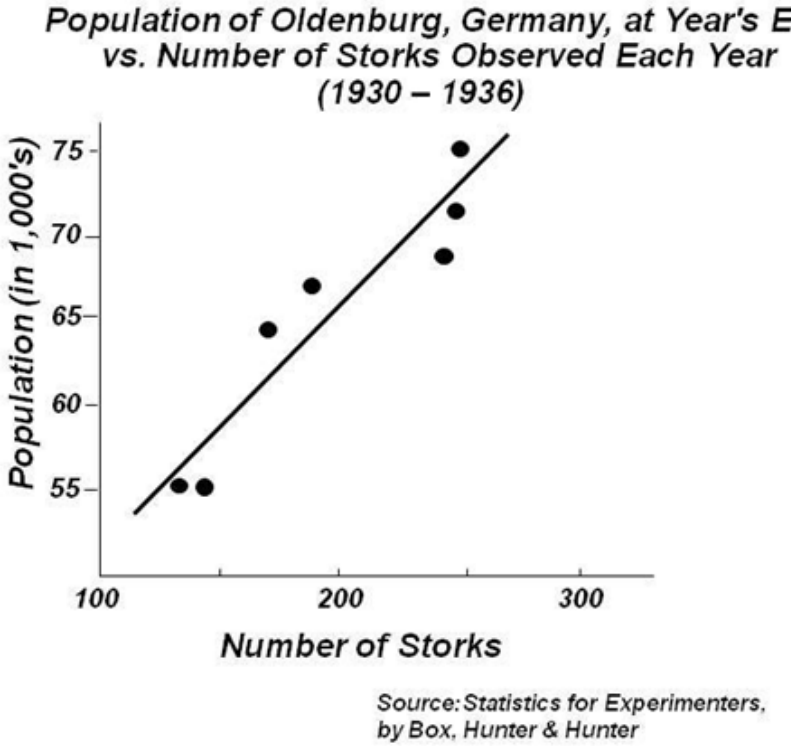
Pouvons-nous conclure que les cigognes mettent effectivement des bébés au monde ?

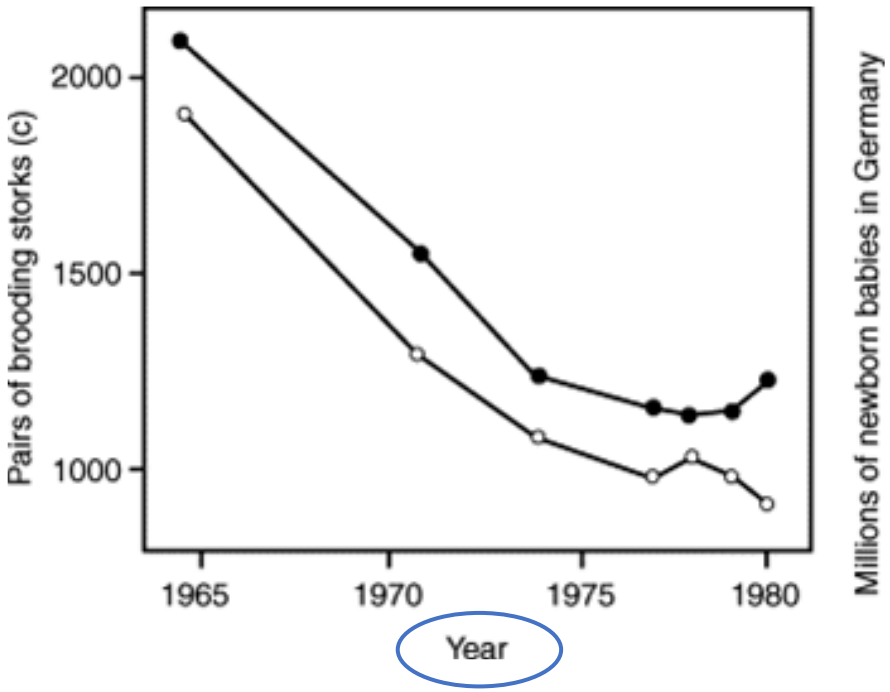


La corrélation est significative et positive !

Corrélation et causalité

Hypothèse: Les cigognes apportent des bébés





La véritable explication est bien plus banale :

1. Les grands villages comptent plus des maisons équipées de cheminées
2. Les cigognes construisent leurs nids dans les toits équipés de cheminées
3. La plus grand le village, plus les cheminées sont nombreuses , plus de bébés naissent.

Le facteur de confusion est la taille du village.

Le paradoxe de Simpson



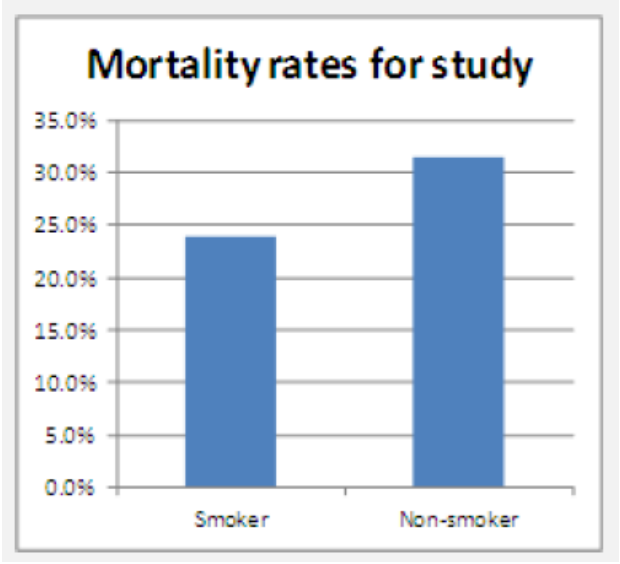
Edward H. Simpson

- Le paradoxe de Simpson est un phénomène relevant des probabilités et des statistiques, dans lequel **une tendance apparaît dans plusieurs groupes de données**, **mais disparaît ou s'inverse lorsque les groupes sont combinés**.
- Ce résultat est souvent rencontré dans les statistiques des sciences sociales et médicales;

Le paradoxe de Simpson

- Dois-je commencer à fumer pour vivre plus longtemps ?
- **Étude des taux de mortalité**

	Décédés	Survécus	Total	Taux de mortalité
Fumeurs	139	443	582	23.9%
Non-fumeurs	230	502	732	31.4%
Total	369	945	1314	28.1%



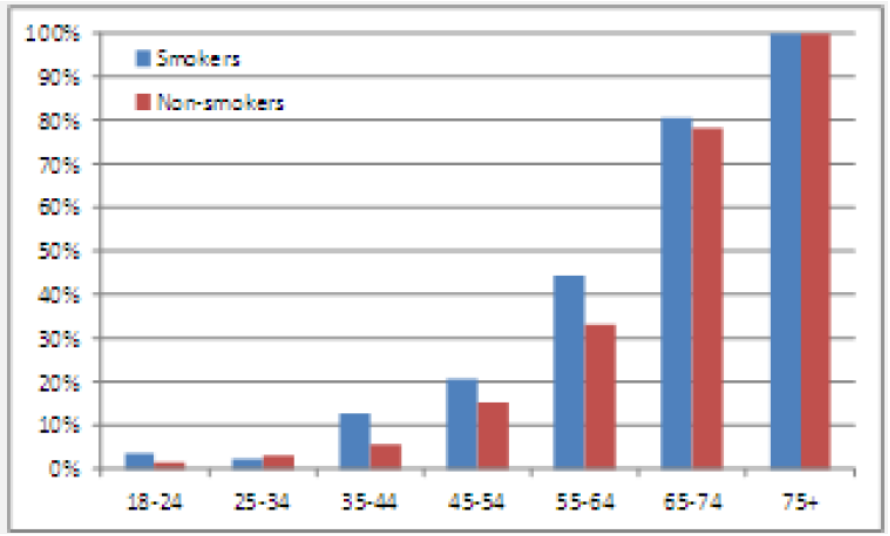
Que peut-on conclure de ces données ?

L’enquête

- Enquête mené auprès de 1314 femmes anglaises
- L’enquête a été réalisée en 1972-74 et les femmes ont été suivies 20 ans plus tard
- Les faits
  - Au milieu de 20e siècle, le tabac était impopulaire chez les femmes en Angleterre
  - Le tabac chez les femmes est devenu populaire dans les années 70, époque à laquelle les jeunes femmes ont commencé à fumer
  - Les jeunes femmes fumeuses avaient une espérance de survie plus que 20 ans (la durée de l’enquête)
- Alors l’échantillon de l’enquête était biaisé en faveur des jeunes femmes

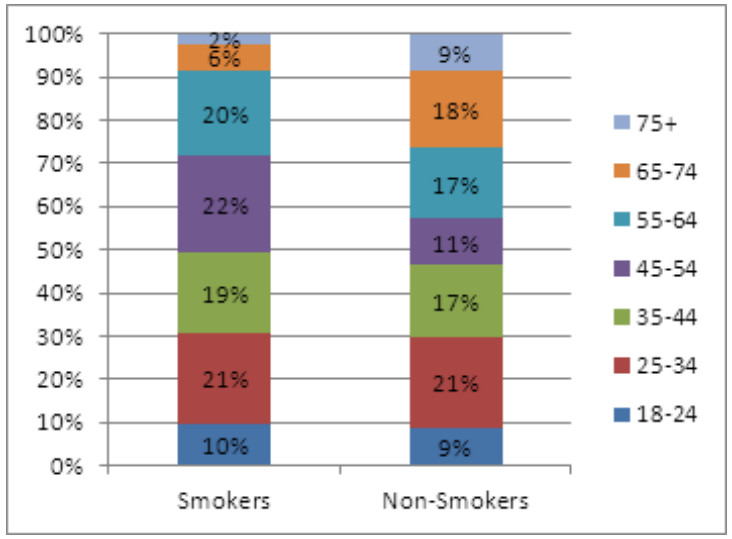
Simpson‘s Paradox

Mortality Rates by Age



Si l’on examine les taux de mortalité en fonction des groupes d’âge, la mortalité des fumeuses est plus élevée, dans presque tous les groupes.

Distribution of Age by Smoking Status



- 8% des fumeuses ont plus de 65 ans
- 27% des non-fumeuses ont plus de 65%

Ainsi, après 20 ans, les femmes âgées non fumeuses étaient plus nombreuses à mourir que les femmes âgées fumeuses.

Corrélation et causalité

Et que dire du chocolat et des prix Nobel ?

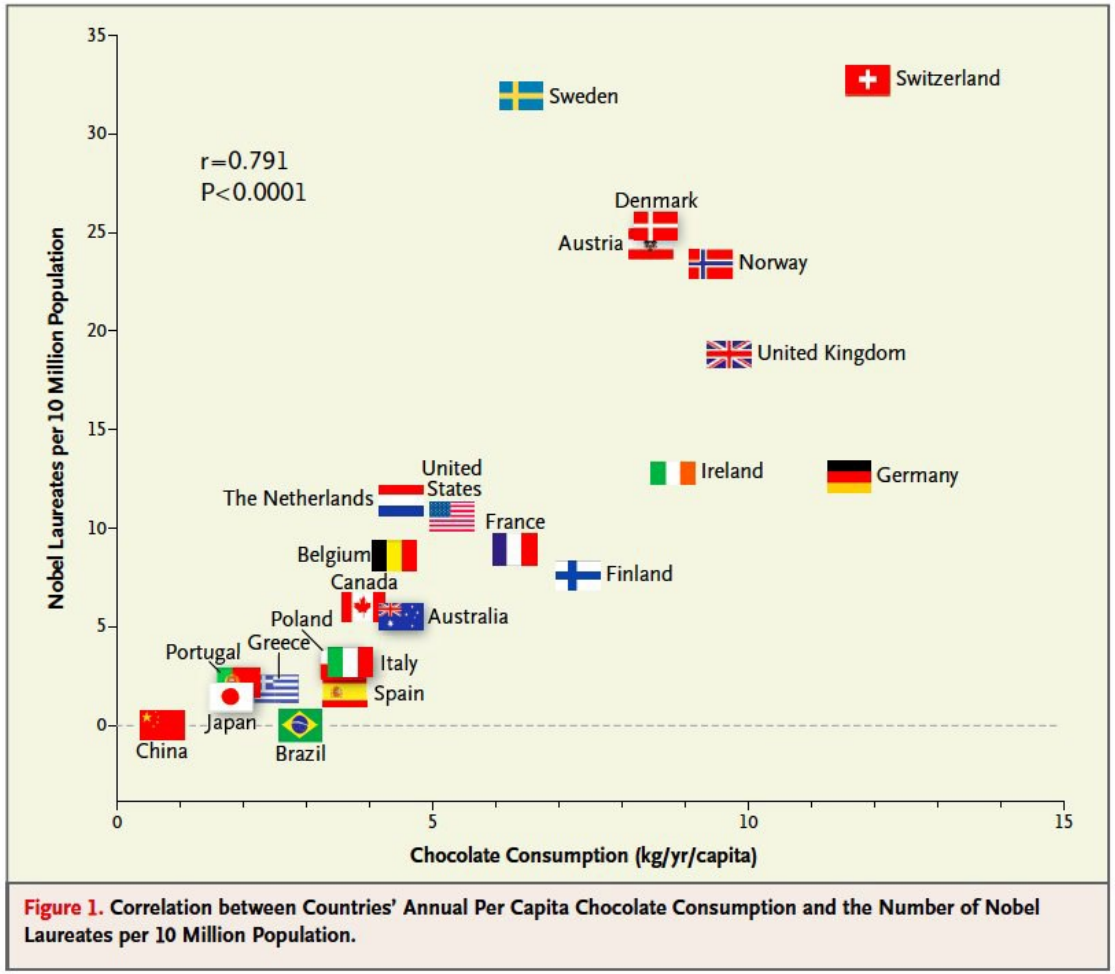


Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

https://www.biostat.jhsph.edu/courses/bio621/misc/Chocolate%20consumption%20cognitive%20function%20and%20nobel%20laurates%20(NEJM).pdf

STUDY LIMITATIONS

The present data are based on country averages, and the specific chocolate intake of individual Nobel laureates of the past and present remains unknown. The cumulative dose of chocolate that is needed to sufficiently increase the odds of being asked to travel to Stockholm is uncertain. This research is evolving, since both the number of Nobel laureates and chocolate consumption are time-dependent variables and change from year to year.

Les données actuelles sont basées **sur des moyennes nationales**, et la **consommation spécifique de chocolat des lauréats Nobel** d'hier et d'aujourd'hui **reste inconnue**. La dose cumulée de chocolat nécessaire pour augmenter suffisamment les chances d'être invité à se rendre à Stockholm est incertaine.

Ne vous fiez pas à vos chiffres !

Loi de Twyman (Twymans's Law)

Toute statistique qui semble intéressante est presque certainement une erreur.