

Statistique Exploratoire Multidimensionnelle

Thomas Papastergiou MCF

M2 de mathématiques

Mathématiques des Données

M2 en Informatique

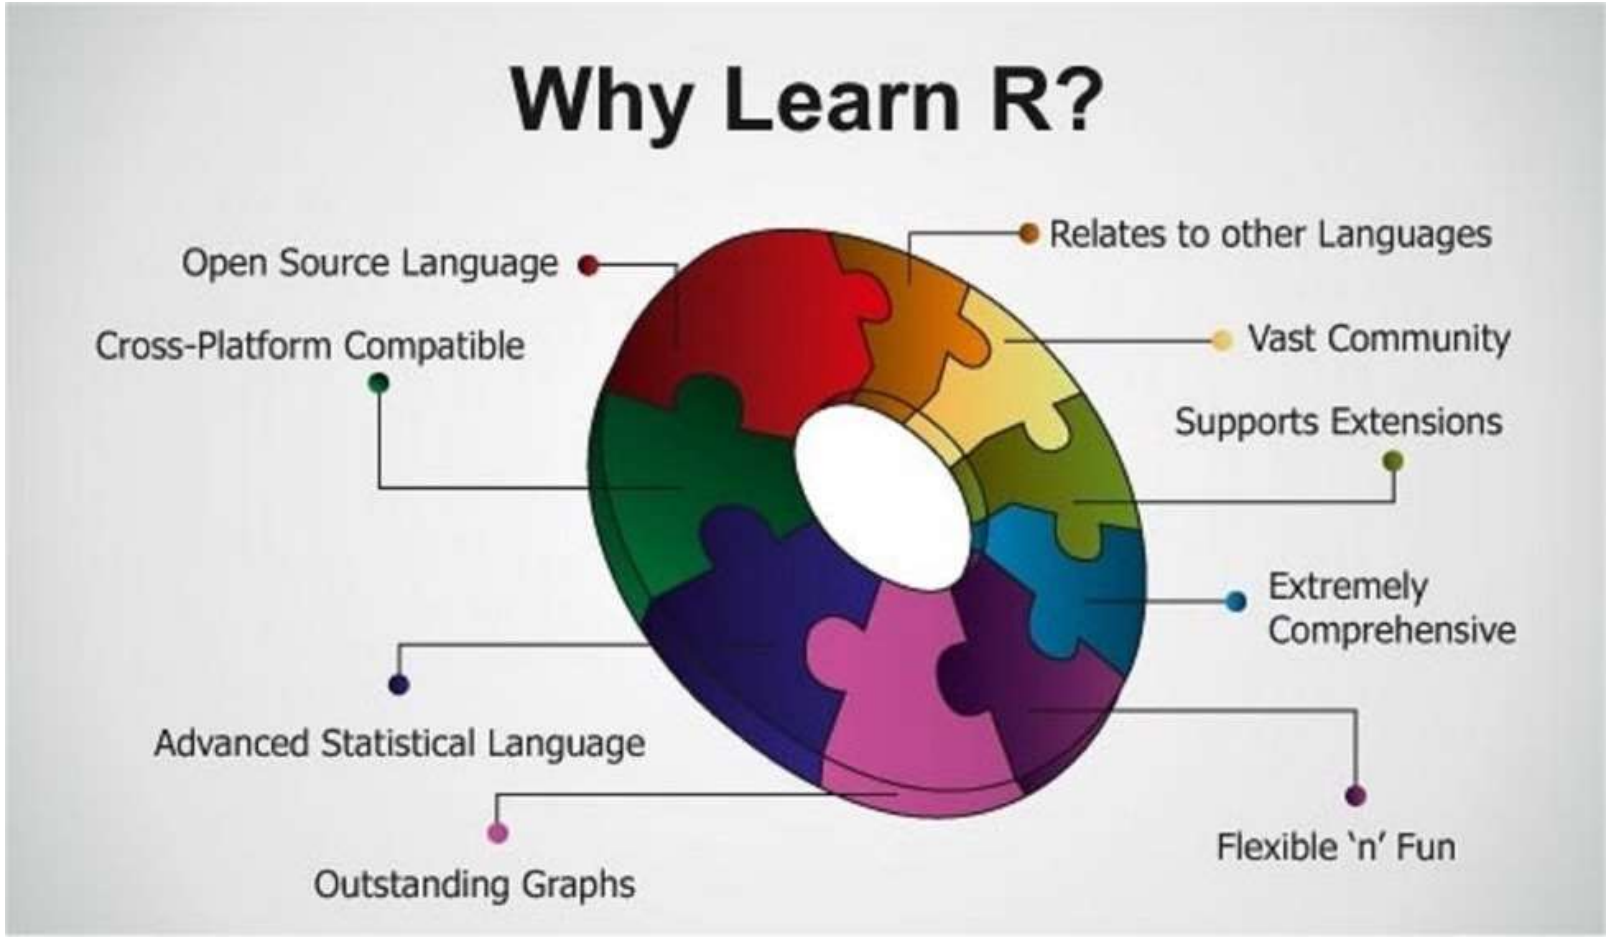
Exploration Informatique des données et décisionnel (EID^2)

Introduction à la langue R

Vue d'ensemble

- *R, Rstudio, Rattle*
- *Variables*
  - *Types*
  - *Operators*
  - *Basic operations*
  - *Lists*
  - *Data frames*
  - *Matrices*
- *Functions*
- *Data Loading*

Vue d’ensemble



Source:https://towardsdatascience.com/getting-started-with-r-programming-2f15e9256c9

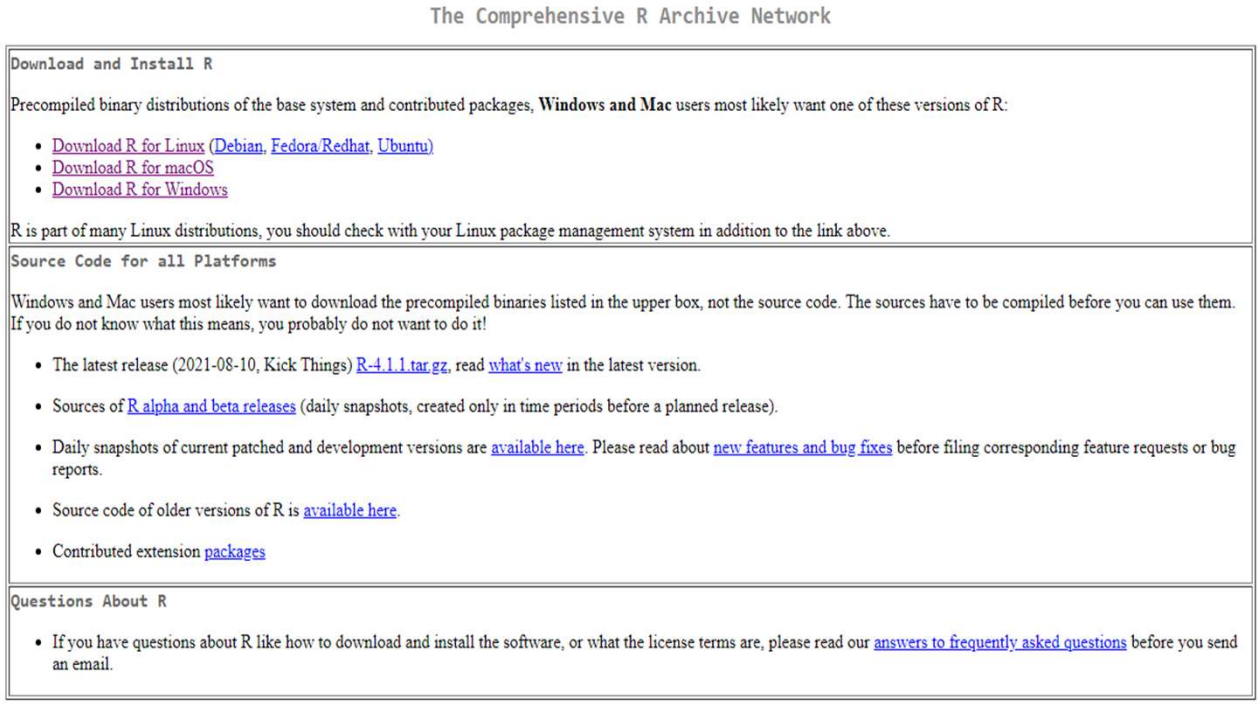
La langue R – The R Language

- *Analyse statistique et exploration de données*
- *Compatible avec les principaux systèmes d'exploitation*
  - *Windows*
  - *Linux*
  - *Mac OS*
- *Grande variété de méthodes supportées*
  - *Classification*
  - *Regroupement*
  - *Modélisation linéaire et non linéaire*
  - *Tests statistiques classiques*
  - *Analyse des séries temporelles.*
  - *...*

Installer R (1/3)

- *Visitez https://cloud.r-project.org/*

pour télécharger la distribution correcte pour votre système d'exploitation



The Comprehensive R Archive Network

Download and Install R

Precompiled binary distributions of the base system and contributed packages, **Windows and Mac** users most likely want one of these versions of R:

- Download R for Linux (Debian, Fedora/Redhat, Ubuntu)
- Download R for macOS
- Download R for Windows

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

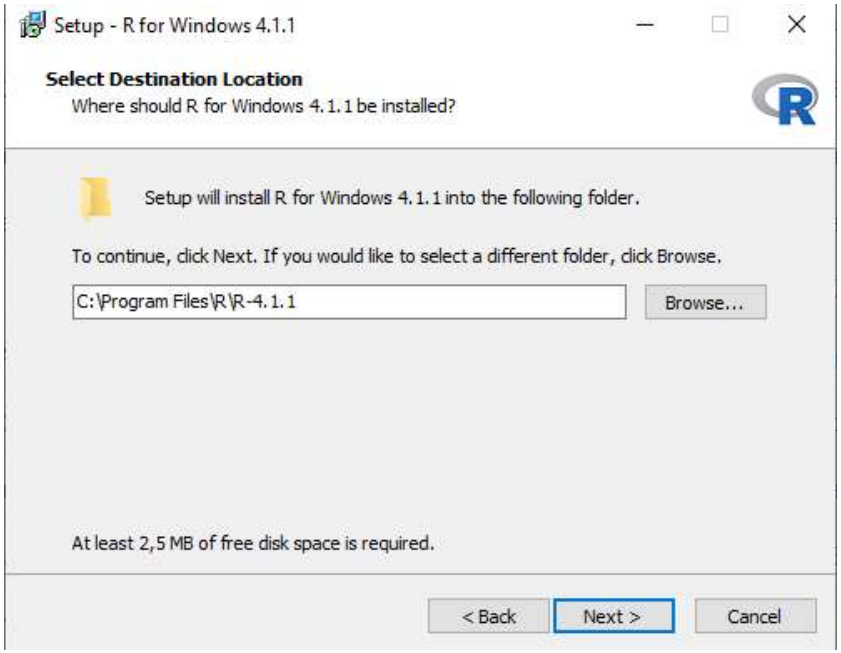
- The latest release (2021-08-10, Kick Things) R-4.1.1.tar.gz, read what's new in the latest version.
- Sources of R alpha and beta releases (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are available here. Please read about new features and bug fixes before filing corresponding feature requests or bug reports.
- Source code of older versions of R is available here.
- Contributed extension packages

Questions About R

- If you have questions about R like how to download and install the software, or what the license terms are, please read our answers to frequently asked questions before you send an email.

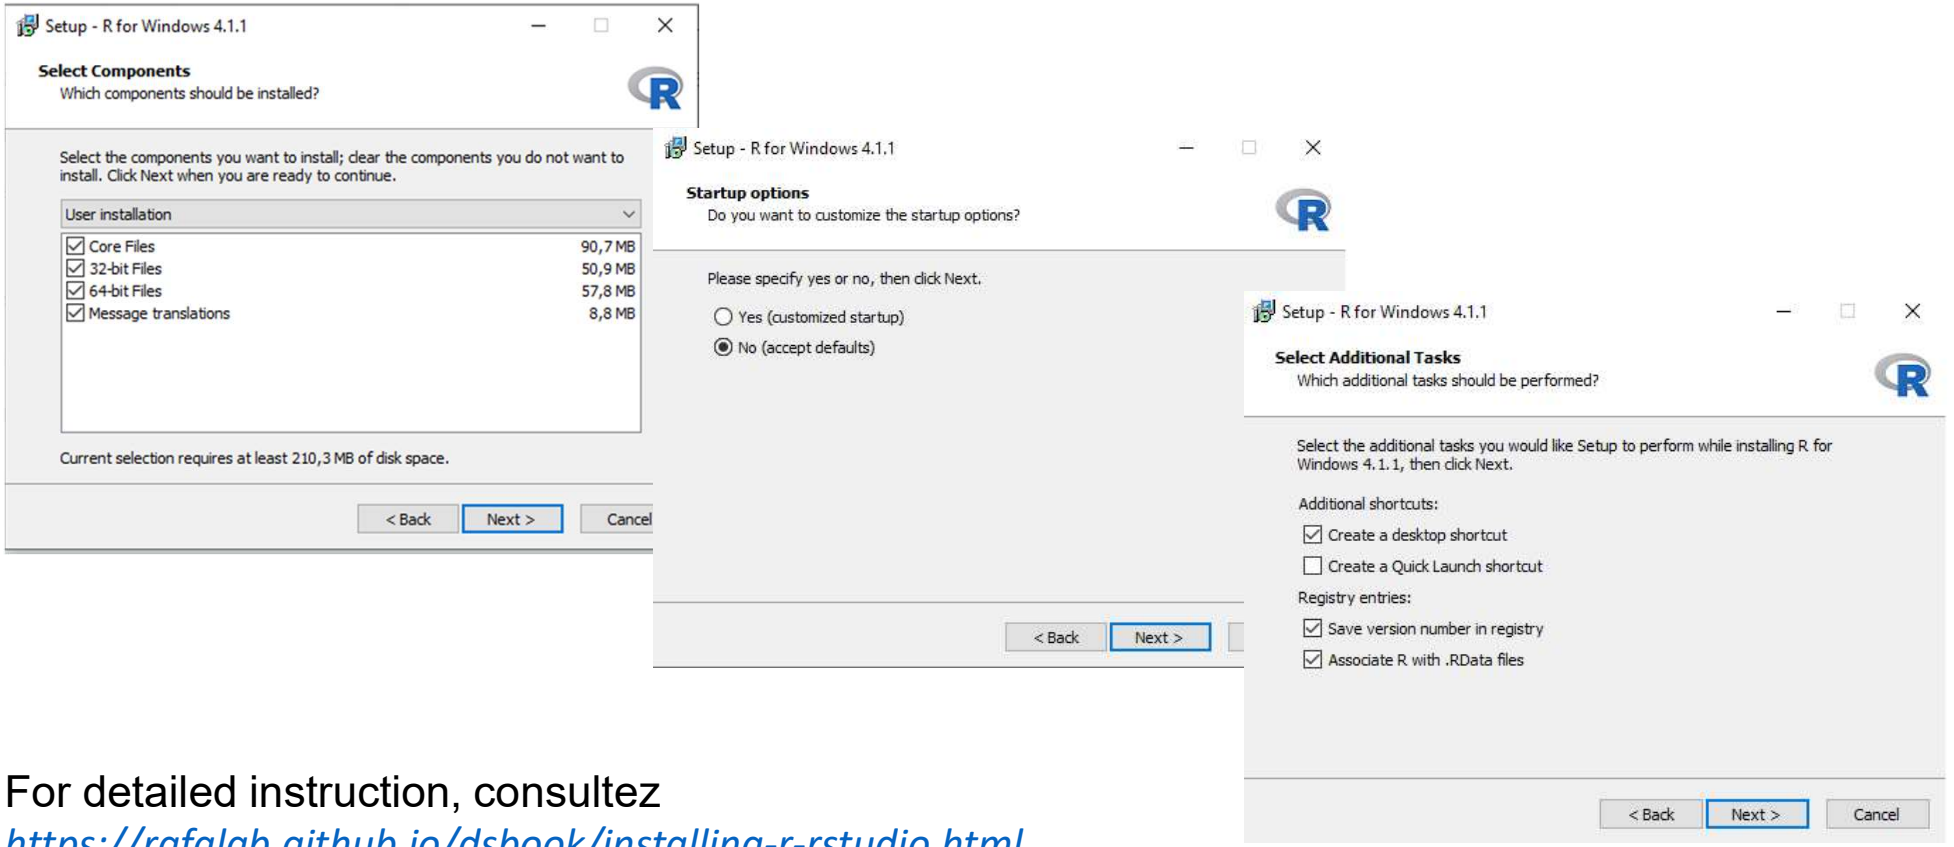
Installer R (2/3)

- Téléchargez le fichier binaire, exécutez-le, puis sélectionnez le dossier sur votre PC pour installer R



Installer R (3/3)

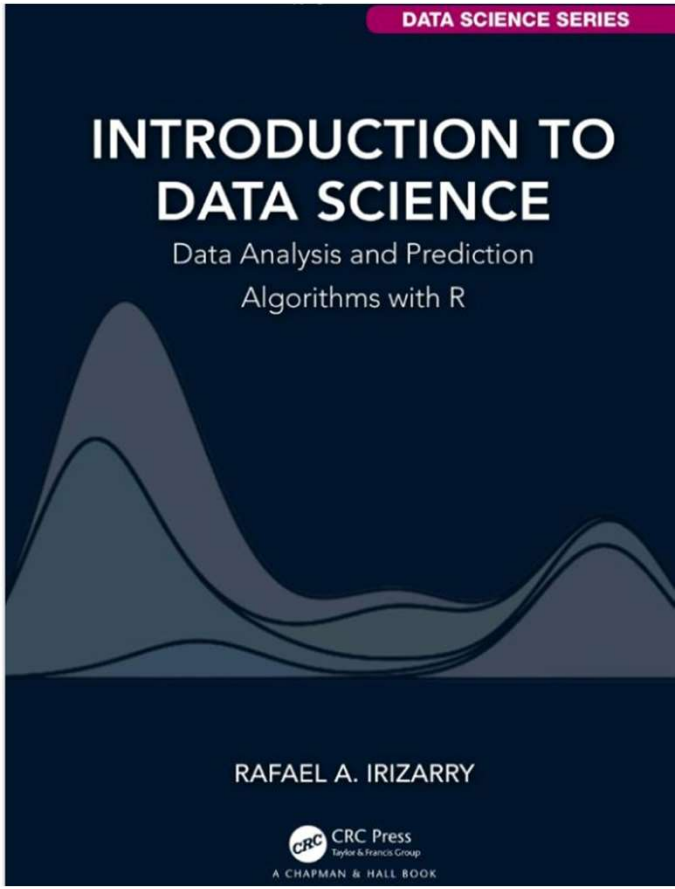
- *Choisissez les options par défaut et installez*



For detailed instruction, consultez
https://rafalab.github.io/dsbook/installing-r-rstudio.html

Pause-ressources

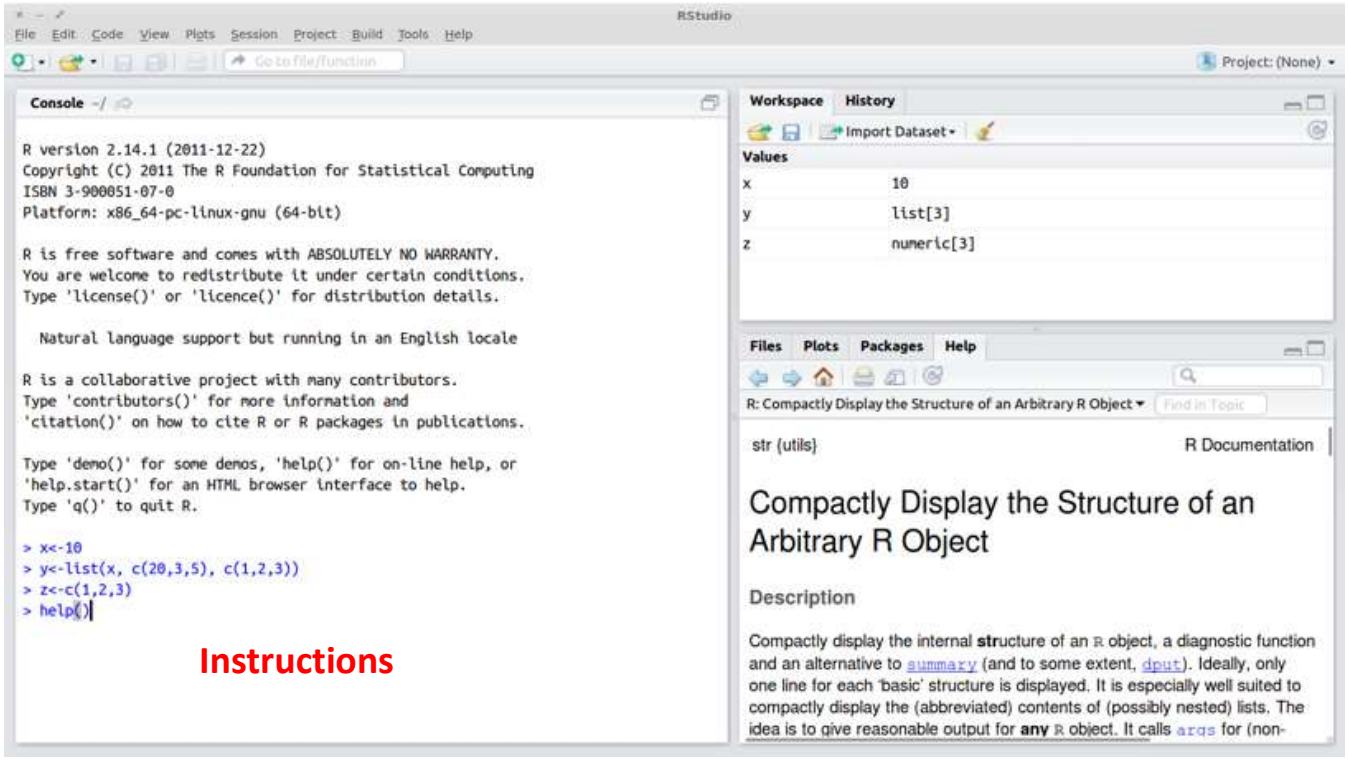
- **Introduction to Data Science**
  - ***Data Analysis and Prediction Algorithms with R***
  - *Rafael A. Irizarry*
- http://rafalab.dfci.harvard.edu/dsbook-part-1/
- http://rafalab.dfci.harvard.edu/dsbook-part-2/



RStudio

- *RStudio: Integrated Development Environment (IDE) pour l'R*
  - *Environnement Windows - facilite l'utilisation de R*
- *Compatible avec les principaux systèmes d'exploitation*
- *Installation à partir de https://posit.co/download/rstudio-desktop/*

RStudio



Environement

help

The Rattle Graphical Environment

- *Rattle: a graphical environment for R*
  - *File loading*
  - *Execution of data mining algorithms*
  - *Processing and storing of results*
- *Compatible with major OSs*
- *Installation from http://rattle.togaware.com/*

On Windows 10 (Tested 1 September 2023)

Download, open, install (create desktop and quick launch shortcuts as desired) , and startup R from https://cran.r-project.org/bin/windows/base/old/4.1.3/R-4.1.3-win.exe

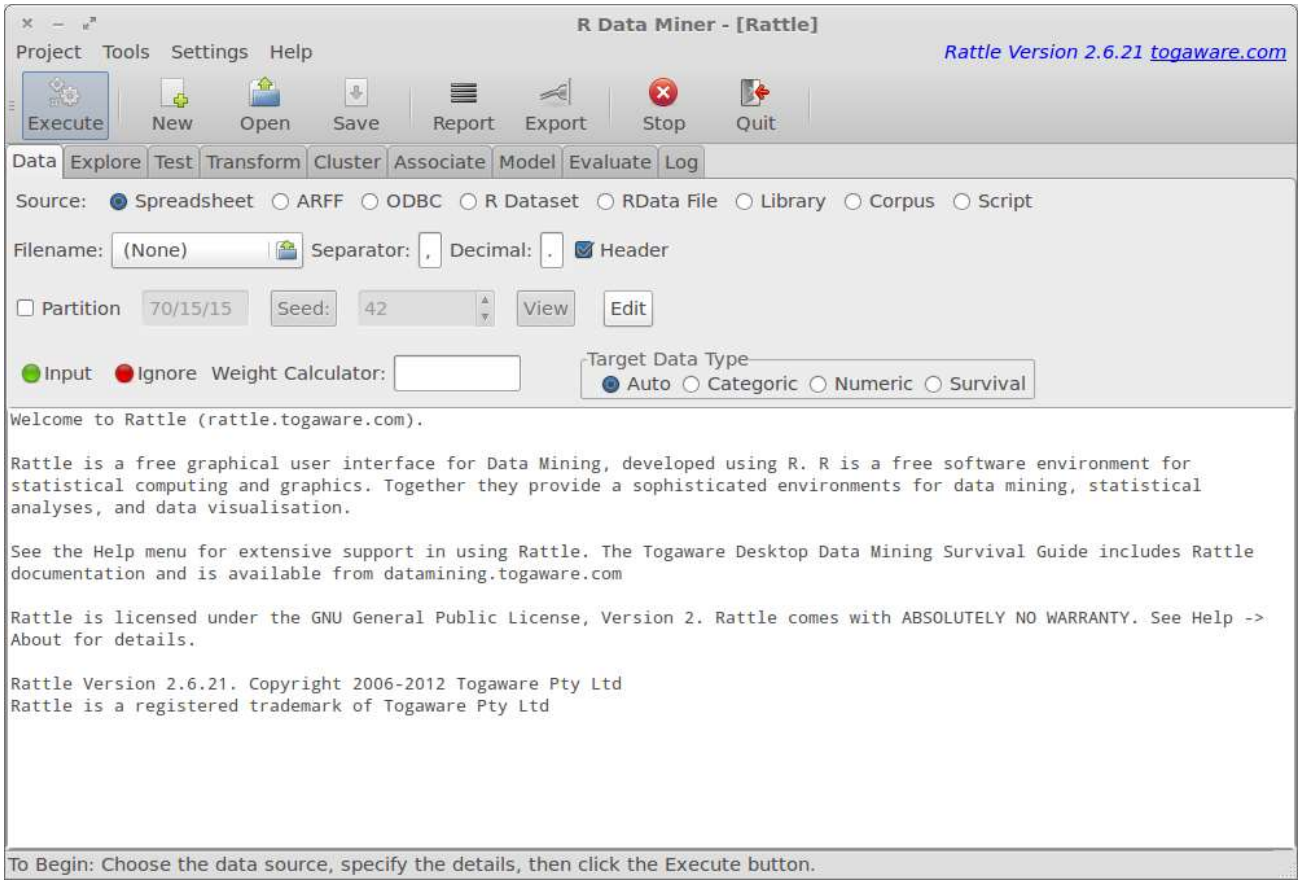
```
> install.packages("rattle")
> install.packages("https://access.togaware.com/RGtk2_2.20.36.2.zip", repos=NULL)

> library(rattle)
> rattle()
```

When prompted to install Gtk2, click OK.

A compatible version of RStudio can be installed from https://s3.amazonaws.com/rstudio-ide-build/desktop/windows/RStudio-2022.02.2-485.exe

The Rattle Graphical Environment



Types de variables

Différents types de variables, i.e.,:

numéros : `x<-10; y<-3.1415`

strings : `x<-"Hello World"`

vectors : `x<-1:10`

- Le vecteur (vector) est une structure de données de base dans R.
  - Il contient des éléments du même type.
  - Les types de données peuvent être: logiques, entiers, doubles, caractères, complexes ou bruts.
  - Le type d'un vecteur peut être vérifié à l'aide de la fonction **`typeof()`**
  - La longueur est le nombre d'éléments du vecteur et peut être vérifiée à l'aide de la fonction **`length()`.**

factors : similaires aux types énumérés en C, i.e.,

- Les facteurs sont les objets de données utilisés pour catégoriser les données et les stocker sous forme de niveaux.

```
gender<-factor("male", "female")
```

- **Il n'est pas nécessaire de définir avant l'utilisation...**

Opérateurs arithmétiques et variables

- Pour imprimer la valeur d'une variable il suffit de taper le nom de la variable
- `y <- 3.1415 <ENTER>` number

```
y
[1] 3.1415
2*y
[1] 6.283
x<-1:4
x
[1] 1 2 3 4
```

Opérateurs arithmétiques et variables

- Chaque opération/fonction prend en considération le type de la variable
- i.e., les opérateurs arithmétiques:

```
x <- 1:4          vector
y <- 2            number
z <- 2:5          vector
y*x               product
[1] 2 4 6 8
x*z
[1] 2 6 12 20
x[1]*y
[1] 2
```

- Quels sont les résultats des opérations suivantes ?

```
2:-2 <ENTER>
sqrt(x) <ENTER>
sqrt(y) <ENTER>
sqrt(x*y) <ENTER>
z-x <ENTER>
```

Opérations de base sur les variables

- Concaténation (Concatenation)

```
x <- 1:4 ; y <- 5:8 ; c(x,y) <ENTER>
[1] 1 2 3 4 5 6 7 8
c(1:3, c(4:6, 7:10))
```

(recursive execution)

```
[1] 1 2 3 4 5 6 7 8 9 10
```

- Répétition (Repetition)

```
x <- 1:3 ; rep(x,2)
[1] 1 2 3 1 2 3
x <- 1:3 ; rep(x,c(1,3,2))
[1] 1 2 2 2 3 3
```

- Sequence

```
x <- seq(1,4);x
[1] 1 2 3 4
x <- seq(1,5, by=2);x
```

step=2

```
[1] 1 3 5
x <- seq(1,7, length=4);x
[1] 1 3 5 7
```

- Quel est le résultat ?

```
x <- c("hello", c(" ",
"world")); x <ENTER>
```

En général, rep(x, times) se traduit par :
- si times=d [integer], “x“ sera répété d fois
- si times=d [vector], x[1] sera répété d[1] fois, x[2] d[2] fois etc.

Opérations de base sur les variables

de fonctions utiles

- sum

```
x <- 1:4 ; sum(x)
[1] 10
sum(rep(x,2))
[1] 20
sum(x^2)
[1] 30
```

- Quel sera le résultat?

```
sum(rep(-2:2, 2))
sum(rep(-2:2, 2)^2)
```

Opérations de base sur les variables

Useful functions

- **structure:**
  - str() est utilisée pour afficher de manière compacte la structure interne d'un objet R.

```
str(x) <ENTER>
int [1:4] 1 2 3 4
```

- **summary(X)**:
  - X peut être un **objet** parmi d'autres: de ensembles de données, de variables et de modèles linéaires etc. **summary** fournit des données récapitulatives relatives à l'objet individuel qui lui a été fourni.

```
x <- 1:4 ; summary(x) <ENTER>
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.00    1.75    2.50    2.50    3.25    4.00
```

- min, max, var, mean, i.e., `mean(x)`

Opérations de base sur les variables

Géstion de variables

- length

```
x <- 1:4 ; length(x) <ENTER>
[1] 4
```

- ls

```
x <- 1:4 ; y<-2; ls() <ENTER>
[1] "x" "y"
```

- rm

```
x <- 1:4 ; y<-2; rm(x); ls() <ENTER>
[1] "y"
```

- **length()** retourne la longueur d'un objet
- **ls:** retourne un vecteur de caractères donnant les noms des objets dans l'environnement spécifié
- **rm** est utilisé pour retirer des objets de la mémoire

Vectors

Vector: Un vecteur est le type de structure de données le plus simple de R.
Il s'agit d'une collection ordonnée de données de même type.

```
a <- c(1,2,5.3,6,-2,4) # numeric vector
b <- c("one","two","three") # character vector
c <- c(TRUE,TRUE,TRUE,FALSE,TRUE,FALSE) #logical vector
```

```
u <- c("red", "yellow", "blue") # create a vector "red" "yellow" "blue"
u # returns "red" "yellow" "blue"
u[1] # returns "red" (1st element in u)
v <- 1:5 # create a vector 1 2 3 4 5
v # returns 1 2 3 4 5
sum(v) # returns 15
w <- v * 2 # create a vector 2 4 6 8 10
w # returns 2 4 6 8 10
w[3] # returns 6 (the 3rd element of w)
z <- v + w # sums two vectors element by element
z # returns 3 6 9 12 15
z > 8 # returns FALSE FALSE TRUE TRUE TRUE
z[z > 8] # returns 9 12 15
z[z > 8 | z < 5] # returns 3 9 12 15 ("|" denotes "or")
```

Vectors

```
a <- vector(length=3) # create a logical vector of length 3
a # returns FALSE FALSE FALSE
b <- vector(mode="numeric", 3) # create a numeric vector of length 3
typeof(b) # returns "double"
b[2] <- 3.1 # assign 3.1 to the 2nd element
b # returns 0.0 3.1 0.0
c <- vector(mode="integer", 0) # create an integer vector of length 0
c # returns integer(0)
length(c) # returns 0
length(b) # returns 3
dim(b) # returns NULL (an undefined value)
```

Les vecteurs en R n'ont pas de dimensionalité.

Combiner de vecteurs

Nous pouvons utiliser la function `c()` pour combiner des vecteurs ayant plus d'une valeur, comme dans l'exemple suivant:

```
fruits <- c("Apples", "Oranges", " Blackberries")
vegetables <- c(" Broccoli ", "Spinach", "Tomatoes")
basket_items <- c(fruits, vegetables)
basket_items
[1] "Apples" "Oranges" " Blackberries " " Broccoli " "Spinach"
[6] "Tomatoes"
```

Lists

List: une structure qui contient des objets de types différents

- Définition de list

```
x<-1:3; y<-4; z<- "Text";
newList<-list(x,y,z); newList;
[[1]]
[1] 1 2 3
[[2]]
[1] 4
[[3]]
[1] "Text"
```

str() fournit des détails sur la structure d'une liste

```
str(newlist)
List of 3
 $ : int [1:3] 1 2 3
 $ : num 4
 $ : chr "text"
```

- Accessing items in the list

```
newList[[1]] # on accède à la valeur d'un élément de la liste
[1] 1 2 3
 class(newlist[[1]])
[1] "integer"
> length(newlist[[1]])
[1] 3
```

```
newlist[1] # on accède à un élément de la liste
[[1]]
[1] 1 2 3
class(newlist[1])
[1] "list"
length(newlist[1])
[1] 1
```

Lists

- Différences entre les listes et les vecteurs
  - Une liste peut contenir des objets de types différents, alors que les vecteurs ne contiennent que des objets du même type.
    - i.e., `c(1,2,3, "text")` transforme tous les éléments à “string”
    - `list(1,2,3, "text")` conserve les types d’origine
    - Une liste peut contenir également des listes
- Accèder les éléments d’une liste via `[[pos]]`.
  - `list[pos]` retourne une liste qui contient l’objet de la position [pos].
  - `list[[pos]]` retourne l’objet de la position [pos]!

Data Frames

Le “Data frame” est une liste particulière qui :

- contient des colonnes de vecteurs de même taille (mais de types différents)
- Chaque colonne (vecteur) du « data frame » contient les mesures d'une variable, alors que chaque ligne contient un cas.
- i.e., id, age, height et weight de trois enfants

```
age <- c(1,2,4)
height <- c(75,87,102)
weight <- c(10.0, 12.1, 17.0)
dataframe <- data.frame(age,height,weight)
dataframe
```

id	age	height	weight
1	1	75	10.0
2	2	87	12.1
3	3	102	17.0

Data Frames

- Accéder à des éléments en utilisant $

```
age<-c(1,2,4)
height<-c(75,87,102)
weight<-c(10.0, 12.1, 17.0)
dataframe<-data.frame(age,height,weight)
dataframe;
```

```
  age height weight
1   1     75   10.0
2   2     87   12.1
3   4    102   17.0
```

```
dataframe$height
[1]  75  87 102
dataframe$weight[2]
[1] 12.1
dataframe$weight[3]<-18;
dataframe$weight[3]
[1] 18.0
```

- `sales <- read.csv("c:/data/yearly_sales.csv")`
- `setwd("c:/data/") # préciser le "working directory"`
- `sales <- read.csv("yearly_sales.csv")`
- `is.data.frame(sales) # returns TRUE`
- `write.table(),write.csv(),write.csv2() # exporter un "data frame" dans un fichier .`

```
# ajouter une colonne contenant la valeur moyenne de chaque commande
sales$per_order <- sales$sales_total/sales$num_of_orders
# exporter les données en format délimité par des tabulations sans les noms des lignes
write.table(sales,"sales_modified.txt", sep="\t", row.names=FALSE
```

TABLE 3-1 *Import Function Defaults*

Function	Headers	Separator	Decimal Point
read.table()	FALSE	""	"."
read.csv()	TRUE	","	"."
read.csv2()	TRUE	";"	","
read.delim()	TRUE	"\t"	"."
read.delim2()	TRUE	"\t"	","

```
length(sales$num_of_orders) # returns 10000 (number of customers)
is.vector(sales$cust_id) # returns TRUE
is.vector(sales$sales_total) # returns TRUE
is.vector(sales$num_of_orders) # returns TRUE
is.vector(sales$gender) # returns FALSE
is.factor(sales$gender) # returns TRUE
```

Manipuler un Data Frame

```
str(sales) # display structure of the data frame object
'data.frame': 10000 obs. of 4 variables:
$ cust_id : int 100001 100002 100003 100004 100005 100006 ...
$ sales_total : num 800.6 217.5 74.6 498.6 723.1 ...
$ num_of_orders: int 3 3 2 3 4 2 2 2 2 2 ...
$ gender : Factor w/ 2 levels "F","M": 1 1 2 2 1 1 2 2 1 2 ...
# extract the fourth column of the sales data frame
sales[,4]
# extract the gender column of the sales data frame
sales$gender
# retrieve the first two rows of the data frame
sales[1:2,]
# retrieve the first, third, and fourth columns
sales[,c(1,3,4)]
# retrieve both the cust_id and the sales_total columns
sales[,c("cust_id", "sales_total")]
# retrieve all the records whose gender is female
sales[sales$gender=="F",]
```

```
class(sales)
"data.frame"
typeof(sales)
"list"
```

Arrays

Création des Arrays :

- array() : création de arrays multidimensionelles

```
# the dimensions are 3 regions, 4 quarters,
and 2 years
quarterly_sales <- array(0, dim=c(3,4,2))
quarterly_sales[2,1,1] <- 158000
quarterly_sales
```

```
, , 1
[,1] [,2] [,3] [,4]
[1,] 0 0 0 0
[2,] 158000 0 0 0
[3,] 0 0 0 0
, , 2
[,1] [,2] [,3] [,4]
[1,] 0 0 0 0
[2,] 0 0 0 0
[3,] 0 0 0 0
```

Matrices

Creéation des Matrices :

- cbind : combine les vecteurs en tant que colonnes
- rbind : combine les vecteurs en tant que lignes
- matrix : il faut preciser le nombre des col. - lignes

```
install.packages('matrixcalc')
library(matrixcalc)
M <- matrix(c(1,3,3,5,0,4,3,3,3),nrow = 3,ncol = 3)
# build a 3x3 matrix
M %*% matrix.inverse(M)# multiply M by inverse(M)
     [,1] [,2] [,3]
[1,]    1    0    0
[2,]    0    1    0
[3,]    0    0    1
```

matrixcalc

https://cran.r-project.org/web/packages/matrixcalc/matrixcalc.pdf

https://cran.r-project.org/web/packages/matrixcalc/index.html

rbind (row-bind):

```
x<-1:3; y<-4:6; z<-rbind(x,y);z
  [,1] [,2] [,3]
x    1    2    3
y    4    5    6
```

cbind (column-bind):

```
x<-1:3; y<-4:6; z<-cbind(x,y);z
     x y
[1,] 1 4
[2,] 2 5
[3,] 3 6
```

Matrices

- matrix: create a matrix from a vector

```
x<-1:8; y<-matrix(x,nrow=2); y
     [,1] [,2] [,3] [,4]
[1,]    1    3    5    7
[2,]    2    4    6    8
```

Si seulement le “nrow” ou le “ncol” est précisé les dimensions de la matrice sont inférées à partir des données.

```
x<-1:8; y<-matrix(x,nrow=2, byrow=T); y
     [,1] [,2] [,3] [,4]
[1,]    1    2    3    4
[2,]    5    6    7    8
```

byrow : si F (faux, par défaut) la matrix est remplie par colonne, sinon par ligne

- What is the output?

```
matrix(c(1,2,3,4,5,6),nr=2)
x<-1:9; y<-matrix(x,nr=2)
```

Si les éléments pour construire une matrice sont insuffisantes en nombre « matrix » va recycler les données.

Basic operations on matrices

- Accéder aux éléments d'une matrice

  [row,column]

```
x<-1:8; y<-matrix(x,nr=2); y <ENTER>
     [,1] [,2] [,3] [,4]
[1,]    1    3    5    7
[2,]    2    4    6    8

y[1,2] <ENTER>
[1] 3
```

- dim : donne les dimensions d'une matrice

```
dim(y) <ENTER>
[1] 2 4
```

2 rows, 4 cols

Basic operations on matrices

- summary (pour chaque colonne)

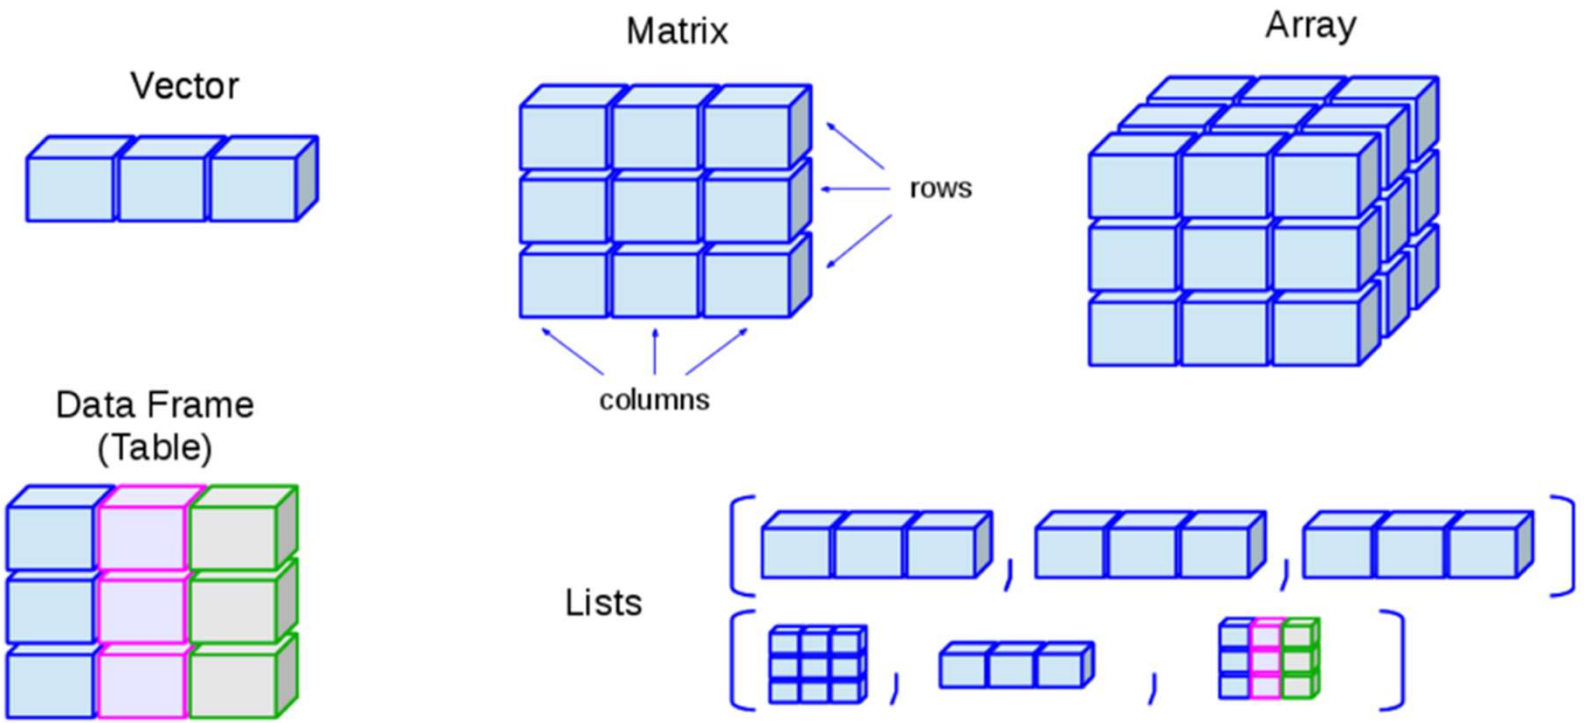
```
x<-1:8; y<-matrix(x,nr=2); y; <ENTER>
     [,1] [,2] [,3] [,4]
[1,]    1    3    5    7
[2,]    2    4    6    8
```

Les colonnes sont considérées comme des variables.

```
summary(y) <ENTER>
       V1              V2              V3              V4
 Min.   :1.00   Min.   :3.00   Min.   :5.00   Min.   :7.00
 1st Qu.:1.25   1st Qu.:3.25   1st Qu.:5.25   1st Qu.:7.25
 Median :1.50   Median :3.50   Median :5.50   Median :7.50
 Mean   :1.50   Mean   :3.50   Mean   :5.50   Mean   :7.50
 3rd Qu.:1.75   3rd Qu.:3.75   3rd Qu.:5.75   3rd Qu.:7.75
 Max.   :2.00   Max.   :4.00   Max.   :6.00   Max.   :8.00
```

Les lignes sont les instances/ observations

Data Structure types in R - overview



Source:http://venus.ifca.unican.es/Rintro/dataStruct.html

Functions

- Création de nouvelles fonctions en ligne (inline)

```
cube <- function (x) x^3 ; cube(2)<ENTER>
[1] 8
```

- De fonctions plus grandes

```
cubePlus1 <- function (x)
{
    tmpCube <- cube(x);
    tmpCube+1;
};
cubePlus1(2)
[1] 9
```

- Modification des fonctions

```
fix(cubePlus1)
```

Data loading

- R intègre différents jeux de données
- `data() # présente les jeux de données intègres`
- Data loading

```
data(data file)
data(iris)
ls()# présente les variables de l'environnement
[1] "iris"
```

- Description du jeu de données

```
help(data file)
help("iris")
```

Data loading

- Editing and printing

```
edit(iris) # ouvres le éditeur de texte pour modifier l'objet spécifié

head(iris) # donne les prémières lignes de l’objet spécifié
Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5          1.4         0.2  setosa
2          4.9         3.0          1.4         0.2  setosa
3          4.7         3.2          1.3         0.2  setosa
4          4.6         3.1          1.5         0.2  setosa
5          5.0         3.6          1.4         0.2  setosa
6          5.4         3.9          1.7         0.4  setosa
```

Data loading

- Editing and printing

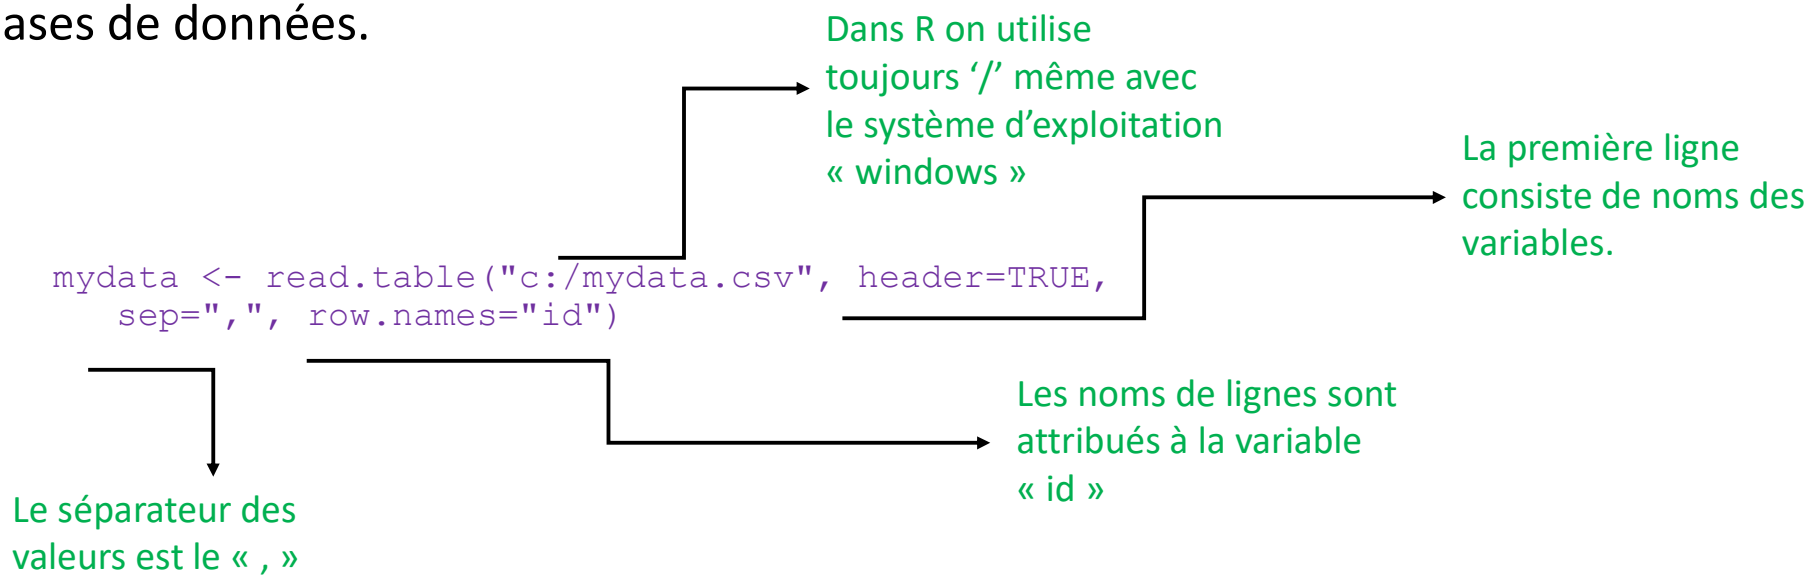
Présente la structure interne d'un objet.

```
str(iris)
```

```
'data.frame':	150 obs. of  5 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4...
 $ Species     : Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1...
```

Importing data I

- Importer des données dans R est assez simple.
- R offre des options pour importer de nombreux types de fichiers, des CSV aux bases de données.



Importing data II

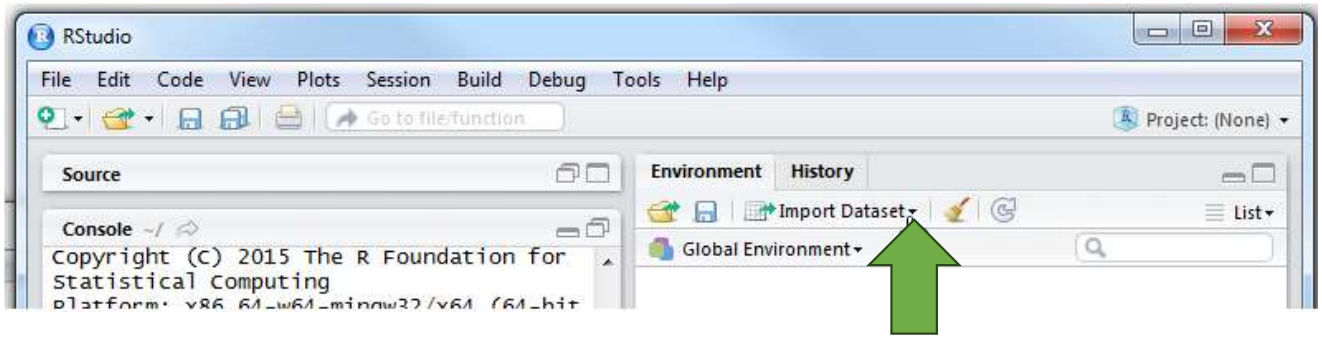
- L'argument `stringsAsFactors` indique si les *strings* d'un *data frame* doivent être traitées comme des variables factorielles (***factors***) ou comme de simples *strings*.
- `mydata <- read.table("c:/mydata.csv", stringsAsFactors = TRUE|FALSE )`

- Les facteurs (***factors)*** sont utilisés pour représenter les données catégoriques (et ordinales) et sont stockés sous forme d'entiers. Des étiquettes sont associées à ces nombres entiers uniques.
- `volume <- factor(c("low", "medium", "medium", "high", "high"))`

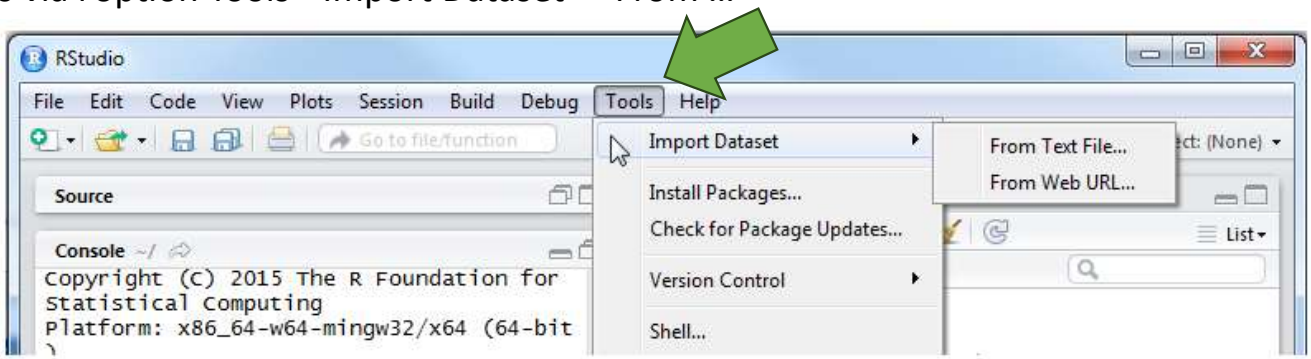
- Nous définissons l'ordre en spécifiant les niveaux et en fixant l'argument **`ordered`** à **`TRUE`**.
- `volume <- factor(volume, levels = c("low", "medium", "high"), ordered = TRUE)`

Importer de données via les éméments de Menu de R Studio

Importer de données via l'option "**Import Dataset**":



Importer de données via l'option Tools->Import Dataset -> From …



Aide et ressources en ligne

```
help()
help.start()
help(str)
demo()
```

Ressources enligne

Tutoriels d'introduction à R

- http://cran.r-project.org/doc/manuals/R-intro.pdf
- https://r4ds.had.co.nz/index.html
- https://www.guru99.com/r-tutorial.html
- https://intellipaat.com/blog/r-for-data-science-tutorial/

Visualisation de données

D’une variable au cas multidimensionnel

Contenu de ce chapitre

- Méthodes pour un et deux attributs
  - Diagramme à barres et histogramme
  - Boxplot
  - Scatter plot et diagramme de densité (density plot(
- Méthodes pour de données à plus haute dimension
  - Analyse en composantes principales (ACP)
  - Échelle multidimensionnelle (Multidimensional Scaling MDS)
  - Coordonnées parallèles
  - Graphique radar et graphique en étoile
  - Graphique ensoleillé (Sunburst Chart)
  - Analyse de corrélation

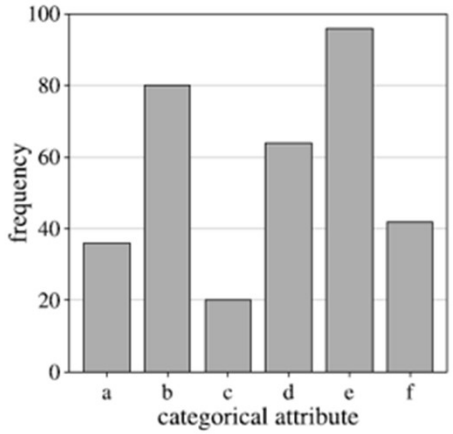
Descripteurs statistiques

Statistical measures can be used to describe a dataset:

- Plage de valeurs (Range)
- Valeurs min/max
- Moyenne (Mean) $\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$
- Variance $\sigma^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\mu)^2$
- Écart type(Standard deviation) $\sigma = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\mu)^2}$
- Médiane (le chiffre du milieu ; on le trouve en ordonnant tous les points de données et en choisissant celui qui se trouve au milieu - ou, s'il y a deux chiffres du milieu, en prenant la moyenne de ces deux chiffres)
- Mode (valeur la plus fréquente)
- Percentiles (Quartiles)
- Nombre de valeurs manquantes
- ...

Méthodes de visualisation pour une variable

Diagramme à barres (Bar chart)



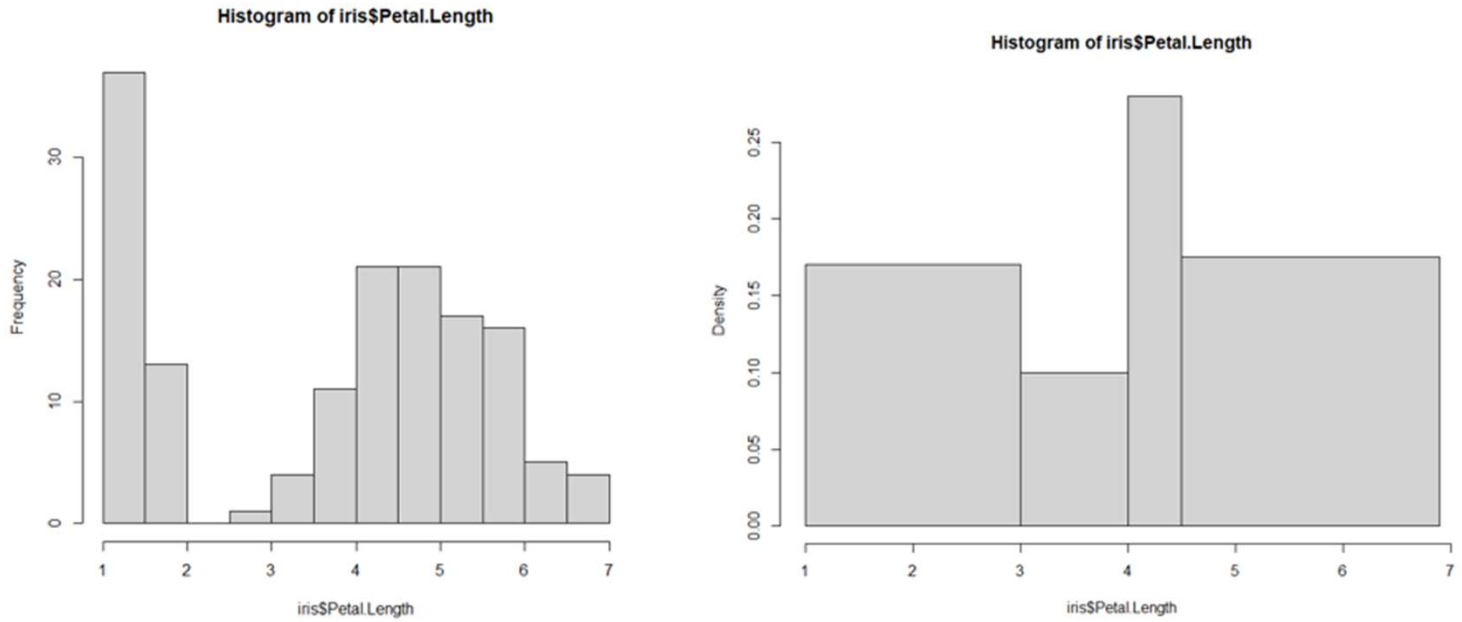
- Un diagramme à barres est un moyen simple de représenter les fréquences des valeurs d'un attribut nominal (categorical attribut).

Barchart – R code

- Tracer un graphique à barres

```
y <- c(35,80,20,62,90,40) <ENTER>
x <- c('a', 'b', 'c', 'd', 'e', 'f') <ENTER>
barplot(y, names.arg=x, xlab="categorical
  attribute", ylab="frequency") <ENTER>
```

Histogramme



- Un histogramme montre la distribution de fréquence d'un attribut numérique.
- La plage de l'attribut numérique est divisée en un nombre fixe d'intervalles (bacs, bins), généralement de longueur égale.
- Pour chaque intervalle, la fréquence (absolue) des valeurs qui s'y trouvent est indiquée par la hauteur d'une barre.

Histogram – R code

- Plot a histogram

```
data(iris)
```

```
head(iris)
```

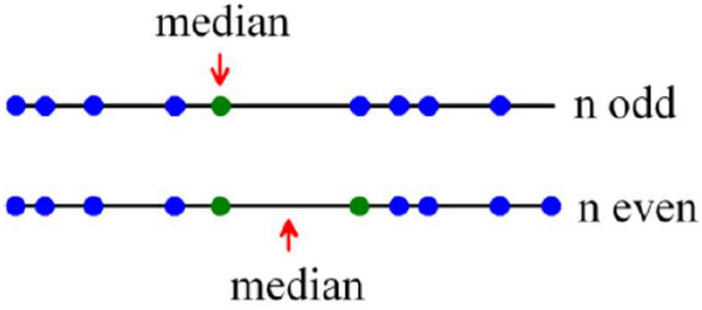
```
 Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1 5.1          3.5         1.4          0.2         setosa
2 4.9          3.0         1.4          0.2         setosa
3 4.7          3.2         1.3          0.2         setosa
4 4.6          3.1         1.5          0.2         setosa
5 5.0          3.6         1.4          0.2         setosa
6 5.4          3.9         1.7          0.4         setosa
```

```
hist(iris$Petal.Length) <ENTER>
```

If we want the boundaries for the bins at 1.0, 3.0, 4.0, 4.5, 6.9, then we would use

```
hist(iris$Petal.Length, breaks=c(1.0, 3.0, 4.0, 4.5, 6.9)) <ENTER>
```

Médiane, quantiles, quartiles, intervalles interquartiles



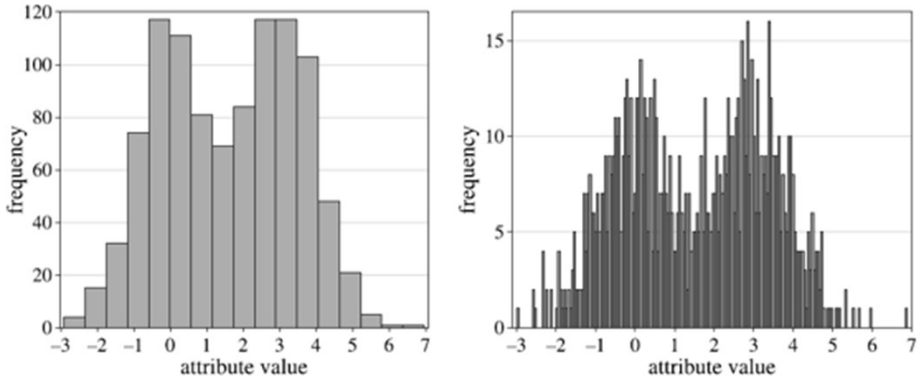
Soit $x = (x_{(1)}, \ldots, x_{(n)})$ un jeu de donées ordoné, i.e.

$\forall i, j : (j > i) \rightarrow (x_{(j)} \geq x_{(i)})$. La médiane est définie

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})} & \text{if } n \text{ is odd,} \\ \frac{1}{2}\left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}\right) & \text{if } n \text{ is even,} \end{cases}$$

- **Médiane** : La valeur du milieu (pour les valeurs triées par ordre croissant)
- **Quantile q% (0 < q < 100)** : La valeur pour laquelle q% des valeurs sont plus petites et 100-q% sont plus grandes par rapport à elle**.** La médiane est le quantile 50%.
- **Quartiles :** 25%-quantile (1er quartile), médiane (2ème quartile), 75%-quantile (3ème quartile)
- **Intervalle interquartile (IQR) :** 3e quartile - 1er quartile

Comment choisir le nombre des bins



- **Quel est le meilleur choix pour le nombre k de bins dans l'histogramme ?**
- Règle de Sturge's, (bins de même taile) $k = \lceil log_2(n) + 1 \rceil$
- Si l'on suppose des bins de taille égale de longueur h

$k = \left\lceil \frac{max_i\{x_i\} - min\ \{x_i\}}{h} \right\rceil$ des choix résonables pour l'h sont : $h = \frac{3.5 \cdot s}{n^{\frac{1}{3}}}$ ou $h = \frac{2 \cdot IQR(x)}{n^{\frac{1}{3}}}$

Où s est **l'écart-type** de la caractéristique d'entrée x, x_i la valeur de la i-ème instance, et n le nombre d'instances dans le jeu de données.

- **L'asymétrie (Skeweness)** est le troisième moment normalisé de X, c'est-à-dire :

$$\tilde{\mu}_3 = E\left[\left(\frac{X-\mu}{s}\right)^3\right] = \frac{E[(X-\mu)^3]}{E[s^3]} = \frac{\mu_3}{s^3} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i-\overline{x}}{s}\right)^3$$

- La skeweness mesure l'asymétrie de la distribution de probabilité de X
- **L'aplatissement** est le 4ème moment standardisé de X, c'est-à-dire :

$$Kurt[X] = E\left[\left(\frac{X-\mu}{s}\right)^4\right] = \frac{E[(X-\mu)^4]}{(E[s^2])^2} = \frac{\mu_4}{s^4} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i-\overline{x}}{s}\right)^4$$

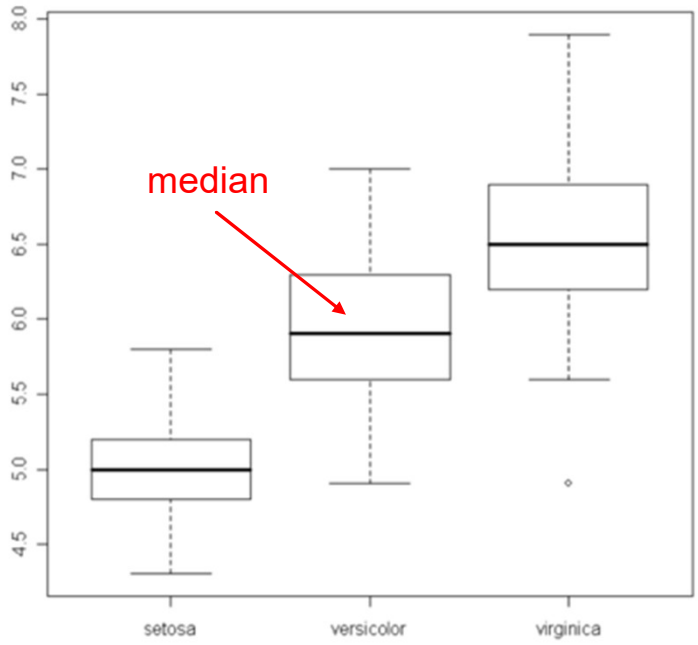
- **Le kurtosis** mesure la déviation du pic d'une distribution gaussienne : il mesure la dispersion due aux valeurs extrêmes.
- **Le kurtosis d'une distribution normale univariée est de 3!**

Boxplots

– Les box plots sont un moyen très compact de visualiser et de résumer les principales caractéristiques d'un attribut numérique, par le biais de la **médiane**, de **l'IQR (interquartile range)** et **d'éventuelles valeurs extrêmes**.

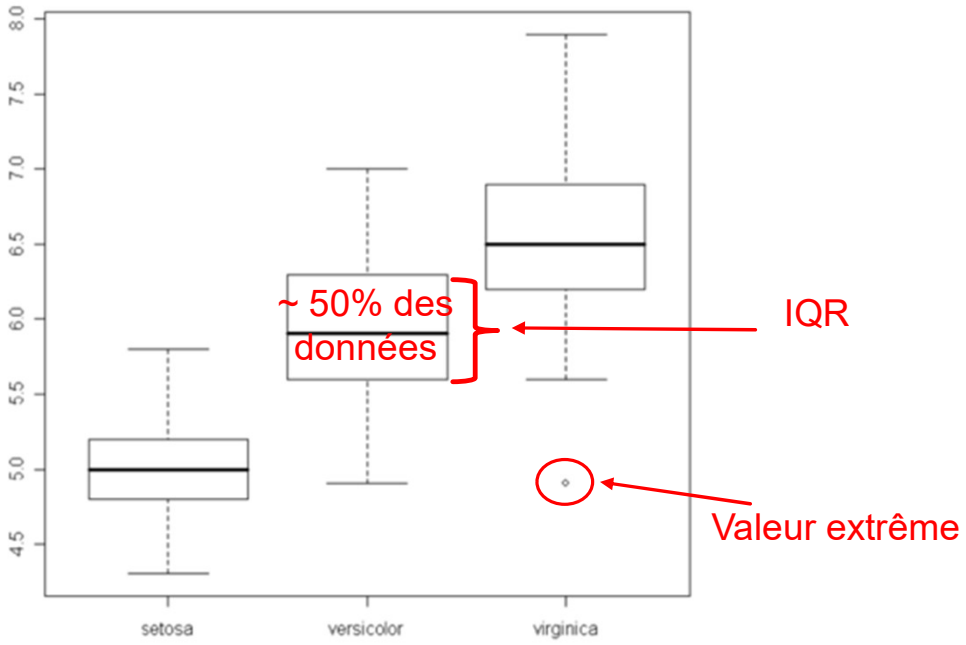
Tracer un box plot

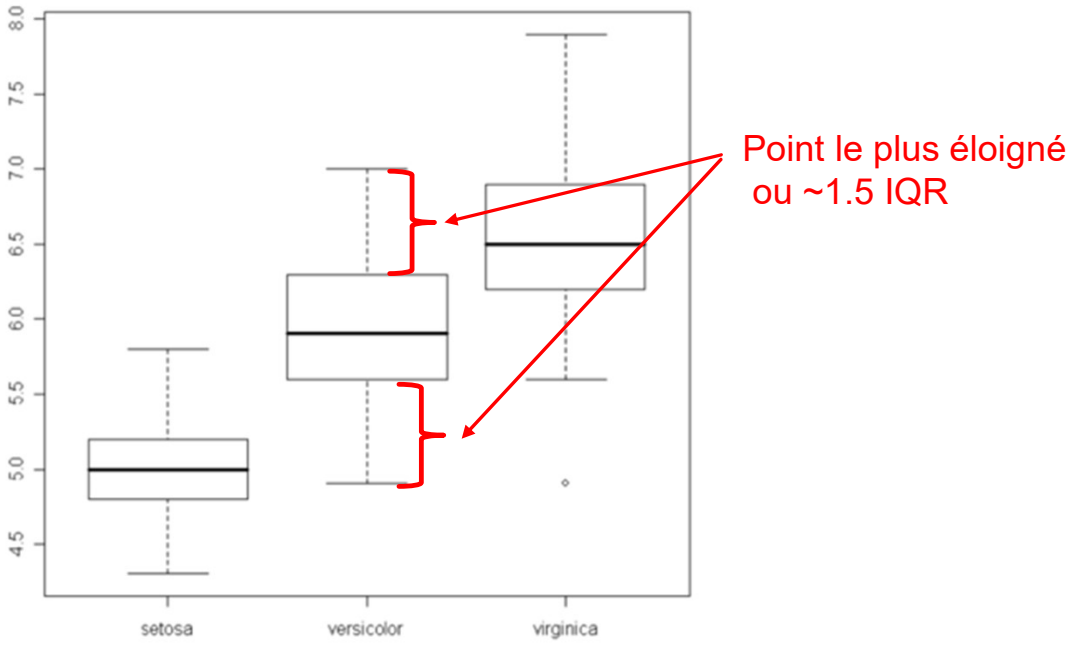
```
boxplot(iris$Sepal.Length~iris$Species)
```



Boxplots

– Les box plots sont un moyen très compact de visualiser et de résumer les principales caractéristiques d'un attribut numérique, par le biais de la **médiane**, de **l'IQR (interquartile range)** et **d'éventuelles valeurs extrêmes**.

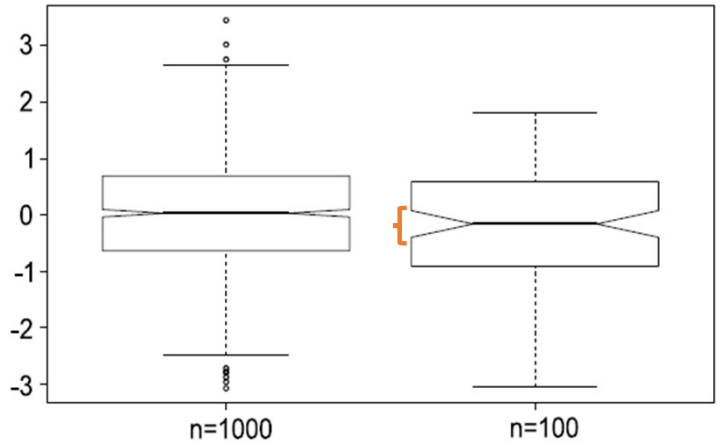




Boxplots à partir de distributions normales

- La même distribution peut donner lieu à des boxplots différents
- Cela dépend de la taille de l'échantillon n
- Deux échantillons d'une distribution normale de taille différente n
- Pour le petit échantillon:
  - Les moustaches ont des longueurs différentes, même s'il s'agit de la même distribution symétrique.
  - Pas des valeurs extrêmes.

L'encoche affiche un intervalle de confiance autour de la médiane
basé souvent sur la médiane +/- 1,58*IQR/sqrt(n).
Les encoches sont utilisées pour comparer les groupes ; si les encoches de deux boîtes ne se superposent pas, cela c'est une indication que les médianes sont différentes.



Boxplots de différents échantillons d'une distribution normale standard

Boxplot using a random sample from a standard normal distribution – R code

- Tracer des diagrammes en boîte à encoches en utilisant des échantillons aléatoires de la distribution normale standard.

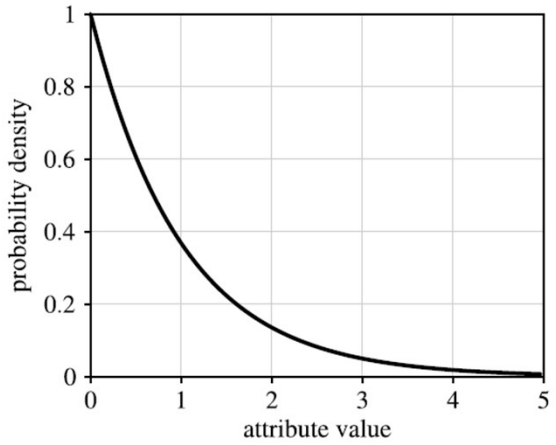
```
norm100 <- rnorm(100, 0, 1) <ENTER>
norm1000 <- rnorm(1000, 0, 1) <ENTER>
boxplot(norm100, norm1000, notch = TRUE, names=c("n=100",
  "n=1000")) <ENTER>
```

Note: *rnorm*(*n*, *mean*, *sd*) génère une distribution aléatoire avec:

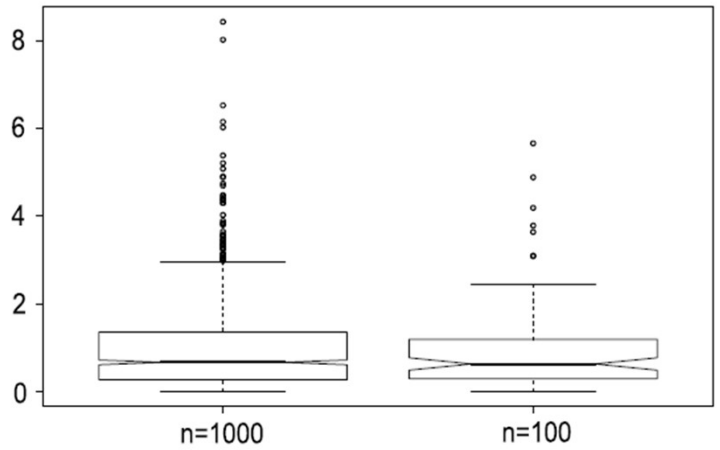
- *n*: Le nombre d'observations (taille de l'échantillon)
- *mean*: Il s'agit de la valeur moyenne des données de l'échantillon (par défaut = 0)
- *sd*: il s'agit de l'écart-type (par défaut = 1)

Boxplot d'une distribution asymétrique

– Boxplots de différents échantillons de la distribution exponentielle avec $\lambda = 1$



distribution exponentielle avec $\lambda = 1$



Boxplots de différents échantillons de la distribution exponentielle avec $\lambda = 1$

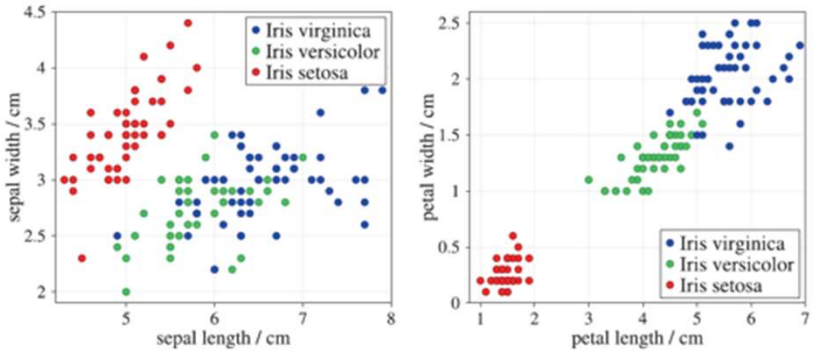
Tracer des diagrammes en boîte à encoches en utilisant des échantillons aléatoires de la distribution exponentielle (λ=1)

```
exp1000 = rexp(n=1000, rate=1) <ENTER>
exp100 = rexp(n=100, rate=1) <ENTER>
boxplot(exp1000, exp100, notch = TRUE, names=c("n=1000", "n=100"))
```

Méthodes de visualisation pour deux attributs

Nuage de points - Scatter Plot

La longueur et la largeur des pétales permettent une meilleure séparation des classes que la longueur et la largeur des sépales.



Nuage de point du jeu des données d'Iris pour la longueur du sépale en fonction de la largeur du sépale (à gauche) et pour la longueur du pétale en fonction de la largeur du pétale (à droite). Toutes les quantités sont mesurées en centimètres

- Dans les nuages de points, deux attributs sont représentés l'un par rapport à l'autre.
- Peut être enrichi par des caractéristiques supplémentaires (couleur, forme, taille)
- Convient pour un petit nombre de points ; ne convient pas aux grands ensembles de données
- Les points peuvent se cacher les uns les autres -> ajouter de la gigue (une petite valeur aléatoire à chaque point)

Scatterplot – R code

Plot scatterplots

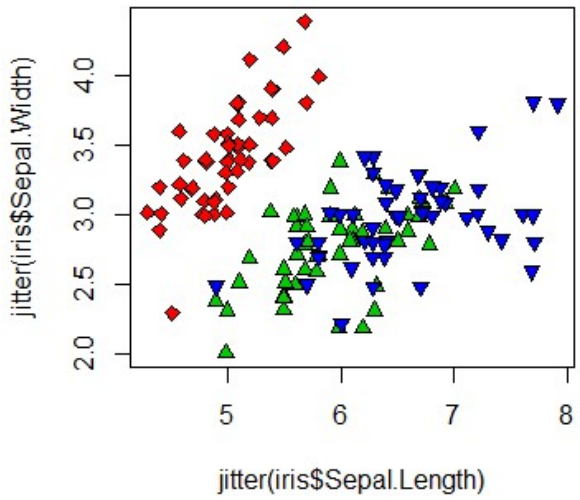
la forme du point

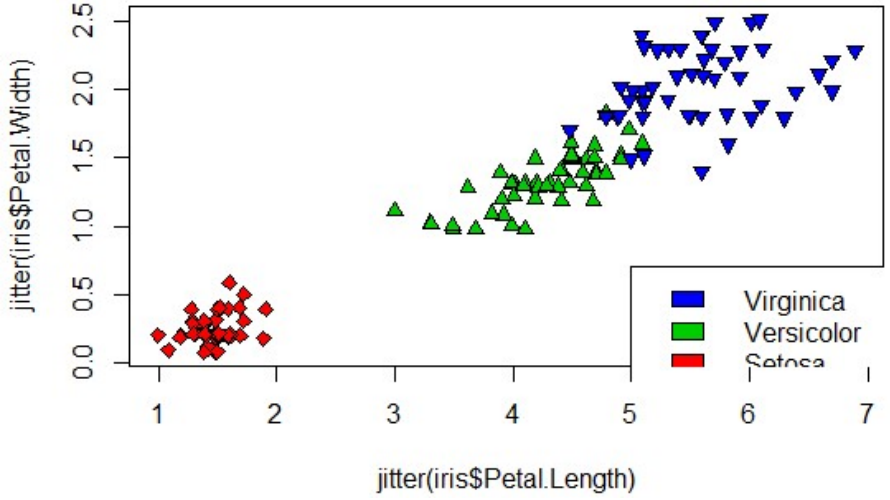
```
plot(jitter(iris$Sepal.Length), jitter(iris$Sepal.Width),
 pch=c(23, 24, 25)[unclass(iris$Species)],
 bg=c("red", "green3", "blue")[unclass(iris$Species)])
```

la couleur du point

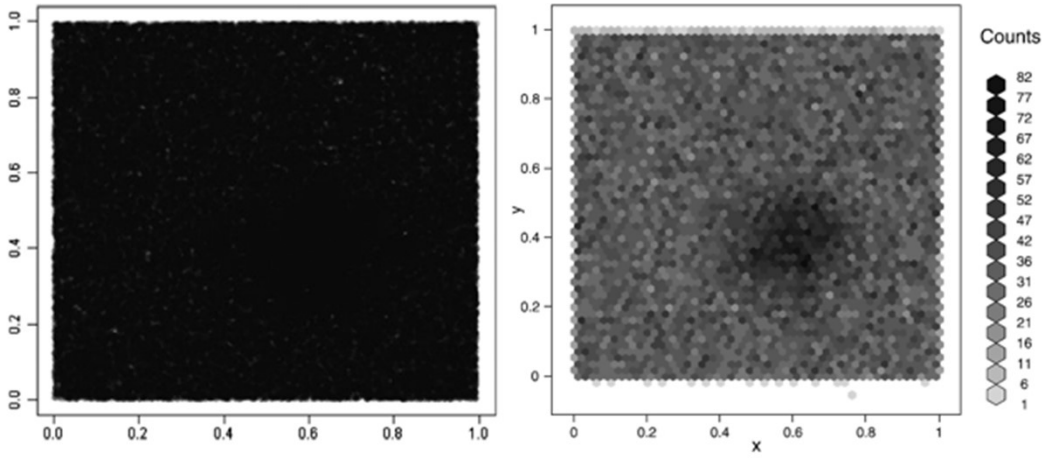
```
plot(jitter(iris$Petal.Length), jitter(iris$Petal.Width),
  pch=c(23, 24, 25)[unclass(iris$Species)],
  bg=c("red", "green3", "blue")[unclass(iris$Species)])
```

```
legend(5, 0.7, legend=c("Virginica", "Versicolor", "Setosa"), fill=c("blue", "green3", "red"))
```





Graphique de densité



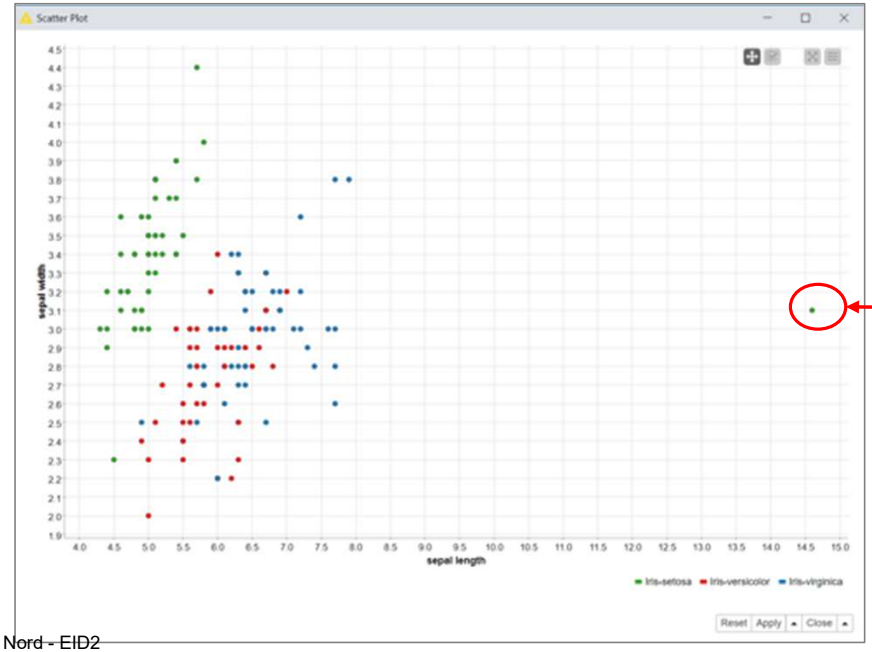
Nuage de points (à gauche) et graphique basé sur le regroupement (binning) hexagonal (à droite) pour un ensemble de données avec n = 100.000 instances.

- Le scatter plot n'est pas adéquat pour de grands jeux de données
- Alternatives:
  - Graphique de densité, utilisant des points semi-transparents : plus il y a de points au même endroit, moins ils sont transparents.
  - Regrouper des points en rectangles ou en hexagones et utiliser d'échelles de couleur de chaleur
  - Pour éviter les superpositions (comme dans le nuage de points ci-contre), on divise la zone de représentation en une multitude de petits fragments et représente le nombre de points dans ce fragment.
  - Il existe plusieurs types de diagrammes de densité 2d. Chacun possède sa propre fonction **ggplot2**.

Nuage de points pour détecter les valeurs aberrantes

– Les nuages de points peuvent être utilisés pour détecter les valeurs aberrantes.

- **Il n'y a aucune garantie que le nuage de points ou toute autre technique de visualisation montre automatiquement tous les schémas intéressants ou divergents de l'ensemble des données.**
- Un nuage de points sans valeurs extrêmes ne signifie pas qu'il n'y a pas de valeurs extrêmes dans l'ensemble des données.
- Cela signifie seulement qu'il n'y a pas de valeurs extrêmes en ce qui concerne la combinaison des caractéristiques affichées dans le diagramme de dispersion.



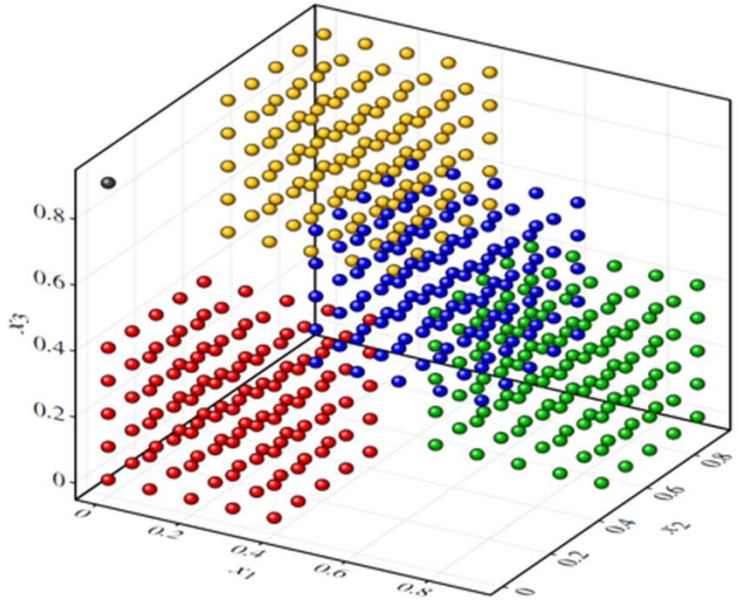
outlier

- La visualisation peut servir de test
- **Good News**
  - La visualisation révèle des schémas ou des exceptions => il y a quelque chose dans le jeu de données
- **Bad News**
  - La visualisation n'indique rien de spécifique => il peut toujours y avoir quelque chose dans l'ensemble de données **même si nous ne le voyons pas**.
  - Par exemple, si nous ne voyons pas de valeurs extrêmes pour cette combinaison de caractéristiques, cela ne signifie pas que les valeurs extrêmes n'existent pas dans l'ensemble de données.

Méthodes de visualisation pour les données de haute dimension

Visualisation de données tridimensionnelles : Tracé 3D

Les techniques 3D peuvent être utilisées pour incorporer trois axes (attributs) (**3D scatter plots)**



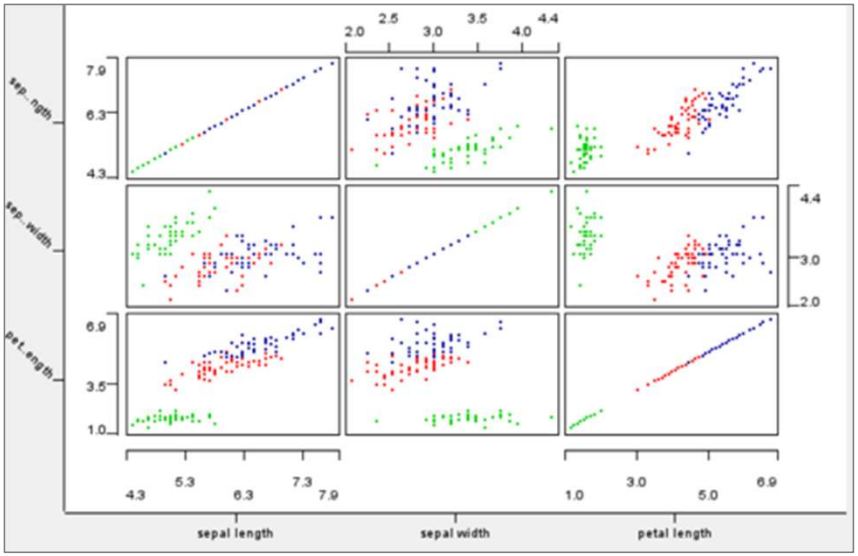
3D scatter plot

Exemple

- Un ensemble de données réparties sur un **cube sous forme d'échiquier**.
- Les couleurs sont uniquement destinées à rendre les différents cubes plus facilement discernables. Elles n'indiquent pas de classes.
- Notez la valeur extrême dans le coin supérieur gauche

Visualisation de données tridimensionnelles : Les matrices de dispersion (Scatter Matrices)

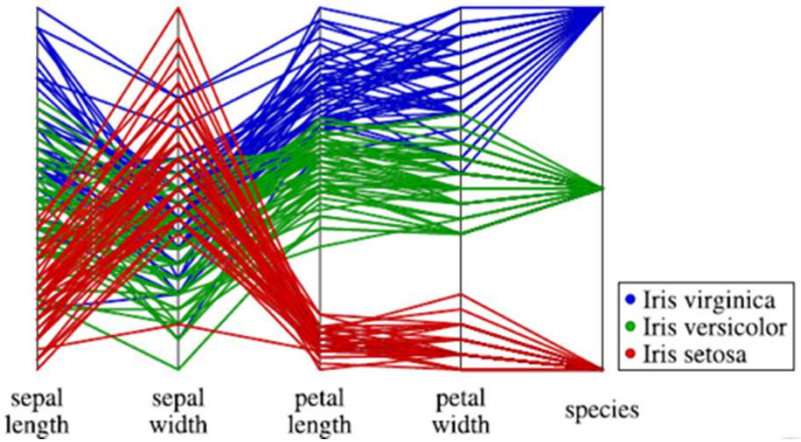
- Une matrice de nuage de points $m \times m$ où m est le nombre d'attributs (dimensionnalité des données).
- Pour m attributs, il existe $P(m,2)=m(m\text{-}1)$ diagrammes de dispersion possibles.
- Par exemple, pour 50 attributs, il y a 2450 nuages de points !



Scatter matrix

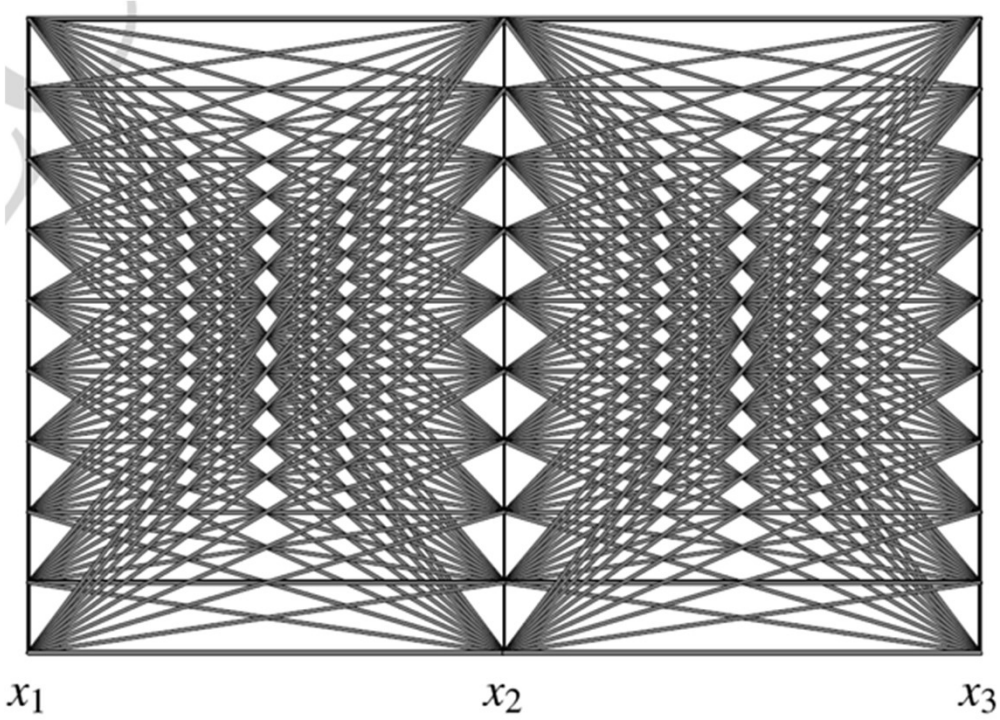
Graphique des coordonnées parallèles

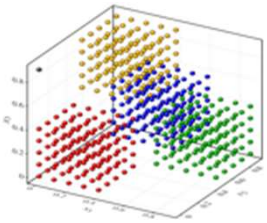
- Les coordonnées parallèles permettent de **dessiner les axes de coordonnées de chaque attribut parallèlement les uns aux autres**, de sorte qu'il n'y a pas de limite au nombre d'axes à afficher.
- Pour chaque objet de données, une polyligne est tracée pour relier les valeurs des attributs sur les axes correspondants.
- Conserve les attributs d'origine
- Adéquent pour un Nombre limité d'instances
- Est-il facile de détecter les corrélations entre les caractéristiques ?



Parallel coordinates plot for the Iris data set

Graphique en coordonnées parallèles : "Cube Data"

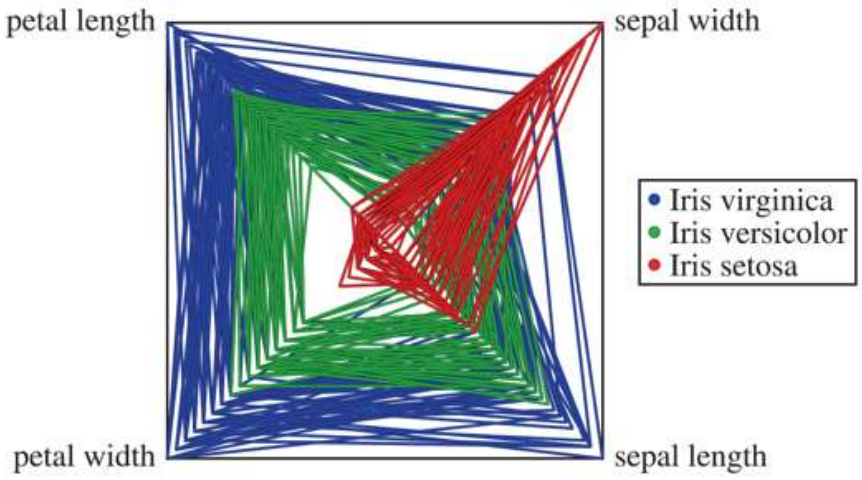




Parallel coordinates plot for the Cube data

Graphe radar - Radar Plot

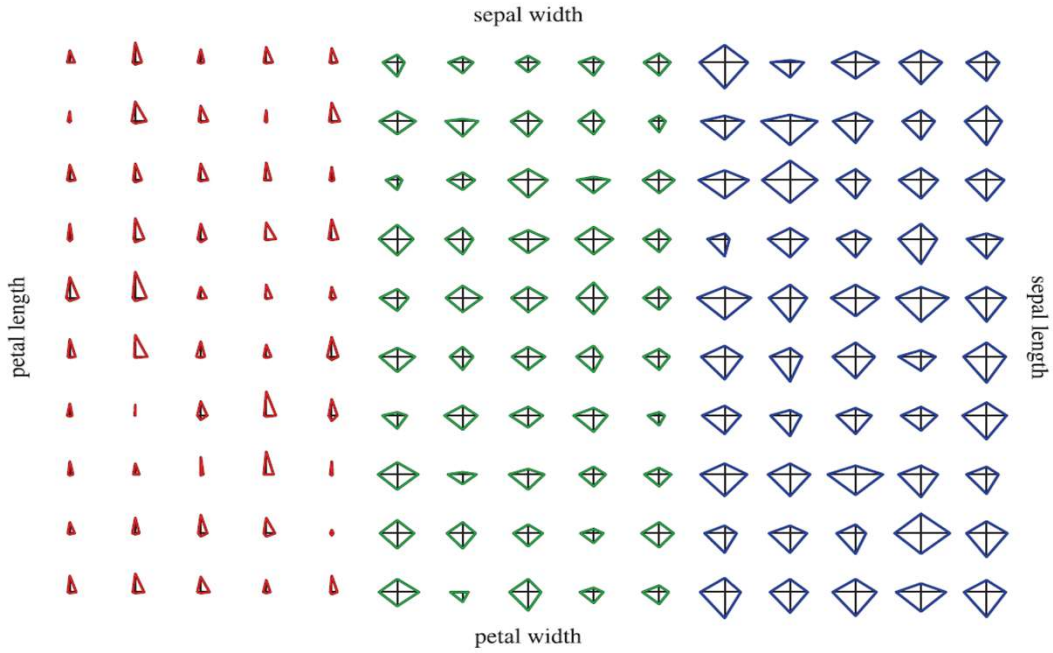
- Idée similaire à celle de Plot de coordonnées parallèles
- Les axes sont dessinés en étoile et se croisent en un p oint.
- Également appelées "parcelles d'araignée".
- Convient aux petits ensembles de données



Radar plot for the Iris data set

Plots d'étoiles - Star Plots

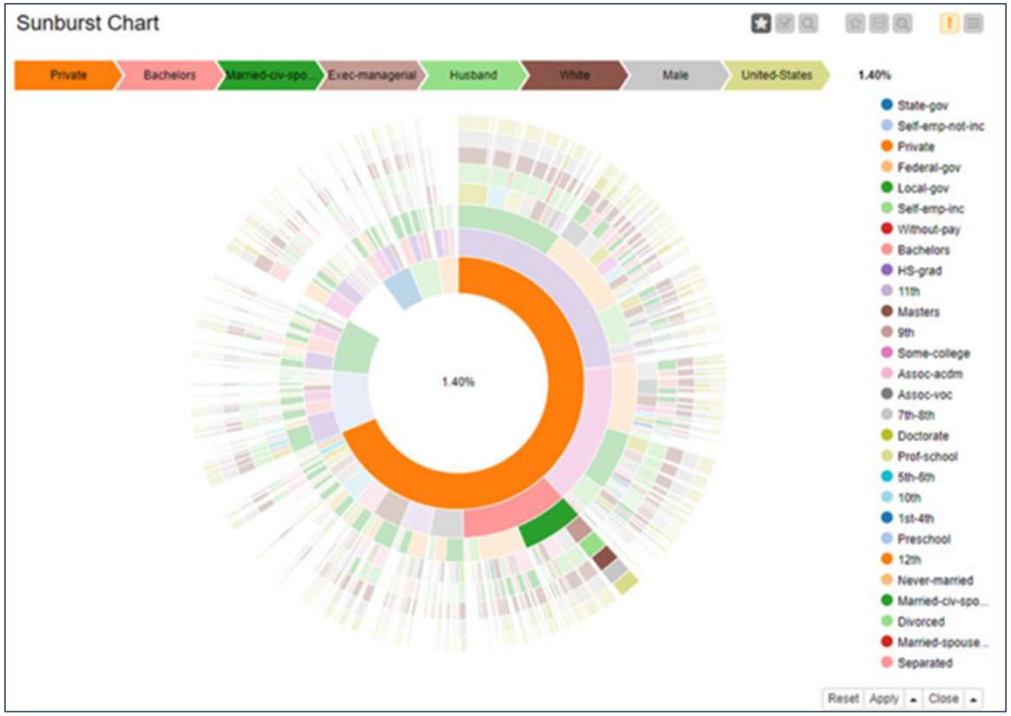
– Dans un diagramme en étoile, chaque objet est dessiné séparément dans un diagramme en radar.



Star plot for the Iris data set

Sunburst Chart

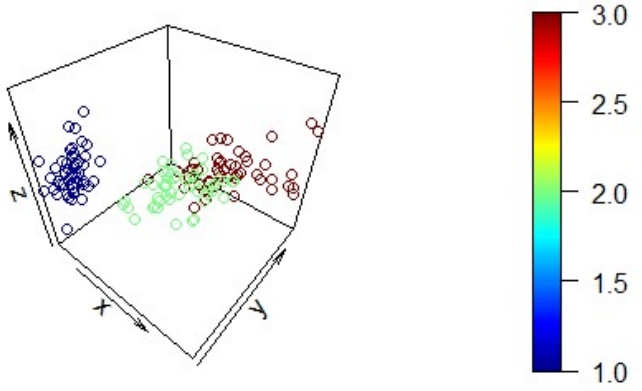
- Afficher des données nominales hiérarchiques multidimensionnelles dans une présentation radiale
- Une section ⇔ un attribut
- Attribut racine au centre, les sections externes sont des attributs situés plus loin dans la hiérarchie.
- La surface d'une section représente la valeur cumulée de toutes les sections descendantes.



Visualisation de données de dimensions supérieures dans R

Plot a 3D graph in R using Iris

```
install.packages("plot3D")
library("plot3D")
x <-  iris$Sepal.Length
y <-  iris$Petal.Length
z <-  iris$Sepal.Width
scatter3D(x, y, z, colvar = unclass(iris$Species))
```



Convertit une variable nominale (factor) en une variable numérique.

Comment transformer un ensemble de données de haute dimension en deux ou trois dimensions ??

- Préserver autant que possible la "structure" des données d'origine
- Définir une mesure permettant d'évaluer dans quelle mesure la structure originale de l'ensemble de données à haute dimension est préservée après la transformation.
- Trouver la transformation qui donne la meilleure valeur pour la mesure donnée

Analyse de corrélation

Similarité de comportement

Comment mesurer la similitude de comportement de deux attributs ?

- Coefficient de corrélation de Pearson
- Coefficient de corrélation de rang de Spearman (rho de Spearman)

Pearson‘s correlation coefficient

- **Le coefficient de corrélation de Pearson** est une mesure de la relation linéaire **entre deux attributs numériques** X et Y et est défini comme suit **:**

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})\ (y_i - \bar{y})}{(n-1)\ s_x s_y}$$

- où $\bar{x}$ et $\bar{y}$ sont les valeurs moyennes (de l'échantillon) des attributs X et Y, respectivement, et s_x et s_y sont les écarts types (de l'échantillon) correspondants.
- $-1 \leq r_{xy} \leq 1$
- Plus la valeur absolue du coefficient de corrélation de Pearson est élevée, plus la relation linéaire entre les deux attributs est forte. Pour $|r_{xy}| = 1$, les valeurs de X et Y se situent exactement sur une ligne.
- Une corrélation positive (négative) indique une relation linéaire (une ligne) avec une inclinaison positive (négative).

Spearman‘s rank correlation coefficient (Spearman‘s rho)

- **Le coefficient de corrélation de rang de Spearman (rho de Spearman)** est défini comme suit :

$$\rho = 1 - 6 \frac{\sum_{i=1}^{n} \left(r(x_i) - r(y_i)\right)^2}{n\,(n^2 - 1)}$$

où $r(x_i)$ est le rang de la valeur x_i lorsque l'on ordonne la liste $(x_1, x_2, \ldots, x_n)$ par ordre croissant. $r(y_i)$ est défini de façon analogue.

- Le corrélation Spearman suggère une corrélation monotonique!
- Lorsque les classements des valeurs x et y sont exactement dans le même ordre, le rho de Spearman donnera la valeur 1.
- S'ils sont dans l'ordre inverse, le rho de Spearman donnera la valeur -1.

