

Statistique Exploratoire Multidimensionnelle

Thomas Papastergiou MCF

M2 de mathématiques

Mathématiques des Données

M2 en Informatique

Exploration Informatique des données et décisionnel (EID^2)

Les mathématiques devant ACP

Les mathématiques derrière l'APC

L'ensemble du processus d'obtention des composantes principales à partir d'un ensemble de données brutes peut être simplifié en six parties :

- Prendre l'ensemble de données composé de d+1 dimensions et ignorer les étiquettes de sorte que notre nouvel ensemble de données devienne d dimensionnel.
- Calculer la **moyenne** et l'**écart-type** pour chaque dimension de l'ensemble des données.
- Calculer la **matrice de covariance** de l'ensemble des données.
- Calculer les **vecteurs propres** et les **valeurs propres** correspondantes.
- Ordonner les vecteurs propres par valeurs propres décroissantes et choisissez k vecteurs propres avec les valeurs propres les plus élevées pour former une matrice de dimension d × k **W**.
- Utilisez cette matrice de vecteurs propres d × k pour transformer les échantillons dans le nouveau sous-espace.

Source: https://towardsdatascience.com/the-mathematics-behind-principal-component-analysis-fff2d7f4b643

Les mathématiques derrière l'APC - La normalisation

- La normalisation des données avant une ACP sur la matrice de covariance dépend des échelles de mesure des caractéristiques originales.

- Étant donné que l'ACP produit un sous-espace de caractéristiques qui maximise la variance le long des axes, il est logique de normaliser les données, en particulier si elles ont été mesurées à des échelles différentes.

Matrices - Vectors

1.1 Matrices

- **Matrix** is a rectangular 2-dimensional array of numbers (scalars).
- $\boldsymbol{M} \in \mathbb{R}^{m \times n}$ is a matrix $\boldsymbol{M}$ with m rows and n columns.
- For example:

$$\boldsymbol{M} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 0 \\ 4 & 3 & 2 & 1 \end{bmatrix}$$

- Here, $\boldsymbol{M}$ is a 3×4 matrix: it has 3 rows and 4 columns. 3 and 4 are the **dimensions** of $\boldsymbol{M}$.

1.3 Vectors

- **Vector** is a $1 \times n$ matrix (NB: we use *row vectors*).
- $\boldsymbol{v} \in \mathbb{R}^n$ is a vector $\boldsymbol{v}$ with n entries or components (n-dimensional vector).
- For example:

$$\boldsymbol{v} = [4, 3, 2, 1]$$

- Here, $\boldsymbol{v}$ is a 4-dimensional vector.

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

Matrices spéciales

Définition. Une matrice dont toutes les entrées sont nulles est appelée **matrice zéro** et est notée O

$$O = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Définition. Une matrice carrée dont les entrées hors diagonale sont toutes nulles est appelée **matrice diagonale**

$$A = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix}$$

Définition. **La matrice identité**, notée $\boldsymbol{I_n}$, est la matrice diagonale nxn dont la diagonale est composée par des uns.

$$I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Définition. La **transposée** d'une matrice mxn A est la matrice nxm A^T obtenue en intervertissant les lignes et les colonnes de A, i. e., $\left(A^T\right)_{ij} = A_{ji}$

$$A = \begin{bmatrix} 0 & 4 & 0 \\ 3 & 7 & 4 \end{bmatrix} \quad A^T = \begin{bmatrix} 0 & 3 \\ 4 & 7 \\ 0 & 4 \end{bmatrix}$$

Définition. Une matrice carrée A est **symétrique** si $A^T = A$

$$A = \begin{bmatrix} 5 & 10 & 1 \\ 10 & 7 & 24 \\ 1 & 24 & 4 \end{bmatrix}$$

Matrices

2 Addition and scalar multiplication

2.1 Matrix addition

- **Matrix addition** is simply adding the entries of two or more matrices one by one.
- This summation results in another matrix:
- $\boldsymbol{M_0 + M_1 = M_2}$
- For example:

$$\begin{bmatrix} 2 & 3 & 4 \\ 0 & 0 & 0 \\ 3 & 2 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 4 & 5 \\ 0 & 0 & 0 \\ 4 & 3 & 2 \end{bmatrix}$$

- NB: we can add only matrices of *the same dimensionality*!
- The resulting matrix retains the same dimensions (3×3 in the example above).
- One can *subtract* matrices in the same way.

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

Matrices

2.2 Multiplication by scalar

- To **multiply a matrix by scalar** (a raw number), one also simply multiplies all its entries by this scalar.
- It results in another matrix of the same dimensionality.
- For example:

$$\begin{bmatrix} 2 & 3 & 4 \\ 0 & 0 & 0 \\ 3 & 2 & 1 \end{bmatrix} \times 2 = \begin{bmatrix} 4 & 6 & 8 \\ 0 & 0 & 0 \\ 6 & 4 & 2 \end{bmatrix}$$

- One can *divide* a matrix by a scalar in the same way:

$$\begin{bmatrix} 2 & 3 & 4 \\ 0 & 0 & 0 \\ 3 & 2 & 1 \end{bmatrix} /2 = \begin{bmatrix} 1 & 1.5 & 2 \\ 0 & 0 & 0 \\ 1.5 & 1 & 0.5 \end{bmatrix}$$

- This essentially amounts to the scalar multiplication by fraction:

$$\begin{bmatrix} 2 & 3 & 4 \\ 0 & 0 & 0 \\ 3 & 2 & 1 \end{bmatrix} /2 = \begin{bmatrix} 2 & 3 & 4 \\ 0 & 0 & 0 \\ 3 & 2 & 1 \end{bmatrix} \times \frac{1}{2} = \begin{bmatrix} 1 & 1.5 & 2 \\ 0 & 0 & 0 \\ 1.5 & 1 & 0.5 \end{bmatrix}$$

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

3 Vector to vector multiplication

- **Vector to vector multiplication** $(\boldsymbol{v} \cdot \boldsymbol{x})$ is a special case of matrix-matrix multiplication.
- It is defined *only* if the dimensionalities of both vectors match:

  $\boldsymbol{v}, \boldsymbol{x} \in \mathbb{R}^n$
- The result of this multiplication is called the *inner product* or *dot product* and is a scalar:

  $\boldsymbol{v} \cdot \boldsymbol{x} = z$
- It is calculated as a sum of one-by-one multiplications of the corresponding entries of $\boldsymbol{v}$ and $\boldsymbol{x}$:

$$z = \sum_{i=0}^{n} \boldsymbol{v}_i \times \boldsymbol{x}_i$$

- For example:

  $[2, 0, 2] \cdot [1, 3, 1] = 2 \times 1 + 0 \times 3 + 2 \times 1 = 2 + 0 + 2 = 4$

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

Produit intérieur - Vecteurs orthogonaux

Définition. On dit que deux vecteurs sont orthogonaux s'ils sont perpendiculaires l'un à l'autre, c'est-à-dire que le produit intérieur des vecteurs est nul.

Définition. On dit qu'un ensemble de vecteurs $\{v_1, v_2, ..., v_n\}$ sont mutuellement orthogonaux si chaque paire de vecteurs est orthogonale, c'est-à-dire $v_i \, v_j = 0$, pour tout $i \neq j$.

Exercice. Trouver tout les vecteurs orthogonal à $v = \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}$

Source: https://textbooks.math.gatech.edu/ila/dot-product.html

Produit intérieur - Vecteurs orthogonaux

Solution

Il faut trouver tous les vecteurs **x** tels que **x**·**v** = 0, ce qui signifie qu'il faut résoudre l'équation suivante

$$0 = x \cdot v = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = x_1 + x_2 - x_3.$$

La forme paramétrique de l'ensemble solution est $x_1 = -x_2 + x_3$, donc la forme vectorielle paramétrique de la solution générale est

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_2 \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} + x_3 \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}.$$

Par conséquent, la réponse est le plan

$$\text{Span} \left\{ \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right\}.$$

Source: https://textbooks.math.gatech.edu/ila/dot-product.html

Matrices

4 Vector to matrix multiplication

4.1 Requirements

- **Vector to matrix multiplication** $(\boldsymbol{v} \cdot \boldsymbol{W})$ is also a special case of matrix-matrix multiplication.
- It is defined *only* if the dimensionality of the vector and the number of rows in the matrix match:
- $\boldsymbol{v} \in \mathbb{R}^m, \boldsymbol{W} \in \mathbb{R}^{m \times n}$
- ...more explicitly, *the number of columns in the vector and the number of rows in the matrix must be identical*:
- $\boldsymbol{v} \in \mathbb{R}^{1 \times m}, \boldsymbol{W} \in \mathbb{R}^{m \times n}$
- The result of right-multiplying a vector $\boldsymbol{v} \in \mathbb{R}^m$ (or, equally, $\boldsymbol{v} \in \mathbb{R}^{1 \times m}$) by a matrix $\boldsymbol{W} \in \mathbb{R}^{m \times n}$ is a *vector* $\boldsymbol{y} \in \mathbb{R}^n$
  - $\boldsymbol{v} \cdot \boldsymbol{W} = \boldsymbol{y}$
  - For example:

$$\boldsymbol{y} = \boldsymbol{v} \cdot \boldsymbol{W} = [2, 3] \cdot \begin{bmatrix} 4 & 2 & 3 \\ 3 & 2 & 1 \end{bmatrix} = [17, 10, 9]$$

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

Matrix multiplication

5 Matrix to matrix multiplication

5.1 Matrix to matrix is another matrix

- Any row vector is in fact a $1 \times n$ matrix.
- Thus, to **multiply one matrix by another**, is conceptually the same as multiplying a vector by a matrix.
- Again, the number of columns in the left matrix $\boldsymbol{W}^1$ must match the number of rows of the right matrix $\boldsymbol{W}^2$:
  $\boldsymbol{W}^1 \in \mathbb{R}^{m \times n}, \boldsymbol{W}^2 \in \mathbb{R}^{n \times z}$
- But the *result of this multiplication is another matrix*:
  $\boldsymbol{W}^1 \cdot \boldsymbol{W}^2 = \boldsymbol{W}^3 \in \mathbb{R}^{m \times z}$
- For example, suppose $\boldsymbol{W}^1 \in \mathbb{R}^{2 \times 3}, \boldsymbol{W}^2 \in \mathbb{R}^{3 \times 4}$:

$$\boldsymbol{W}^3 = \boldsymbol{W}^1 \cdot \boldsymbol{W}^2 = \begin{bmatrix} 4 & 2 & 3 \\ 3 & 2 & 1 \end{bmatrix} \cdot \begin{bmatrix} 2 & 1 & 2 & 2 \\ 1 & 2 & 1 & 1 \\ 3 & 3 & 3 & 2 \end{bmatrix} = \begin{bmatrix} 19 & 17 & 19 & 16 \\ 11 & 10 & 11 & 10 \end{bmatrix}$$

- Here, $\boldsymbol{W}^3 \in \mathbb{R}^{2 \times 4}$

Source: https://www.uio.no/studier/emner/matnat/ifi/IN5550/v19/la.pdf

Matrix multiplication

What sizes of matrices can be multiplied together?

For m x n matrix A and n x p matrix B, the matrix product AB is an m x p matrix.

m x n $\quad$ n x p

"inner" parameters must match

"outer" parameters become parameters of matrix AB

If A is a square matrix and k is a positive integer, we define

$$A^k = \underbrace{A \cdot A \cdots A}_{k \text{ factors}}$$

Source: https://www.math.hmc.edu/~dk/math40/math40-lect07.pdf

Propretés de la multiplication des matrices

La plupart des propriétés attendues pour la multiplication des matrices sont vraix…

$$A(B + C) = AB + AC$$
$$(AB)C = A(BC)$$
$$k(AB) = (kA)B = A(kB) \text{ for scalar k}$$

…sauf la commutativité

En général, $AB \neq BA$

Source: https://www.math.hmc.edu/~dk/math40/math40-lect07.pdf

Déterminants

What they are. A determinant is a value associated to a square array of numbers, that square array being called a square matrix. For example, here are determinants of a general 2×2 matrix and a general 3×3 matrix.

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc.$$

$$\begin{vmatrix} a & b & c \\ d & e & f \\ g & h & i \end{vmatrix} = aei + bfg + cdh - ceg - afh - bdi.$$

The determinant of a matrix A is usually denoted $|A|$ or $\det(A)$.

Source: http://aleph0.clarku.edu/~djoyce/ma122/determinants.pdf

Matrice de Covariance

La matrice de covariance est une matrice symétrique $m \times m$ (où m est le nombre de dimensions) dont les entrées sont les covariances associées à toutes les paires possibles de variables initiales.

Par exemple, pour un ensemble de données tridimensionnelles avec 3 variables x, y et z, la matrice de covariance est une matrice 3×3 de ce type :

$$\begin{bmatrix} Cov(x,x) & Cov(x,y) & Cov(x,z) \\ Cov(y,x) & Cov(y,y) & Cov(y,z) \\ Cov(z,x) & Cov(z,y) & Cov(z,z) \end{bmatrix}$$

$$Cov(x,y) = \frac{1}{n-1}\sum_{i=1}^{n}(\boldsymbol{x}_i - \overline{\boldsymbol{x}})\,(\boldsymbol{y}_i - \overline{\boldsymbol{y}})$$

$\boldsymbol{x}_i$ - les valeurs de la variable x
$\boldsymbol{y}_i$ - les valeurs de la variable y
$\overline{\boldsymbol{x}}$ - la moyenne de la variable x
$\overline{\boldsymbol{y}}$ - la moyenne de la variable y

Matrice de Covariance

Puisque la covariance d'une variable avec elle-même est sa variance $(Cov(x,x) = Var(x))$, dans la diagonale principale (du haut à gauche au bas à droite), nous avons en fait les variances de chaque variable initiale.

$$\begin{bmatrix} Cov(x,x) & Cov(x,y) & Cov(x,z) \\ Cov(y,x) & Cov(y,y) & Cov(y,z) \\ Cov(z,x) & Cov(z,y) & Cov(z,z) \end{bmatrix}$$

Et comme la covariance est commutative $(Cov(x,y) = Cov(x,y))$, les valeurs de la matrice de covariance sont symétriques par rapport à la diagonale principale, ce qui signifie que les parties triangulaires supérieures et inférieures sont égales.

Source: https://builtin.com/data-science/step-step-explanation-principal-component-analysis

Matrice de Covariance

Qu'est-ce que les covariances que nous avons comme valeurs de la matrice nous apprennent sur les corrélations entre les variables ?

C'est en fait le signe de la covariance qui importe :

- si elle est positive : les deux variables augmentent ou diminuent ensemble (corrélées)
- si elle est négative : l'une augmente lorsque l'autre diminue (corrélation inverse).

Nous savons maintenant que la matrice de covariance n'est rien d'autre qu'une matrice qui résume les corrélations entre toutes les paires de variables possibles.

Indépendance linéaire

- Un ensemble de vecteurs à *n dimensions* $x_i \in \mathbb{R}^n$, est dit linéairement indépendant si aucun d'entre eux ne peut être écrit comme une combinaison linéaire des autres.
- Cela veut dire que

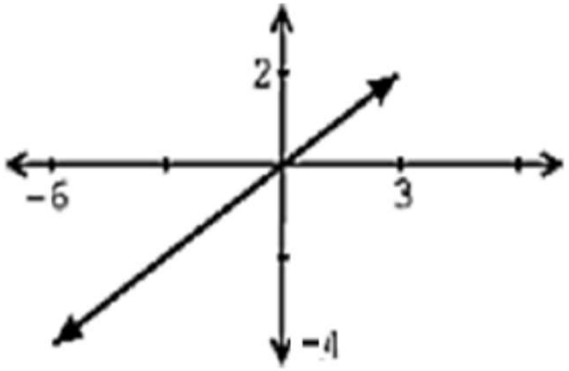
$$c_1 x_1 + c_2 x_2 + \cdots + c_k x_k = 0$$

si et seulement si $c_1 = c_2 = \cdots = c_k = 0$

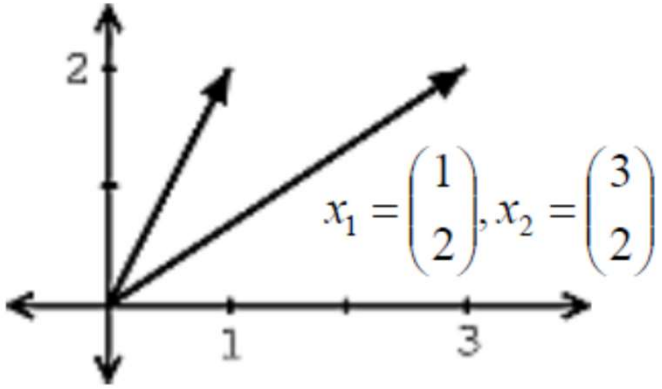
Indépendance linéaire

– Une autre approche pour révéler l'indépendance de vecteurs est la représentation graphique des vecteurs.

$$x_1 = \begin{pmatrix} 3 \\ 2 \end{pmatrix}, x_2 = \begin{pmatrix} -6 \\ -4 \end{pmatrix}$$



Not linearly independent vectors



Linearly independent vectors

Span

– Le Span d'un ensemble de vecteurs x_1, x_2, ... , x_k est l'ensemble des vecteurs qui peuvent être écrits comme une combinaison linéaire de x_1, x_2, ... , x_k .

$$span(x_1, x_2, \ldots, x_k) = \{c_1x_1 + c_2x_2 + \ldots + c_kx_k \mid c_1, c_2, \ldots, c_k \in \Re\}$$

Base

- **Une base pour $\mathbb{R}^n$** est un ensemble de vecteurs qui :
  - **span sur $\mathbb{R}^n$**, c'est-à-dire que tout vecteur dans cet espace à n dimensions peut être écrit comme une combinaison linéaire de ces vecteurs de base.
  - Sont linéairement indépendants.

- Il est clair que tout ensemble de *n* vecteurs linéairement indépendants forment une base pour $\mathbb{R}^n$.

Base Orthogonale/Orthonormale

- **Une base orthonormale** d'un espace vectoriel *V* avec un produit intérieur est un ensemble de vecteurs de base dont les éléments sont mutuellement orthogonaux et de magnitude 1 (vecteurs unitaires).
- Les éléments d'une **base orthogonale** ne doivent pas nécessairement être des vecteurs unitaires, mais doivent être mutuellement perpendiculaires. Il est facile de changer les vecteurs d'une base orthogonale par des multiples scalaires pour obtenir une base orthonormée, et c'est d'ailleurs une façon typique de construire une base orthonormée.
- Deux vecteurs sont orthogonaux s'ils sont perpendiculaires, c'est-à-dire s'ils forment un angle droit, i.e. si leur produit intérieur est nul.

$$a^T \cdot b = \sum_{i=1}^{n} a_i b_i = 0 \quad \Rightarrow \quad a \perp b$$

La base standard de l'espace euclidien à n dimensions $\mathbb{R}^n$ est un exemple de base orthonormée (et ordonnée).

Eigenvalues et Eigenvectors

"Eigen" est un mot allemand qui signifie "propre", "approprié" ou "caractéristique".

Définitions

Soit A une matrice $n \times n$. Le nombre λ est **une valeur propre** de A s'il existe un vecteur non nul **v** tel que $A\boldsymbol{v} = \lambda\boldsymbol{v}$**.**

Dans ce cas, le vecteur **v** est appelé **vecteur propre** de A correspondant à λ.

Calcul des valeurs propres et des vecteurs propres

Nous pouvons réécrire la condition $A\boldsymbol{v} = \lambda\boldsymbol{v}$ comme $(A - \lambda I)\boldsymbol{v} = \mathbf{0}$, où I est la matrice d'identité $n \times n$.

Pour qu'un vecteur non nul **v** satisfasse cette équation, $A - \lambda I$ ne doit pas être inversible.

Autrement dit, le déterminant de $A - \lambda I$ doit être égal à 0. Nous appelons $p(\lambda) = \det(A - \lambda I)$ le **polynôme caractéristique** de A.

Les valeurs propres de A sont simplement les racines du polynôme caractéristique de A.

Le vecteur propre correspondant peut être trouvé en substituant λ à l'équation $A\boldsymbol{v} = \lambda\boldsymbol{v}$ et en résolvant ensuite pour $\boldsymbol{v}$.

Eigenvalues & Eigenvectors

- **Vecteurs propres** (pour une matrice carrée mxm ***A***)

$$A\boldsymbol{v} = \lambda\boldsymbol{v}$$

vecteur propre droit $\mathbf{v} \in \mathbb{R}^m \neq \mathbf{0}$ valeur propre $\lambda \in \mathbb{R}$

- Combien y a-t-il de valeurs propres au maximum ?

$$A\boldsymbol{v} = \lambda\boldsymbol{v} \Leftrightarrow (A - \lambda I)\boldsymbol{v} = \mathbf{0}$$

n'a une solution non nulle que si $\det(A - \lambda I) = 0$

Il s'agit d'une équation d'ordre m dans λ qui peut avoir **u plus m solutions distinctes** (racines du polynôme caractéristique) - **elle peut être complexe même si A est réel.**

Théorèmes utiles

Théorème 1. (Orthogonalité et vecteurs propres)

Si la matrice $n \times n$ A est **symétrique,** then **les vecteurs propres correspondant aux différentes valeurs propres** doivent être **orthogonaux** entre eux.

Théorème 2.

Toutes les valeurs propres d'une **matrice symétrique réelle** sont **réelles**.

Eigenvalues et Eigenvectors

Trouver les valeurs propres et les vecteurs propres de la matrice of the matrix

$$A = \begin{bmatrix} -4 & -6 \\ 3 & 5 \end{bmatrix}$$

Eigenvalues et Eigenvectors

Trouver les valeurs propres et les vecteurs propres de la matrice

$$A = \begin{bmatrix} -4 & -6 \\ 3 & 5 \end{bmatrix}$$

Déterminons d'abord le polynôme caractéristique de A. Nous obtenons

$$A - \lambda I_2 = \begin{bmatrix} -4 & -6 \\ 3 & 5 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} -4-\lambda & -6 \\ 3 & 5-\lambda \end{bmatrix}$$

$$|A - \lambda I_2| = (-4-\lambda)(5-\lambda) + 18 = \lambda^2 - \lambda - 2$$

Résolvons maintenant l'équation caractéristique de A.

$$\lambda^2 - \lambda - 2 = 0 \Rightarrow (\lambda - 2)(\lambda + 1) = 0 \Rightarrow \lambda = 2 \text{ or } -1$$

Les valuers propres de A sont 2 et –1.

Les vecteurs propres correspondants sont trouvés en utilisant ces valeurs de λ dans l'équation $(A - \lambda I_2)\mathbf{x} = \mathbf{0}$. Il existe de nombreux vecteurs propres correspondant à chaque valeur propre.

Source: https://members.imamu.edu.sa/staff/mibinasfour/courses/Pages/default.aspx

Eigenvalues et Eigenvectors

- Pour $\lambda = 2$

  Nous résolvons l'équation $(A - 2I_2)\mathbf{x} = \mathbf{0}$ pour $\mathbf{x}$.

La matrice $(A - 2I_2)$ est obtenue en soustrayant 2 aux éléments diagonaux de A. On obtient ainsi $\begin{bmatrix} -6 & -6 \\ 3 & 3 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$

Cela conduit au système d'équations suivant

$$-6x_1 - 6x_2 = 0$$
$$3x_1 + 3x_2 = 0$$

donnant $x_1 = -x_2$. Les solutions de ce système d'équations sont $x_1 = -r$, $x_2 = r$, où r est un scalaire. Ainsi, les **vecteurs propres** de A correspondantes à $\lambda = 2$ sont des vecteurs non nuls de la forme

$$\mathrm{v}_1 = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_2 \begin{bmatrix} -1 \\ 1 \end{bmatrix} = r \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

Eigenvalues et Eigenvectors

- Pour $\lambda = -1$

Nous résolvons l'équation $(A - 1I_2)\mathbf{x} = \mathbf{0}$ pour $\boldsymbol{x}$.

La $(A - 1I_2)$ est obtenue en ajoutant 1 aux éléments diagonaux de A. Nous obtenons

$$\begin{bmatrix} -3 & -6 \\ 3 & 6 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$$

This leads to the system of equations

$$-3x_1 - 6x_2 = 0$$

$$3x_1 + 6x_2 = 0$$

donnant $x_1 = -2x_2$. Les solutions de ce système d'équations sont $x_1 = -2s$ et $x_2 = s$, où s is a scalar. Ainsi, les **vecteurs propres** de A correspondantes à $\lambda = -1$ sont des vecteurs non nuls de la forme

$$\mathrm{v}_2 = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_2\begin{bmatrix} -2 \\ 1 \end{bmatrix} = s\begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

Source: https://members.imamu.edu.sa/staff/mibinasfour/courses/Pages/default.aspx

ACP – Analyse en Composants Principales

PCA – Principal Components Analysis

Quand dois-je utiliser l'ACP ?

- Vous souhaitez réduire le nombre de variables, mais vous n'êtes pas en mesure d'identifier les variables à éliminer complètement ?
- Voulez-vous vous assurer que vos variables sont indépendantes les unes des autres ?
- Êtes-vous prêt à rendre vos variables indépendantes moins interprétables ?

Si vous avez répondu "oui" aux trois questions, l'ACP est une bonne méthode à utiliser. Si vous avez répondu "non" à la question 3, **vous ne devez pas utiliser l'ACP**.

Source: https://towardsdatascience.com/a-one-stop-shop-for-principal-component-analysis-5582fb7e0a9c

ACP : une technique d'extraction de caractéristiques

L'analyse en composantes principales est une technique **d'extraction de caractéristiques** - elle combine donc nos variables indépendantes d'une manière spécifique, ce qui nous permet d'éliminer les variables "les moins importantes" tout en conservant les parties les plus précieuses de toutes les variables !

En outre, chacune des "nouvelles" variables après l'ACP est indépendante des autres.

L'ACP atteint cet objectif en projetant les données sur un sous-espace de dimension inférieure qui conserve la majeure partie de la variabilité entre les données.

Source: https://towardsdatascience.com/a-one-stop-shop-for-principal-component-analysis-5582fb7e0a9c

L'ACP : un exemple

Imaginez que vous preniez une photo de quelques personnes. Vous réduisez la dimensionnalité de la 3D (le monde réel) à une représentation en 2D. Vous perdez certaines informations 3D explicites, comme la distance entre une personne à l'avant et une autre personne à l'arrière. Toutefois, vous aurez une idée assez précise de la distance qui sépare ces deux personnes dans la réalité, car la personne située à l'arrière paraîtra plus petite que celle située à l'avant. L'information 3D n'est donc pas complètement perdue, mais elle est en quelque sorte encodée dans l'image 2D.



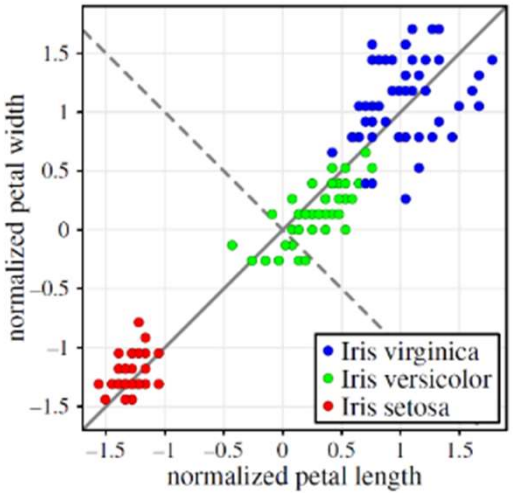
Photo: https://www.nottinghamcollege.ac.uk/about-us/news/graduation-is-just-the-beginning-for-our-university-level-students
Source: https://programmathically.com/principal-components-analysis-explained-for-dummies/

APC: une procédure statistique

- L'analyse en composantes principales (ACP) est une procédure statistique qui utilise ***une transformation orthogonale*** pour convertir un ensemble d'observations de variables ***éventuellement corrélées*** en un ensemble de valeurs de variables ***linéairement non corrélées*** appelées composantes principales.
- L'objectif est d'extraire les informations pertinentes du tableau de données et de les exprimer sous la forme d'un ensemble de nouvelles variables orthogonales.
    - Le nombre de composantes principales est *inférieur ou égal au nombre de variables originales*.
    - Cette transformation est définie de manière à ce que la **première composante principale** ait la ***plus grande variance possible*** (c'est-à-dire qu'elle rende compte de la plus grande partie possible de la variabilité des données), et que **chaque composante suivante ait à son tour la plus grande variance possible *sous la contrainte qu'elle soit orthogonale aux composantes précédentes***.
    - Les vecteurs résultants forment un ensemble de **base orthogonale non corrélées**

Analyse en composantes principales : Objectif

- Méthode statistique pour construire une **projection** de l'espace à haute dimension vers ***un espace à dimension plus basse***
- Utilise la **variance** des données comme *critère de préservation de la structure*
- La projection doit se faire dans un **sous-espace linéaire** qui préserve autant que possible **la variance** originale des données.



Première CP (ligne continue) dans la direction de la variance maximale ; deuxième CP (ligne pointillée) dans la direction de la deuxième variance maximale et orthogonale à la première CP.

step-by-step PCA

Un exemple

- Nous avons collecté m caractéristiques de 100 étudiants :

- Taille

- le poids

- Couleur des cheveux

- Notes scolaires

- ...

- Nous voulons trouver **les paramètres les plus importants** qui décrivent le mieux un élève.

Un exemple

- Chaque étudiant est représenté par un vecteur de données qui le décrit, de longueur m :

- (180,70, 'violet',84,...)

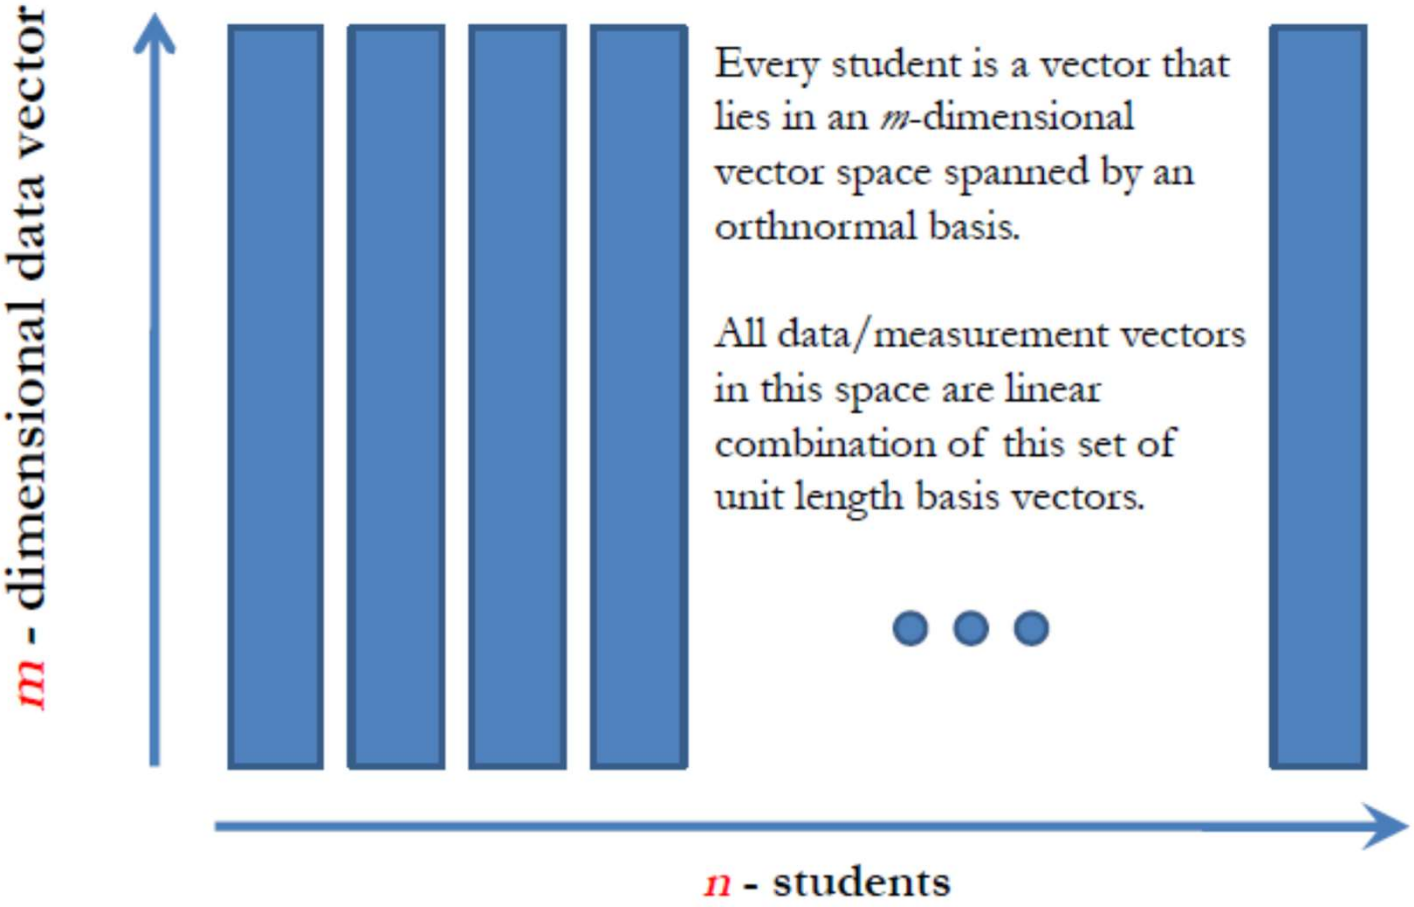
- Nous avons n = 100 vecteurs de ce type.

Mettons-les dans une matrice, où *chaque colonne est un vecteur élève*.

- Nous avons donc une matrice *mxn*.

Cette matrice sera l'entrée de notre problème.

Un exemple


m - dimensional data vector
Every student is a vector that lies in an m-dimensional vector space spanned by an orthnormal basis.
All data/measurement vectors in this space are linear combination of this set of unit length basis vectors.
n - students

Quelles caractéristiques pouvons-nous ignorer ?

- Caractéristiques constantes

(e.g. nombre de têtes)

- 1,1,...,1.

Caractéristiques constantes avec un peu de bruit

- (e.g. épaisseur des cheveux)
  - 0,003, 0,005, 0,002, ..., 0,0008 -> **low variance**
- Caractéristique dépendante linéairement d'autres caractéristiques

(e.g. taille de la tête et hauteur)

- Z= aX + bY

Quelles caractéristiques voulons-nous conserver ?

- - Caractéristiques qui ne dépendent pas des autres
  - par exemple la couleur des yeux
  - c'est-à-dire non corrélé,
  - c'est-à-dire **low covariance**.
- Caractéristiques qui changent beaucoup
  - Notes
  - Le contraire du bruit
  - Variance élevée **High variance**

Questions

- Comment **décrire** les caractéristiques **les plus « importantes »** à l'aide des mathématiques ?
  - **Variance**

- Comment **représentons-nous nos données** de manière telle que les caractéristiques les plus importantes peuvent être extraites facilement ?
  - **Changement de base**

Changement de base !!!

- Soit ***X*** et ***Y*** des matrices m x n reliées par une transformation linéaire **P**.
- ***X*** est l'ensemble des données originales et ***Y*** est une autre représentation de cet ensemble de données.

$$\mathbf{PX = Y}$$

Définitions

- p_i sont les lignes de **P**.
- x_i sont les colonnes de **X**.
- y_i sont les colonnes de **Y**.

Changement de base !!!

- Soit ***X*** et ***Y*** des matrices m x n reliées par une transformation linéaire **P**.
- ***X*** est l'ensemble des données originales et ***Y*** est une autre représentation de cet ensemble de données.

$$PX = Y$$

Qu'est-ce que cela signifie ?

- P est une matrice qui **transforme** X en Y.
- Géométriquement, **P** est une **rotation** et un **stretch** (mise à l'échelle) qui, transforme **X** en **Y**.
- Les lignes de **P**, $\{p_1, p_2, ..., p_m\}$ sont un ensemble de vecteurs **d'une nouvelle base** pour exprimer les colonnes de **X**.

Changement de base !!!

- Écrivons les produits intérieurs explicites de **PX**.
- Nous pouvons observer la forme de chaque colonne de **Y**.

$$PX = \begin{bmatrix} p_1 \\ \vdots \\ p_m \end{bmatrix} \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix}$$

$$Y = \begin{bmatrix} p_1 \cdot x_1 & \cdots & p_1 \cdot x_n \\ \vdots & \ddots & \vdots \\ p_m \cdot x_1 & \cdots & p_m \cdot x_n \end{bmatrix}$$

$$y_i = \begin{bmatrix} p_1 \cdot x_i \\ \vdots \\ p_m \cdot x_i \end{bmatrix}$$

- Nous observons que chaque élément de y_i est un produit intérieur de x_i avec la ligne correspondante de **P**.

- Ça veut dire que, le $j^{ème}$ élément de y_i est une projection sur la $j^{ème}$ ligne de **P**.
- Par conséquent, les ***lignes*** de **P** constituent un nouvel ensemble de vecteurs de base pour représenter les colonnes de **X**.

Changement de base !!!

- Le changement de base ne modifie pas les données, mais seulement leur représentation.

- Changer de base ça veut dire en fait de ***projeter les vecteurs des données sur les vecteurs de la base***.

- Géométriquement, **P** est une **rotation** et un **stretch** de X.
  - Si la base de **P** est orthonormée (longueur = 1 des vecteurs de base), alors la transformation **P** n'est qu'une rotation de X.

Questions restantes !!!

- En supposant la linéarité, *le problème est maintenant de* ***trouver le changement de base approprié***.
- Les vecteurs *lignes* $\{p_1, p_2,...,p_m\}$ dans cette transformation deviendront les composantes principales de **X**.
- Maintenant,
  - Quelle est la meilleure façon de *réexprimer* **X** ?
  - Quel est un bon choix de la base **P** ?
- En outre,
  - *quelles sont les caractéristiques que nous souhaitons que* ***Y*** *possède ?*

Que signifie "*exprimer au mieux*" les données?!!!

- Comme nous l'avons déjà dit, nous voulons **enlever le bruit** et **extraire les informations pertinentes** de des données.

- Par conséquent, la représentation que nous recherchons **réduira** à la fois **le bruit** et la **redondance** des données en question.

Le bruit ...

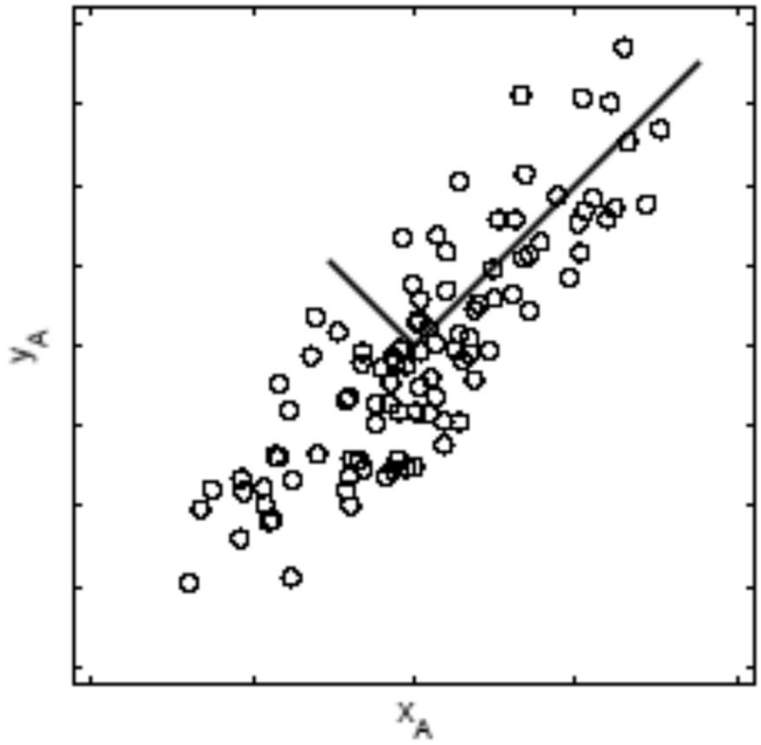
- Le **bruit** dans les données *doit être faible*, sinon - *quelle que soit la technique d'analyse* - aucune information sur un système ne peut être extraite.
- Il n'existe pas d'échelle absolue pour le bruit mais il est plutôt mesuré par rapport à la mesure.
- Une mesure souvent utilisée est le rapport signal/bruit (RSB), ou un rapport de variances.

$$SNR = \frac{\sigma^2_{signal}}{\sigma^2_{noise}}$$

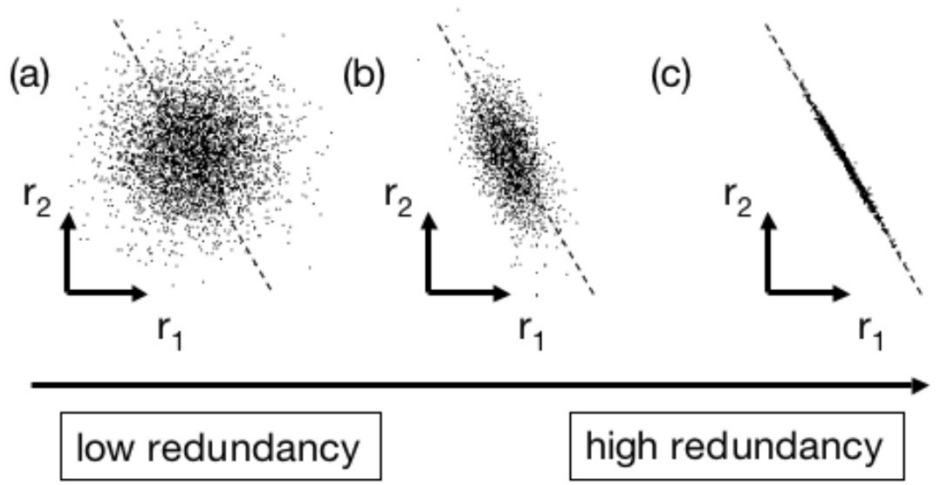
- Un rapport signal/bruit élevé (>>1) indique des données de haute précision
- tandis qu'un rapport signal/bruit faible indique des données contaminées par le bruit.

Pourquoi la variance ???

- Trouver la rotation des axes qui maximise le SNR = maximise la variance entre les axes.



Redondance ...



- Plusieurs capteurs enregistrent la même information dynamique.
- Considérons une gamme de tracés possibles entre deux types de mesures arbitraires r_1 et r_2.
- Le panneau (a) représente deux enregistrements sans redondance, c'est-à-dire *non corrélés*
  - par exemple, la taille d'une personne et sa note moyenne générale.
- Cependant, dans le panneau (c), les deux enregistrements semblent *être fortement liés*, c'est-à-dire que l'un d'eux peut être exprimé en fonction de l'autre.

Matrice de covariance

- En supposant que les données ont ***une moyenne nulle*** (soustraire la moyenne), considérons les vecteurs indexés suivants $\{x_1, x_2, ..., x_m\}$ qui sont les lignes d'une matrice *mxn* **X**.
- Chaque **ligne** correspond à toutes les mesures d'une caractéristique (x_i).
- Chaque colonne de **X** correspond à un ensemble de mesures d'une observation.
- Nous allons maintenant définir la matrice de covariance $\mathbf{S_X}$.

$$\mathbf{S_X} \equiv \frac{1}{n-1}\mathbf{X}\mathbf{X}^T \quad \text{où} \quad \mathbf{X} = \begin{bmatrix} \mathbf{x_1} \\ \vdots \\ \mathbf{x_m} \end{bmatrix}$$

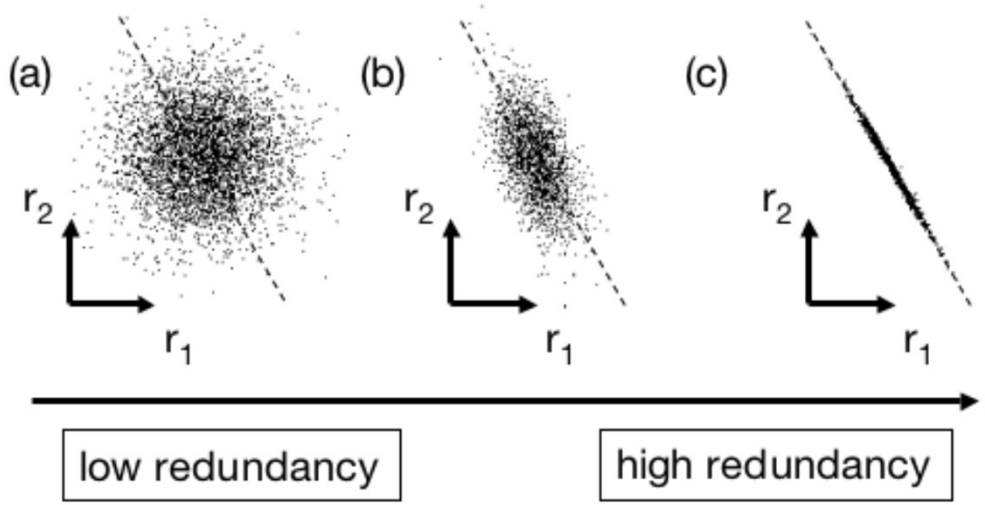
Matrice de covariance

$$\mathbf{S_X} \equiv \frac{1}{n-1}\mathbf{X}\mathbf{X}^T \quad \text{où} \quad \mathbf{X} = \begin{bmatrix} \mathbf{x_1} \\ \vdots \\ \mathbf{x_m} \end{bmatrix}$$

- Le ij^{ème} élément de la variance est le produit intérieur entre le vecteur du i^{ème} caractéristique et le vecteur du j^{ème} caractéristique.
- $\mathbf{S_X}$ est une m×m matrice carrée symétrique.
- Les éléments diagonaux de $\mathbf{S_X}$ sont la variance des caractéristiques particulières.
- Les éléments hors diagonale de $\mathbf{S_X}$ sont la covariance entre des caractéristiques.

Matrice de covariance

$$\mathbf{S_X} \equiv \frac{1}{n-1}\mathbf{X}\mathbf{X}^T \quad \text{où} \quad \mathbf{X} = \begin{bmatrix} \mathbf{x_1} \\ \vdots \\ \mathbf{x_m} \end{bmatrix}$$



- Le calcul de $\mathbf{S_X}$ quantifie les corrélations entre toutes les paires de caractéristiques possibles.
- Entre une paire de mesures,
  - une grande covariance correspond à une situation comme celle du panneau (c),
  - tandis qu'une covariance nulle correspond à des données entièrement non corrélées, comme dans le panneau (a).

Matrice de covariance

- Supposons que nous ayons la possibilité de manipuler $\mathbf{S_X}$. Nous allons définir au fur et à mesure notre matrice de covariance manipulée $\mathbf{S_Y}$.

Quelles caractéristiques voulons-nous optimiser dans S_Y ?

Diagonaliser la matrice de covariance

- Notre objectif est de trouver la matrice de covariance qui :

1. Minimise la redondance, mesurée par la covariance (hors diagonale), c'est-à-dire que nous aimerions que ***chaque variable co-varie le moins possible par rapport aux autres variables***.
2. **Maximise le *signal***, mesuré par la ***variance***, (la diagonale).

Puisque la covariance est non négative, alors la matrice de covariance optimisée sera une matrice diagonale.

Diagonaliser la matrice de covariance
Hypothèses de l'ACP

- L'ACP suppose que tous les vecteurs de base $\{p_1, \ldots, p_m\}$ sont orthonormés (c'est-à-dire que $p_i \cdot p_j = \delta_{ij}$).
- Par conséquent, dans le langage de l'algèbre linéaire, l'ACP suppose que **P** est une matrice orthonormée.
- Deuxièmement, l'ACP suppose que ***les directions ayant les plus grandes variances sont les plus « importantes »*** ou, en d'autres termes, les plus principales.

Pourquoi ces hypothèses sont-elles les plus simples ?

Diagonaliser la matrice de covariance Hypothèses de l'ACP

- En vertu de l'hypothèse de variance, *l'ACP sélectionne d'abord une direction normalisée dans l'espace à m dimensions le long de laquelle la variance de X est maximisée* - elle l'enregistre sous le nom de p1
- *Elle trouve* à nouveau *une autre direction le long de laquelle la variance est maximisée*
  - Cependant, en raison de la condition d'orthonormalité, elle limite sa recherche à toutes les directions perpendiculaires à l'espace des toutes les directions sélectionnées précédemment.
- Cette opération peut se poursuivre jusqu'à ce que *m* directions soient sélectionnées. L'ensemble ordonné de $\mathbf{p}_i$ constitue l'ensemble des *composantes principales.*
- Les variances associées à chaque direction $\mathbf{p}_i$ quantifient le degré d'importance de la composante principale de chaque direction. Nous pourrions donc classer chaque vecteur de base $\mathbf{p}_i$ en fonction des variances correspondantes.
- Ce pseudo-algorithme fonctionne, mais nous pouvons le résoudre à l'aide de l'algèbre linéaire.

Solving PCA: Eigen Vectors of Covariance Matrix

- Nous allons trouver notre première solution algébrique à l'ACP à l'aide de l'algèbre linéaire. Cette solution est basée sur une propriété importante cela de ***la décomposition en vecteurs propres***.
- Une fois encore, l'ensemble de données est **X**, une matrice *m*×*n*, où *m* est le nombre des caractéristiques et *n* le nombre d'observations.
- L'objectif peut être résumé comme suit :
- Trouver une matrice orthonormée **P** où **Y** = **PX** telle que $\boldsymbol{S_Y} \equiv \frac{1}{n-1}\boldsymbol{YY}^T$ soit diagonalisée. Les lignes de **P** sont les composantes principales de X.

Solving PCA: Eigen Vectors of Covariance Matrix

- On commence à réécrire $\mathbf{S_Y}$ en termes de notre matrice de choix **P**

$$
\begin{aligned}
\mathbf{S_Y} &= \frac{1}{n-1}\mathbf{Y}\mathbf{Y}^T \\
&= \frac{1}{n-1}(\mathbf{P}\mathbf{X})(\mathbf{P}\mathbf{X})^T \\
&= \frac{1}{n-1}\mathbf{P}\mathbf{X}\mathbf{X}^T\mathbf{P}^T \\
&= \frac{1}{n-1}\mathbf{P}(\mathbf{X}\mathbf{X}^T)\mathbf{P}^T \\
\mathbf{S_Y} &= \frac{1}{n-1}\mathbf{P}\mathbf{A}\mathbf{P}^T
\end{aligned}
$$

- Notons que nous avons défini une nouvelle matrice **A** = **XX**^{T} , où **A** est symétrique
- Notre feuille de route consiste à reconnaître qu'une matrice symétrique (**A**) est diagonalisée par une matrice orthogonale de ses vecteurs propres
- Une matrice symétrique **A** peut être écrite sous la forme **VDV**^{T} où **D** est une matrice diagonale et **V** est une matrice de vecteurs propres de **A** disposés en colonnes.
- La matrice **A** a $r \leq m$ vecteurs propres orthonormés où **r** est le rang de la matrice.

Résolution de l'ACP : vecteurs propres de la matrice de covariance

- *Voilà le trick : Nous choisissons la matrice **P** comme étant une matrice où chaque ligne p_i est un vecteur propre de $\mathbf{XX^T}$.*
- Par cette sélection, $\mathbf{P} = \mathbf{V^T}$, alors nous avons $\mathbf{A} = \mathbf{P^T D P}$.
- Avec cette relation et le fait que $\mathbf{P^{-1}} = \mathbf{P^T}$ puisque *l'inverse d'une matrice orthonormée est sa transposée*, nous pouvons terminer l'évaluation de $\mathbf{S_Y}$ comme suit ;

$$
\begin{aligned}
\mathbf{S_Y} &= \frac{1}{n-1}\mathbf{P A P}^T \\
&= \frac{1}{n-1}\mathbf{P}(\mathbf{P}^T\mathbf{D}\mathbf{P})\mathbf{P}^T \\
&= \frac{1}{n-1}(\mathbf{P}\mathbf{P}^T)\mathbf{D}(\mathbf{P}\mathbf{P}^T) \\
&= \frac{1}{n-1}(\mathbf{P}\mathbf{P}^{-1})\mathbf{D}(\mathbf{P}\mathbf{P}^{-1}) \\
\mathbf{S_Y} &= \frac{1}{n-1}\mathbf{D}
\end{aligned}
$$

Il est évident que le choix de **P** diagonalise $\mathbf{S_Y}$. *C'était l'objectif de l'ACP !*

ACP Process – STEP 1

- Soustraire la moyenne de chacune des dimensions
- On obtient un ensemble de données dont la moyenne est nulle.
- La soustraction de la moyenne facilite le calcul de la variance et de la covariance en simplifiant leurs équations.
- Les valeurs de variance et de covariance ne sont pas affectées par la valeur moyenne.
- Supposons que nous ayons deux types de caractéristiques $\mathbf{X_1}$ et $\mathbf{X_2}$, (par conséquence *m = 2)*, et 10 observations chacun, (par conséquence *n = 10)*.

ACP Process – STEP 1

X_1	X_2				X'_1	X'_2
2.5	2.4				0.69	0.49
0.5	0.7				−1.31	−1.21
2.2	2.9				0.39	0.99
1.9	2.2				0.09	0.29
3.1	3.0	$\Rightarrow$	$\overline{X_1} = 1.81$ $\overline{X_2} = 1.91$	$\Rightarrow$	1.29	1.09
2.3	2.7				0.49	0.79
2.0	1.6				0.19	−0.31
1.0	1.1				−0.81	−0.81
1.5	1.6				−0.31	−0.31
1.2	0.9				−0.71	−1.01

ACP Process – STEP 2

- Calculer la matrice de covariance

$$S_X = \begin{bmatrix} 0.616555556 & 0.615444444 \\ 0.615444444 & 0.716555556 \end{bmatrix}$$

- Étant donné que les éléments non diagonaux de cette matrice de covariance sont positifs, nous devrions nous attendre à ce que les variables $\mathbf{X_1}$ et $\mathbf{X_2}$ augmentent ensemble.
- Puisqu'elle est symétrique, nous nous attendons à ce que les vecteurs propres soient orthogonaux.

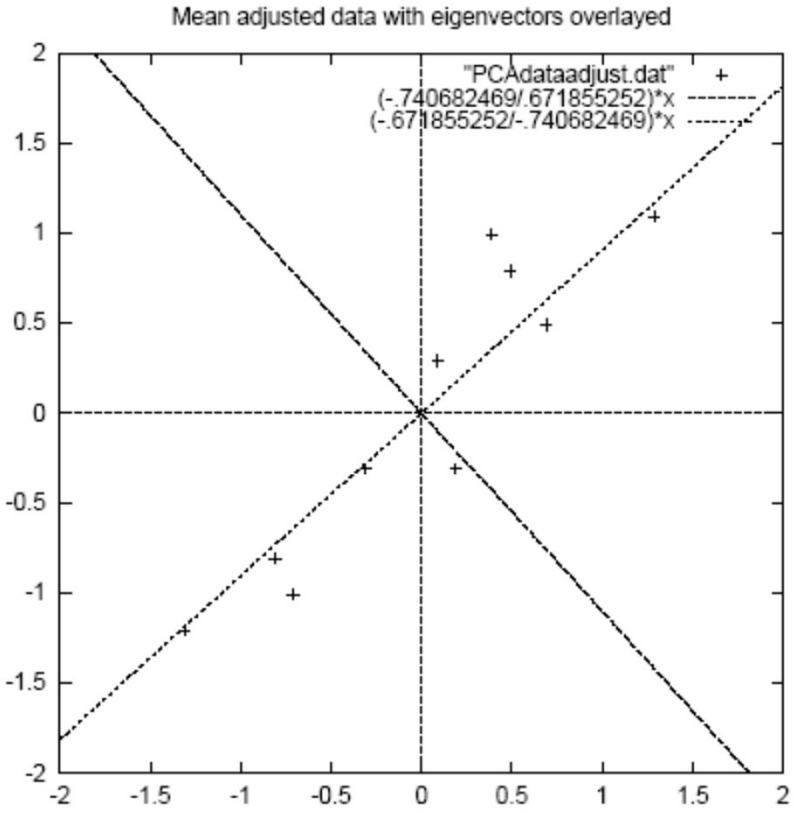
ACP Process – STEP 3

- Calculer les vecteurs propres **V** et les valeurs propres **D** de la matrice de covariance

$$D = \begin{bmatrix} 0.490833989 \\ 1.28402771 \end{bmatrix} = \begin{bmatrix} \lambda_1 \\ \lambda_2 \end{bmatrix}$$

$$V = \begin{bmatrix} -0.735178656 & -0.677873399 \\ 0.677873399 & -0.735178656 \end{bmatrix}$$

ACP Process – STEP 3



A plot of the normalised data (mean subtracted) with the eigenvectors of the covariance matrix overlayed on top.

Les **vecteurs propres** sont représentés par des **diagonales** en pointillés sur le graphique. (remarque **: ils sont perpendiculaires l'une à l'autre**).

L'un des vecteurs propres **passe par le milieu des points,** comme si l'on traçait une ligne de meilleur ajustement (best fit line).

Le second vecteur propre nous donne l'autre motif, moins important, dans les données, à savoir que tous les points suivent la ligne principale, mais s'écartent de la ligne principale d'une certaine façon (de la façon dictée par la ligne correspondant au deuxième CP)

ACP Process – STEP 4

- Réduire la dimensionnalité et former un vecteur de caractéristiques

Le vecteur propre ayant la valeur propre *la plus élevée* est la *composante principale* de l'ensemble de données.

Dans notre exemple, le vecteur propre ayant la valeur propre la plus élevée est celui qui pointe vers le milieu des données.

Une fois que les vecteurs propres sont trouvés à partir de la matrice de covariance, on procède à l'étape suivante où on ordonne les vecteurs propres par valeur propre, de la plus élevée à la plus faible. Cela nous donne les composantes par ordre d'importance.

ACP Process – STEP 4

- Maintenant, si vous le souhaitez, vous pouvez décider *d'ignorer* les composants de moindre importance.
- Vous perdez alors un peu d'information, mais si les valeurs propres sont petites, vous ne perdez pas grand-chose.

Reduction de dimensionnalité

- m les dimensions de vos données
- calculez m vecteurs propres et valeurs propres
- ne choisissez que les r premiers vecteurs propres
- l'ensemble de données final ne comporte que r dimensions.

ACP Process – STEP 4

- Lorsque les λ_i sont triés par ordre décroissant, la proportion de variance expliquée par les r composantes principales est la suivante :

$$\frac{\sum_{i=1}^{r} \lambda_i}{\sum_{i=1}^{m} \lambda_i} = \frac{\lambda_1 + \lambda_2 + \ldots + \lambda_r}{\lambda_1 + \lambda_2 + \ldots + \lambda_p + \ldots + \lambda_m}$$

- Si les dimensions sont fortement corrélées, il y aura un petit nombre de vecteurs propres avec de grandes valeurs propres et *r* sera beaucoup plus petit que *m*.
- Si les dimensions ne sont pas corrélées, *r* sera aussi grand que *m* et l'ACP n'est d'aucune utilité.

ACP Process – STEP 4

- Vecteur de caractéristiques

FeatureVector = (λ_1 λ_2 λ_3... λ_r)

(prendre les vecteurs propres à conserver dans la liste ordonnée des vecteurs propres et former une matrice avec ces vecteurs propres en colonnes)

Nous pouvons soit former un vecteur de caractéristique avec les deux vecteurs propres:

$$\begin{bmatrix} -0.677873399 & -0.735178656 \\ -0.735178656 & 0.677873399 \end{bmatrix}$$

soit choisir de ne pas tenir compte de la composante la plus petite, la moins significative, et n'avoir qu'une seule colonne :

$$\begin{bmatrix} -0.677873399 \\ -0.735178656 \end{bmatrix}$$

ACP Process – STEP 5

- Obtenir les nouvelles données
- **FinalData = RowFeatureVector x RowZeroMeanData**
- RowFeatureVector est la matrice ayant les vecteurs propres comme colonnes qui a été transposée de telle manière que les vecteurs propres se trouvent maintenant dans les lignes, avec les vecteurs propres les plus importants se trouvant en haut de la matrice
- RowZeroMeanData correspond aux données ajustées ayant une moyenne zéro. Les données sont transposées, c'est-à-dire que les observations se trouvent dans chaque colonne, et chaque ligne contient une dimension distincte (caractéristique).

ACP Process – STEP 5

- FinalData est l'ensemble de données final, avec les observations en colonnes et les dimensions (les caractéristiques) en lignes.

- Qu'est-ce que cela nous donne ?

- Les données d'origine uniquement *en termes de vecteurs que nous avons choisis.*

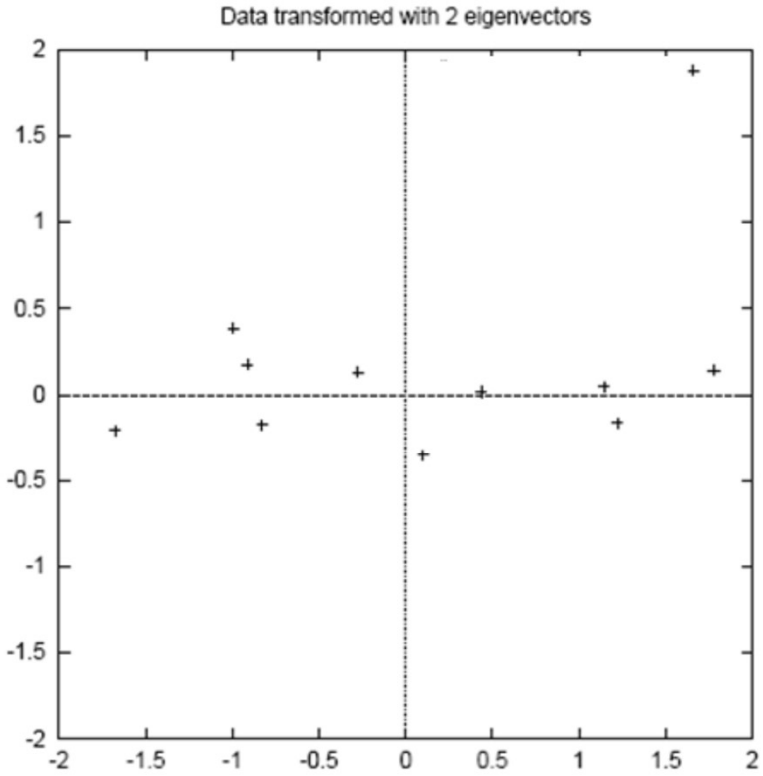
- Nous avons modifié nos données en les faisant passer des axes $\mathbf{X_1}$ et $\mathbf{X_2}$ en termes de nos deux vecteurs propres.

ACP Process – STEP 5

FinalData (transpose: dimensions along columns)

Y_1	Y_2
−0.827870186	−0.175115307
1.77758033	0.142857227
−0.992197494	0.384374989
−0.274210416	0.130417207
−1.67580142	−0.209498461
−0.912949103	0.175282444
0.0991094375	−0.349824698
1.14457216	0.0464172582
0.438046137	0.0177646297
1.22382956	−0.162675287

ACP Process – STEP 5



The table of data by applying the PCA analysis using both eigenvectors, and a plot of the new data points.

Reconstruction des données originales

- Rappelons que :

$$\text{FinalData} = \text{RowFeatureVector} \times \text{RowZeroMeanData}$$

- Alors :

$$\text{RowZeroMeanData} = \text{RowFeatureVector}^{-1} \times \text{FinalData}$$

- Et donc :

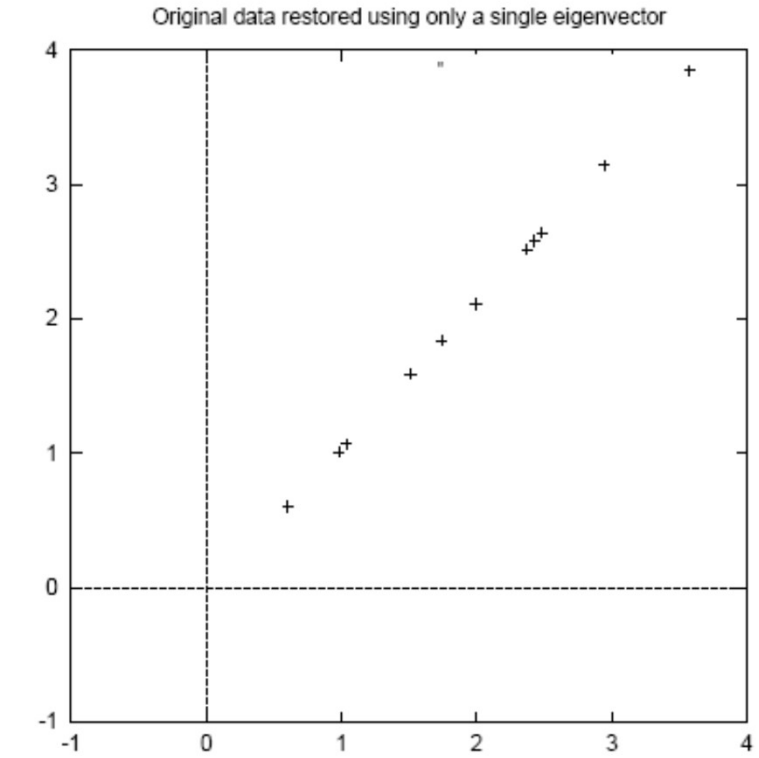
$$\text{RowOriginalData} = (\text{RowFeatureVector}^{-1} \times \text{FinalData}) + \text{MoyenneOriginale}$$

- Si **nous utilisons des vecteurs propres unitaires**, l'inverse est **identique à la transposée** (donc plus facile).

Reconstruction des données originales

- **Si nous réduisons la dimensionnalité** (c'est-à-dire r < m), évidemment, lors de la reconstruction des données, **nous perdons les dimensions que nous avons choisi de supprimer**.
- Dans notre exemple, supposons que nous ayons considéré qu'un seul vecteur propre.
- Les données finales sont uniquement $\mathbf{Y_1}$ et la reconstruction donne...

Reconstruction des données originales



The reconstruction from the data that was derived using only a single eigen vector

La variation le long des composant principale est préservée.

La variation le long de l'autre composante a été perdue.

Principal Component Analysis

Récapitulation et calcul de Composantes Principales à l'aide de Singular Value Decomposition

Analyse en composantes principales ACP I

- Commençons par une matrice de données $\boldsymbol{X} = \begin{bmatrix} & \\ & \end{bmatrix}$ (n samples ; m measurments)

mxm matrix

- L'ACP est la eigen-décomposition de la matrice de covariance $\mathbf{X^T X}$
- On calcule les *m* vecteurs propres **W** et les valeurs propres correspondantes λ_i i=1,2,…,m de $\mathbf{X^T X}$

scores ⟵ **T = XW** ⟶ loadings

- Chaque colonne de **W** (mxm) est une composante principale des données.
  - Les colonnes de **W** sont ordonnées par ordre décroissant d'importance de la valeur propre correspondante.
- **T** est une façon « transformée » de voir les données dans **X**. Nous voyons les données dans une nouvelle base et avec une rotation. **T** est une matrice nxm.

Analyse en composantes principales ACP II

- Réduction de la dimensionnalité
- Nous avons calculé les scores de **X : T** = **XW**
  - Ce qui représente les données dans une nouvelle base.
  - **T** est toujours une matrice nxm.
- Comment pouvons-nous obtenir une représentation de **X** dans un espace de dimension inférieure ?
  - Étant donné que les vecteurs propres dans **W** sont ordonnés en fonction de l'importance des valeurs propres, nous pouvons choisir les r premières composantes de **W**
  - et calculer les scores $\mathbf{T_r = XW_r}$ **.**



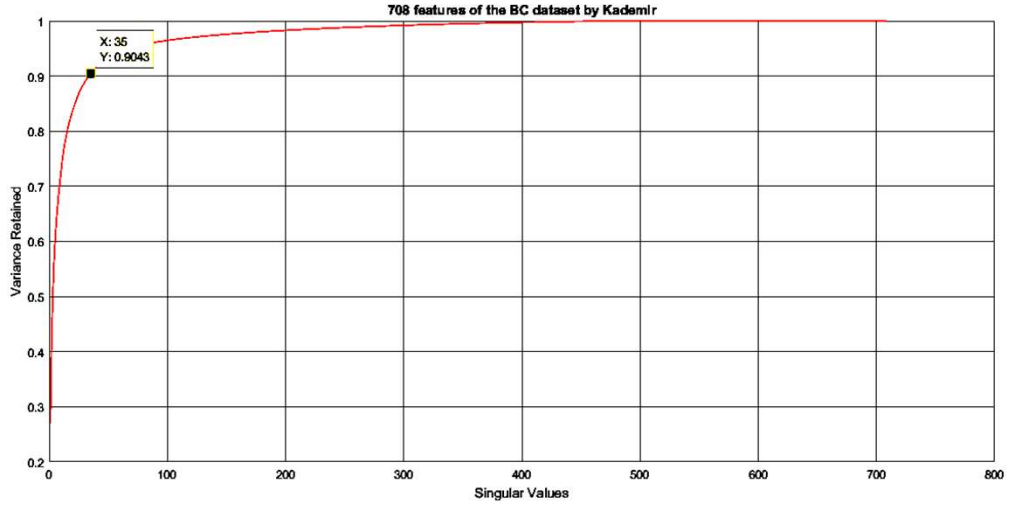
  - **T** a encore n observations
  - **T** a maintenant r caractéristiques
  - Si *r=2* ou *r=3*, nous pouvons visualiser des données de haute dimension.

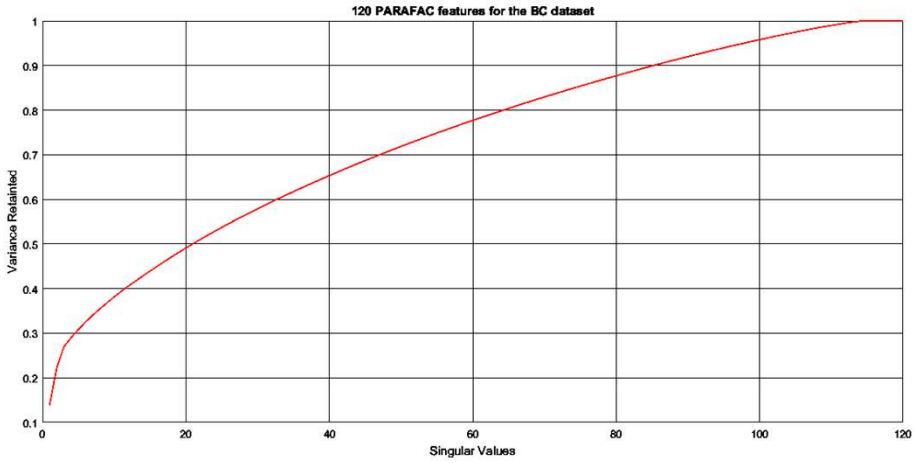
Calcul de l'ACP - Décomposition en valeurs singulières

- **ACP ->** calculer la décomposition propre de la matrice de covariance mxm $\mathbf{X^T X}$.
  - m peut être extrêmement grand
- **SVD (singular value decomposition)**
  - $\mathbf{X} = \mathbf{U\Sigma V^*}$.
    - $\mathbf{V^*}$ est la transposée conjuguée de **V** (si **V** contient des nombres complexes)
  - **U ->** les vecteurs singuliers de gauche
  - $\mathbf{V^*}$ **->** les vecteurs singuliers de droite. Est identique à **W**.
  - $\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\sigma_1} & \mathbf{0} & \mathbf{0} \\ \dots & \dots & \dots \\ \mathbf{0} & \mathbf{0} & \boldsymbol{\sigma_n} \end{bmatrix}$ une matrice diagonale contenant les valeurs singulières par ordre décroissant d'importance.
  - Les valeurs singulières sont proportionnelles aux valeurs propres
    - $\mathbf{U^*U} = \mathbf{V^*V} = \mathbf{I}$
- $\mathbf{X = U\Sigma V^* \Rightarrow XV = U\Sigma V^*V \Rightarrow XW = U\Sigma \Rightarrow T = U\Sigma}$

Comment choisir le nombre de composants r l

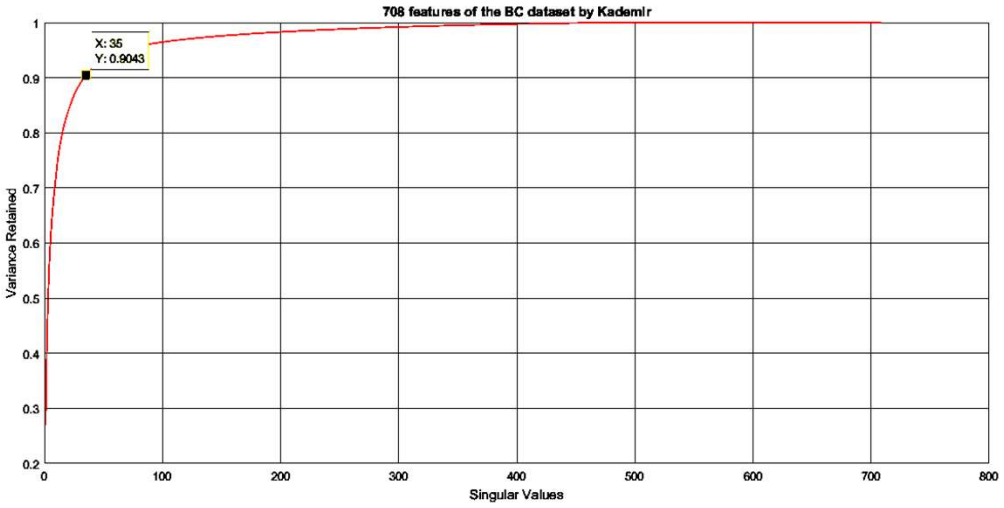
- **T = UΣ**
  - Les valeurs singulières sont ordonnées par ordre décroissant, alors choisissez les r premières valeurs singulières
  - $\mathbf{T_r = U_r \Sigma_r}$.
- **Variance retenue** : mesure du pourcentage de données retenues lors du choix des composantes r.
  - Plot $VarRet(k) = \frac{\sum_{i=1}^{k} \sigma_i}{\sum_{i=1}^{m} \sigma_i}$

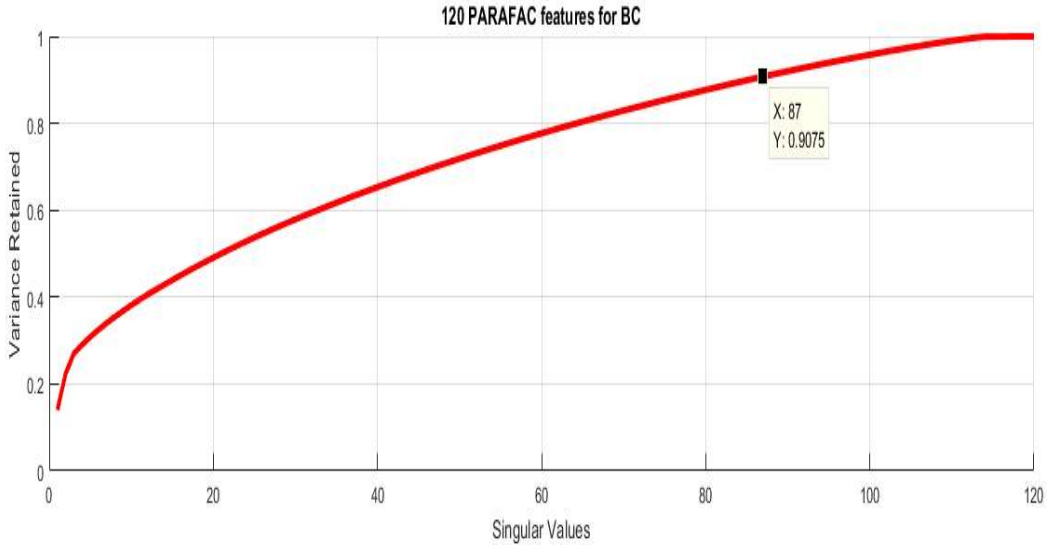




Comment choisir le nombre de composants r II

- Même ensemble de données, différentes méthodes d'extraction de caractéristiques
- Lorsque nous choisissons r= 35, 90,43% des données sont expliquées.
  - 35 des 708 caractéristiques modélisent les données
  - Il semble y avoir beaucoup de caractéristiques **non pertinentes (corrélés)**
- Lorsque nous choisissons r=87, 90,75 % des données sont expliquées
  - 87 des 120 caractéristiques modélisent les données
  - Il semble que chaque caractéristique ait une contribution significative





Data viualization I

- **Comment pouvons-nous visualiser des données de haute dimension ?**
  - Calculer la décomposition SVD sur **X**
  - Calculer les scores tronqués pour r=2 ou r=3
  - Faire une graphique de la matrice des scores tronqués

```
load('ucsb_breast_tenDataset.mat')

[U,S,V] = svd(X);

varRetained =
cumsum(diag(S(:,1:2)))/sum(diag(S));
disp(['variance retained: '
num2str(varRetained(2))])

T_r = U(:,1:2)*S(1:2,1:2);

scatter(T_r(:,1), T_r(:,2),5,Y,'filled')
```

```
load('ucsb_breast_tenDataset.mat')

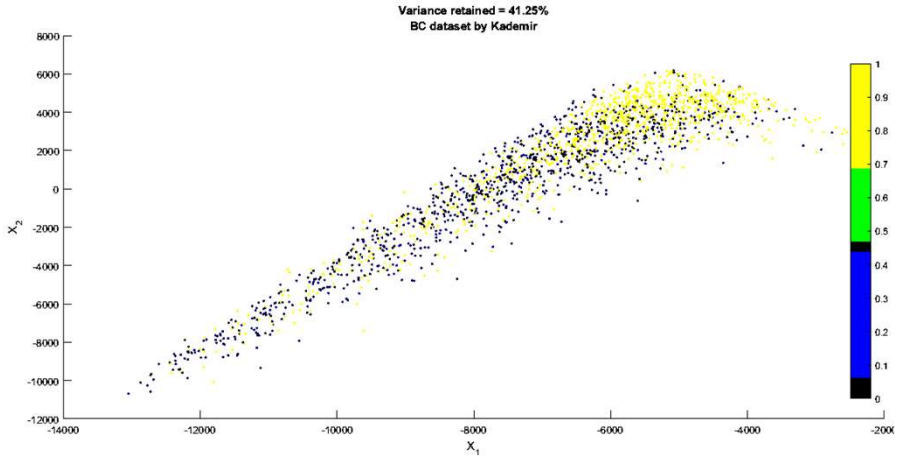
[U,S,V] = svd(X);

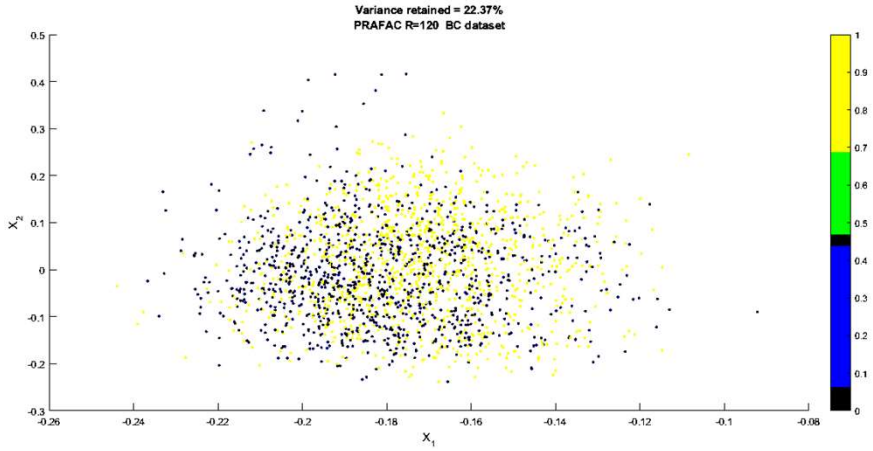
varRetained =
cumsum(diag(S(:,1:3)))/sum(diag(S));
disp(['variance retained: '
num2str(varRetained(2))])

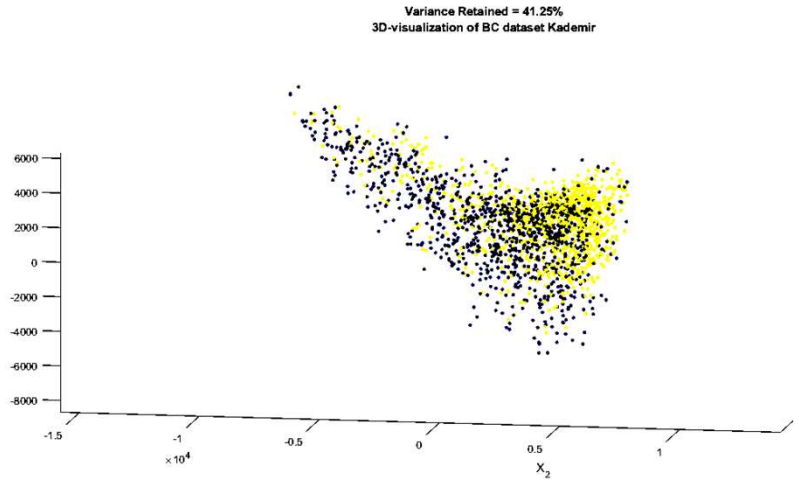
T_r = U(:,1:3)*S(1:3,1:3);

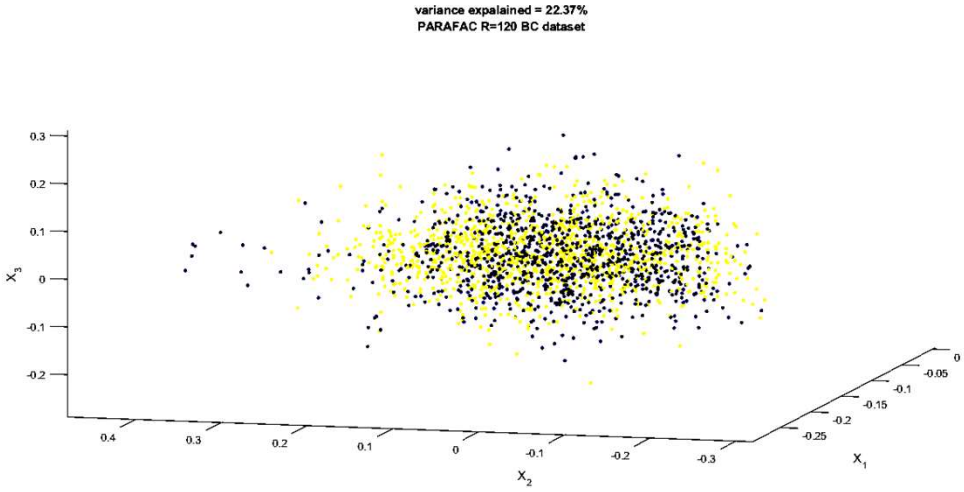
scatter3(T_r(:,1),
T_r(:,2),T_r(:,3),10,Y,'filled')
```

Data visualization II









Un exemple d'ACP étape par étape dans l'ensemble de données Iris

L'ensemble de données Iris contient les mesures de 150 fleurs d'iris de trois espèces différentes

Les trois classes de l'ensemble de données Iris sont les suivantes :

- Iris-setosa (n=50)
- Iris-versicolor (n=50)
- Iris-virginica (n=50)

Les quatre caractéristiques de l'ensemble de données sur les iris sont les suivantes

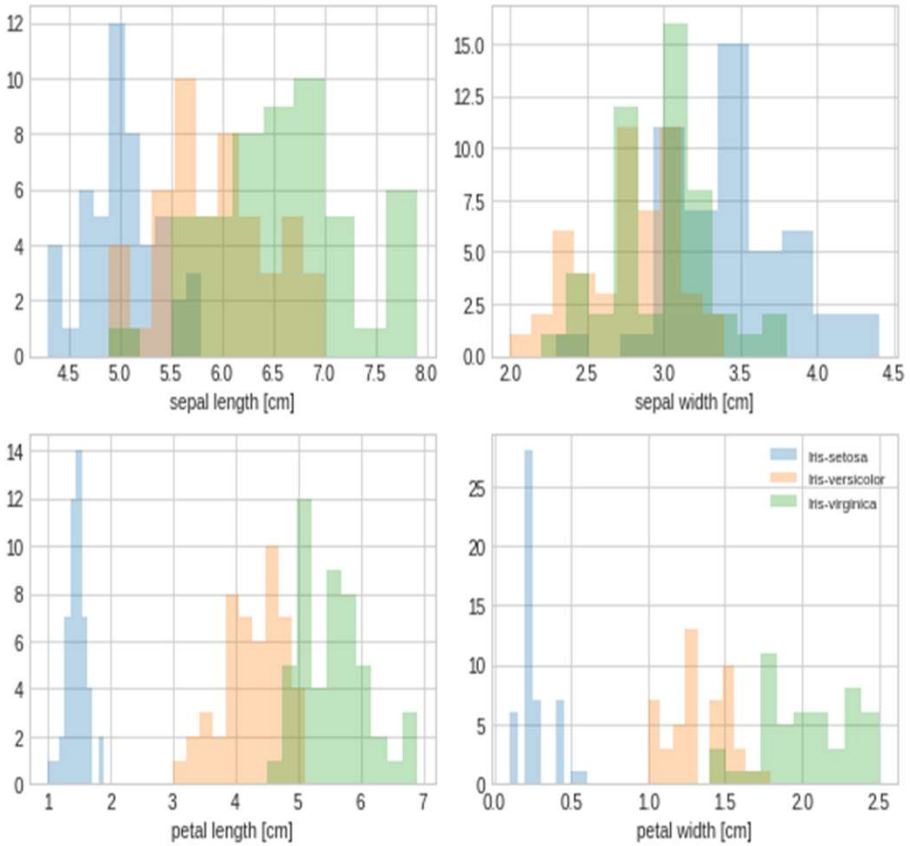
- longueur du sépale en cm
- largeur du sépale en cm
- longueur des pétales en cm
- largeur des pétales en cm

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Exemple – le jeu de données IRIS

Un exemple d'ACP étape par étape dans l'ensemble de données Iris

sepal_len	sepal_wid	petal_len	petal_wid	class
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3.0	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5.0	3.6	1.4	0.2	Iris-setosa



L'ensemble de données **Iris** est stocké sous la forme d'une 150×4 matrice où les colonnes représentent les différentes caractéristiques et chaque ligne représente une observation d'une fleur distincte.
*Chaque ligne d'échantillon **x** peut être représentée sous la forme d'un vecteur à 4 dimensions*

$$X^T = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} sepal\ length \\ sepal\ width \\ petal\ length \\ petal\ width \end{pmatrix}$$

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

A step-by-step PCA example in Iris data set - Normalisation de données

La normalisation des données avant une ACP sur la matrice de covariance dépend des échelles de mesure des caractéristiques originales.

Étant donné que l'ACP produit **un sous-espace de caractéristiques qui maximise la variance le long des axes**, il est logique de normaliser les données, en particulier si elles ont été mesurées à des échelles différentes.

Bien que toutes les caractéristiques de l'ensemble de données Iris aient été mesurées en centimètres, nous poursuivons **la transformation des données à l'échelle unitaire** (moyenne=0 et variance=1), ce qui **est une condition préalable à la performance optimale de nombreux algorithmes d'apprentissage automatique**.

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

A step-by-step PCA example in Iris data set - valeurs propres

Les **vecteurs propres** et les **valeurs propres** d'une matrice de covariance (ou de corrélation) représentent le "cœur" d'une ACP : les **vecteurs propres** (composantes principales) *déterminent les directions du nouvel espace de caractéristiques* et les valeurs **propres** *déterminent leur ampleur*. En d'autres termes, **les valeurs propres expliquent la variance des données le long des nouveaux axes de caractéristiques**.

Covariance matrix

```
[[ 1.00671141 -0.11010327 0.87760486 0.82344326]
[-0.11010327 1.00671141 -0.42333835 -0.358937 ]
[ 0.87760486 -0.42333835 1.00671141 0.96921855]
[ 0.82344326 -0.358937 0.96921855 1.00671141]]
```

Eigenvectors

```
[[ 0.52237162 -0.37231836 -0.72101681 0.26199559]
[-0.26335492 -0.92555649 0.24203288 -0.12413481]
[ 0.58125401 -0.02109478 0.14089226 -0.80115427]
[ 0.56561105 -0.06541577 0.6338014 0.52354627]]
```

Eigenvalues

```
[2.93035378 0.92740362 0.14834223 0.02074601]
```

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Un exemple d'ACP étape par étape dans l'ensemble de données Iris - Sélection des composantes principales

L'objectif typique d'une ACP est **de réduire la dimensionnalité de l'espace original des caractéristiques** en le projetant dans un **sous-espace** plus petit, où les **vecteurs propres formeront les axes**.

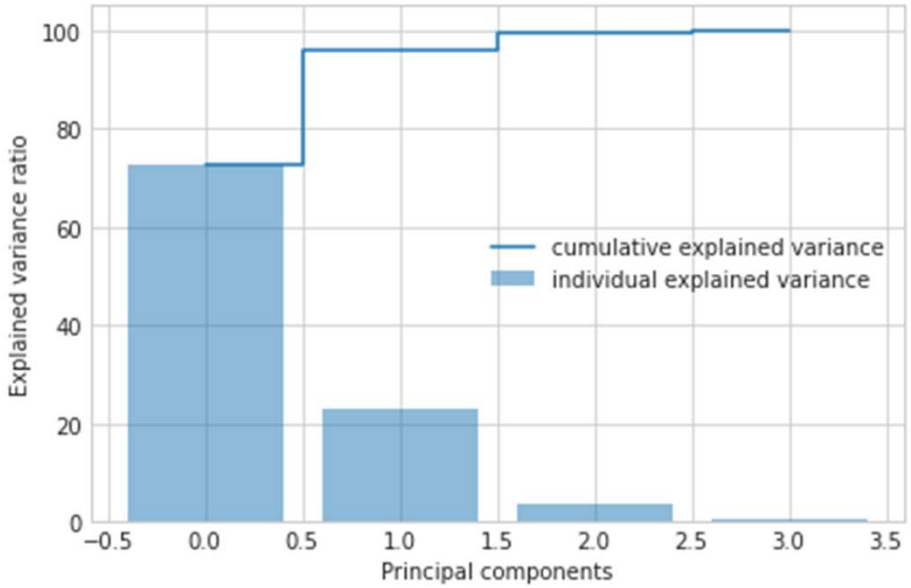
Afin de décider quel(s) vecteur(s) propre(s) peut/peuvent être supprimé(s) sans perdre trop d'information pour la construction d'un sous-espace de dimension inférieure, nous devons inspecter les valeurs propres correspondantes :
Les **vecteurs propres** ayant les **valeurs propres les plus faibles** sont ceux qui contiennent le moins d'informations sur la distribution des données ; ce sont ceux qui peuvent être supprimés.

```
Eigenvalues in
descending order:
2.930353775589317
0.9274036215173428
0.14834222648163967
0.020746013995595967
```

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Un exemple d'ACP étape par étape dans l'ensemble de données Iris - Explained Variance

Après avoir ordonné les paires propres, la question est : "**Combien de composantes principales allons-nous choisir pour notre nouveau sous-espace de caractéristiques ?**" Une mesure utile est ce que l'on appelle la "**variance expliquée**", qui peut être calculée à partir des valeurs propres. La **variance expliquée** *nous indique la quantité d'information (variance) qui peut être attribuée à chacune des composantes principales*.



Le graphique de gauche montre clairement que la majeure partie de la variance (~73%) peut être expliquée seulement par la première composante principale. La deuxième composante principale contient encore quelque information (~23%), tandis que les troisième et quatrième composantes principales peuvent être supprimées sans perdre trop d'information. Ensemble, les deux premières composantes principales contiennent ~96% de l'information.

	Prinicipal Components			
	PC1	**PC2**	**PC3**	**PC4**
Proportion de la variance	0.73	0.229	0.0367	0.00518
Proportion cumulée	0.73	0.958	0.9948	1.0000

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Un exemple d'ACP étape par étape dans l'ensemble de données Iris - Projection Matrix

Il est temps de passer à la partie vraiment intéressante :

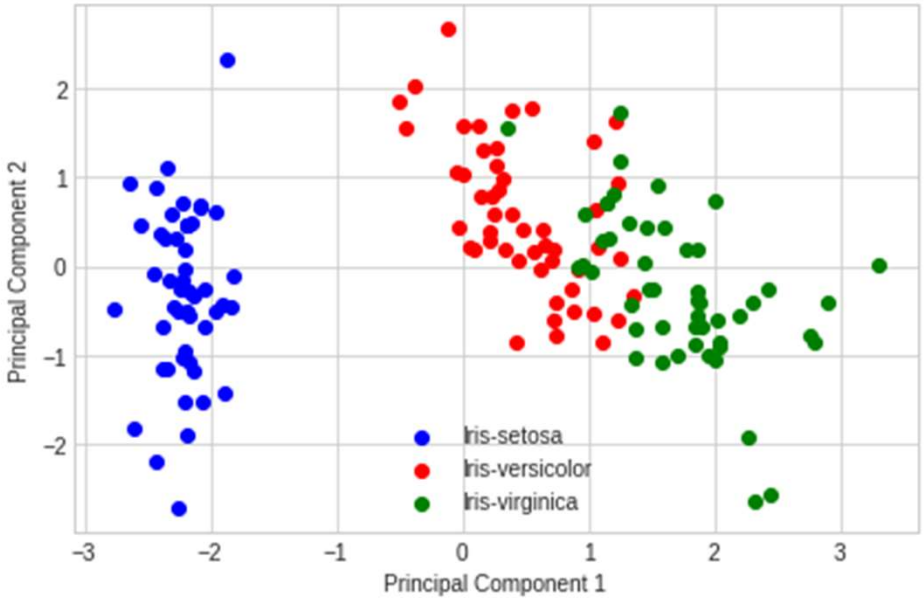
- la construction de la matrice de projection qui sera utilisée pour transformer les données Iris dans le nouveau sous-espace de caractéristiques.
- **La matrice de projection** *est essentiellement la matrice de nos k vecteurs propres concaténés*.
- Ici, nous réduisons l'espace de caractéristiques quadridimensionnel à un sous-espace de caractéristiques bidimensionnel, en choisissant les "2 premiers" vecteurs propres ayant les valeurs propres les plus élevées pour construire notre matrice de vecteurs propres de dimensionnalité 4×2 - W.

```
Matrix W:
[ 0.52237162 -0.37231836]
[-0.26335492 -0.92555649]
[ 0.58125401 -0.02109478]
[ 0.56561105 -0.06541577]]
```

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Exemple d'ACP étape par étape dans l'ensemble de données Iris - Projection sur le nouvel espace des caractéristiques

Dans cette dernière étape, nous utiliserons la matrice de projection **W** à 4×2 dimensions *pour transformer nos échantillons* sur le nouveau sous-espace via l'équation $\boldsymbol{Y} = \boldsymbol{S} \times \boldsymbol{W}$,
où **S** est l'ensemble de données originales normalisées (150x4) et **Y** est une matrice 150×2 de nos échantillons transformés[1].



Dans ce graphique, nous avons identifié chaque espèce avec une couleur différente pour faciliter l'observation. Ici, nous pouvons voir comment l'utilisation de **l'ACP** nous permet d'identifier la structure des données.

[1] L'ensemble de données originales dans cet exemple étape par étape est stocké dans une matrice 150×4 (sous forme de lignes) dont les colonnes représentent les différentes caractéristiques. Dans une diapositive précédente, le vecteur $(\boldsymbol{x} - \overline{\boldsymbol{x}})$ a été écrit sous forme de colonnes et, pour cette raison, la matrice de projection se trouve à gauche.

Source: https://www.apsl.net/blog/2017/06/21/using-principal-component-analysis-pac-data-explore-step-step/

Analyse en composantes principales en R

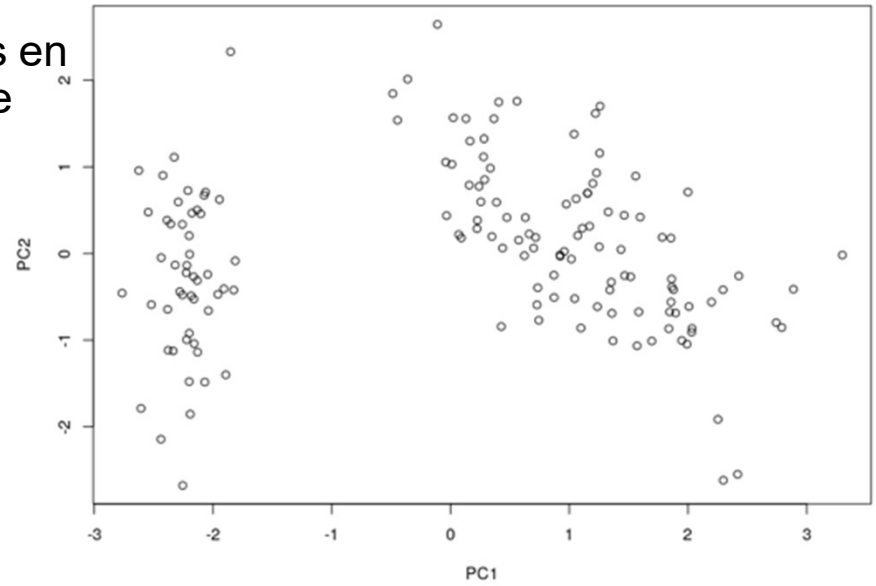
- La fonction **prcomp(x)** calcule les composantes principales de **X** (matrice numérique ou data frame).
- Les arguments **center=T et scale=T** indiquent que la normalisation du **score z** est effectuée pour chaque attribut avant d'appliquer l'ACP.
- La première ligne de code prépare le cadre de données en supprimant la colonne « Spieces » (qui est la cinquième colonne du cadre de données).

Z-score normalisation $\frac{X-\mu}{\sigma}$

Min-Max feature scaling $\frac{X-X_{min}}{X_{max-X_{min}}}$

```
iris_stripped <- iris[,-5]
iris.pca <- prcomp(iris_stripped,
                   center=TRUE, scale=TRUE)

plot(predict(iris.pca))
```



Évaluer les résultats de l'ACP en R

```
> summary(iris.pca)
Importance of components:
                          PC1    PC2     PC3     PC4
Standard deviation     1.7084 0.9560 0.38309 0.14393
Proportion of Variance 0.7296 0.2285 0.03669 0.00518
Cumulative Proportion  0.7296 0.9581 0.99482 1.00000
```