Statistique Exploratoire Multidimensionnelle

TP 1

Le premier TP se compose de deux parties :

Dans la première partie, vous répondrez à un quiz à réponses multiples. Chaque question ne comporte qu'une seule bonne réponse. Si cela est indiqué, vous devrez également justifier brièvement votre réponse à l'endroit réservé à cet effet.

Dans la deuxième partie, vous aurez des questions auxquelles vous devrez répondre en utilisant le langage R ou des calculs à la main. Veuillez fournir le code R dans chacune de vos réponses. Le code R doit être complet et fonctionnel.

Partie 1 - Quiz

Question 1

Je souhaite importer un fichier de données, nommé "data" et stocké dans le répertoire de travail (working directory), en utilisant R. Le fichier de données contient 3 colonnes nommées "UID", "total_sales" et "nr_of_orders". Les valeurs de chaque ligne de données sont séparées par une tabulation "\t" et l'indicateur de point décimal est ','. Quelle commande chargera correctement mes données ?

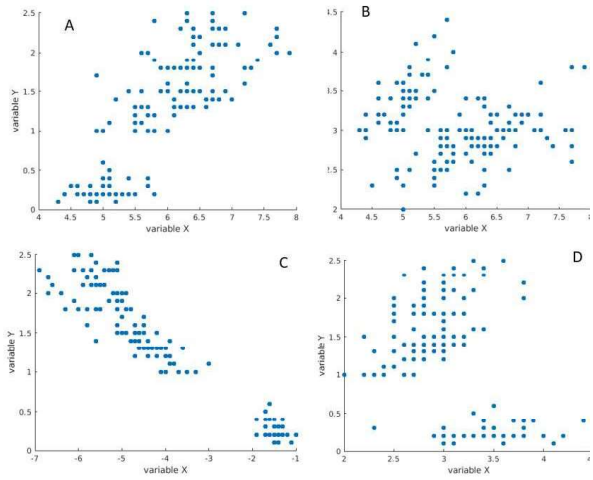
1. read.csv(“data”)
2. read.csv2(“data”)
3. read.table(“data”, header=TRUE, sep=’\t’)
4. read.delim2(“data”)
5. Aucune de ces réponses.

Question 2

Le data frame "df_pats" comporte 4 colonnes nommées "pat_ID", "BP", "Temp" et "gender" qui correspondent respectivement à l'ID du patient, à sa tension artérielle, à sa température et à son sexe. Quelle est la commande correcte pour extraire le sexe et la température (dans cet ordre particulier) de tous les patients dont la tension artérielle est supérieure à 17,5 ?

1. df_pats[df_pats$BP>17.5, 3:4]
2. df_pats[df_pats$BP>17.5, c(“gender”, “Temp”)]
3. df_pats[3:4 , df_pats$BP>17.5]
4. df_pats[c(“gender”, “Temp”) , df_pats$BP>17.5]
5. Aucune de ces réponses.

Question 3



Chaque figure représente les diagrammes de nuage de points de deux variables (X et Y). Sélectionnez l'affirmation vraie.

1. Les variables représentées dans la figure A sont fortement corrélées positivement.
2. Les variables représentées dans la figure B sont faiblement corrélées positivement.
3. Les variables représentées dans la figure C ne sont pas corrélées.
4. Les variables représentées dans la figure D sont faiblement corrélées positivement.

Question 4

Sélectionnez l'affirmation vraie.

1. Soit X une variable qui contient les mesures de la température moyenne journalière à Athènes. La variable X est une variable de ratios (de rapport) et l'analyse des données nous a permis de conclure que la température à Athènes en hiver est 2,3 fois plus froide qu'en été.
2. Nous voulons étudier le type de boisson que les Parisiens préfèrent. Nous encodons les données collectées de la manière suivante : 1 pour les boissons contenant de la caféine, 2 pour les boissons à base de fruits et 3 pour les boissons alcoolisées. Dans ce contexte, nos données consistent en des valeurs discrètes {1, 2, 3} et nous pouvons donc considérer que cet attribut est numérique et qu'il est mesuré sur une échelle d'intervalles.
3. La variable X contient le revenu mensuel d'une population en euros et X est donc mesurée dans l'échelle rations (des rapports). Nous avons décidé d'utiliser les valeurs limites de 1250 et 3500 euros pour définir une nouvelle variable Y, comme suit : les revenus inférieurs à 1250 euros correspondent à des "bas revenus", les revenus compris entre 1250 et 3500 euros correspondent à des "revenus moyens" et les revenus supérieurs à 3500 euros correspondent à des "hauts revenus". Nous avons donc transformé la variable X en variable ordinale Y.
4. La variable X contient le niveau d'éducation d'une population encodée de la manière suivante : 1 - Lycée, 2 - Licence, 3 - Master, 4 - Doctorat. La variable X est mesurée sur l'échelle ordinale et donc, comme elle contient des valeurs numériques, la valeur moyenne de cette variable a un sens.

Justification :

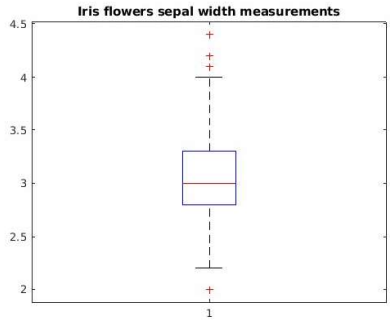
Question 5

La variable X contient 1M points de données mesurant la satisfaction des clients, codée de la manière suivante : 0 - insatisfait, 1 - moyennement satisfait, 2 - très satisfait. Nous calculons la moyenne et l'écart-type des valeurs de X, qui sont respectivement 1 et 0. Comment comprenez-vous la variable X ?

1. La variable X est clairement mesurée sur une échelle ordinale, les valeurs de la moyenne et de l'écart-type n'ont donc aucune signification et je ne peux donc faire aucune déclaration sur la variable X.
2. La variable X contient des valeurs manquantes et c'est la raison pour laquelle l'écart-type est égal à 0.
3. 50 % des clients sont insatisfaits ou moyennement satisfaits.
4. 100 % des clients sont moyennement satisfaits.

Justification :

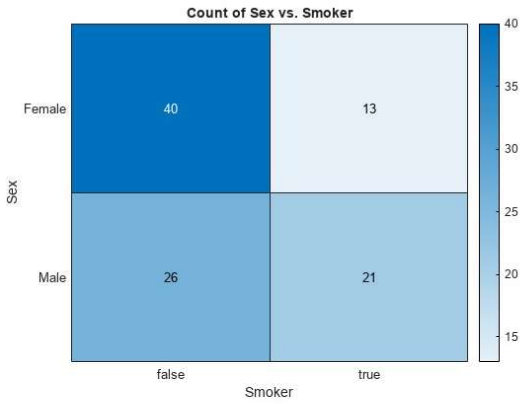
Question 6



Le diagramme en boîte reprend les mesures de la largeur des sépales de 150 fleurs d'iris. Quel type d'information pouvons-nous extraire de ce diagramme en boîte ? (Cochez la bonne réponse)

1. 50% des fleurs observées ont une largeur de sépale inférieure ou égale à 2,8.
2. La valeur moyenne de la variable est 3.
3. Il n'y a pas de valeurs extrêmes dans ces mesures.
4. 25% des fleurs ont une largeur de sépale supérieure à 3,3 et un quart des fleurs ont une largeur de sépale inférieure ou égale à 2,8.

Question 7



Le tableau de contingence reprend les données de deux variables catégorielles (Sexe, Fumeur). Sélectionnez l'affirmation correcte.

1. 21% des hommes sont fumeurs.
2. 44,68% des hommes sont fumeurs.
3. 53% de l'échantillon sont des hommes.
4. Il est certain que les hommes fument plus que les femmes.

Question 8

Sélectionnez l'affirmation vraie

1. L'asymétrie (skewness) de la variable X est de 0. Je peux donc conclure que la distribution de la variable X est définitivement normale.
2. L'asymétrie (skewness) de la variable X est positive ; je peux donc conclure que la distribution de X est plus pentue à droite.
3. La moyenne de la variable X est inférieure à son mode ; je peux donc conclure que X a une asymétrie positive.
4. Si la variable X a une asymétrie (skewness) positive, alors le mode de la variable est inférieur à sa moyenne.

Question 9

La variable X contient les mesures {1, 5, 3, 9, 20, 3, 5, 3, 2, 10}. Sélectionnez l'affirmation vraie.

1. La valeur moyenne de X X est 6,10.
2. La valeur médiane de X est 3.
3. Le mode de X est 6,10.
4. L'asymétrie de est négative.

Question 10

Que fait le code ci-dessous ?

```
fun <- function(x){
  len = length(x)
  if (len%%2 == 0)
    res = 0.5*(x[len/2]+x[(len/2)+1])
  else
    res = x[(len+1)/2]
  res
}
d = c(1, 2, 3)
fun(d)
```

Ce code produit une erreur.

Ce code calcule la valeur moyenne du vecteur d.

Ce code calcule le mode du vecteur d.

Ce code calcule la médiane du vecteur d.

Partie 2

Initiation à la langage R

1. Ecrivez un programme R pour créer trois vecteurs a,b,c avec 3 entiers dans chacun (1-9). Combinez les trois vecteurs pour obtenir une matrice 3×3 où chaque colonne représente un vecteur. Imprimez le contenu de la matrice
2. Importez le fichier « Table0.txt. »

```
Alex    25      177     57      F
Lilly   31      163     69      F
Mark    23      190     83      M
Oliver  52      179     75      M
Martha  76      163     70      F
Lucas   49      183     83      M
Caroline 26     164     53      F
```

   a) Changez les noms des colonnes en « Nom », « Age », « Taille », « Poids » et « Sexe ».
   b) Changez les noms des lignes pour qu'ils soient identiques aux valeurs de la variable « Nom », et supprimez la variable « Nom ».
3. Importez le fichier « Table1.txt ».
   a) Combien de lignes et de colonnes contient-il ?
   b) Réimportez le fichier et faites en sorte que la variable « Nom » soit le nom des lignes.

Assurez-vous que vous lisez les variables comme des caractères et non comme des facteurs.

```
Name    Age     Height  Weight  Sex
Alex    25      177     57      F
Lilly   31      163     69      F
Mark    23      190     83      M
Oliver  52      179     75      M
Martha  76      163     70      F
Lucas   49      183     83      M
Caroline 26     164     53      F
```

4. Lisez l'ensemble de données « Cereals.csv », examinez les premières lignes avec « head » et inspectez les types de données des variables dans le cadre de données avec « str ». Décrivez le jeu de données.
   a) Ajoutez une nouvelle variable à l'ensemble de données, appelée "totalcarb", qui est la somme de "carbo" et "sugars".
   b) Combien de céréales dans l'image de données sont des céréales "hot" ? Conseil : prenez un sous-ensemble approprié des données, puis comptez le nombre d'observations dans le sous-ensemble.
   c) Combien de fournisseurs uniques sont inclus dans l'ensemble de données ? Indice : utilisez la « length » et « unique »
   d) Prenez un sous-ensemble du data frame contenant uniquement le fournisseur "K" (Kellogg's).
   e) Prenez un sous-ensemble du jeu de données de toutes les céréales qui contiennent moins de 80 calories ET plus de 20 unités de vitamines.

f) Prenez un sous-ensemble du data frame contenant les céréales qui contiennent au moins 1 unité de sucre, et ne conservez que les variables "Cereal.name", "calories" et "vitamines". Inspectez ensuite les premières lignes du tableau de données avec « head ».
g) Pour l'un des sous-ensembles ci-dessus, sauvegardez un nouveau fichier CSV sur le disque à l'aide de write.csv
h) Renommez la colonne "Fournisseur" en "Producteur".

5. Chargez l'ensemble de données « islands » et obtenez le nombre total d'observations. Décrivez le jeu de données.

Mesures de tendance centrale.

Obtenez les statistiques suivantes sur les îles

a. Moyenne
b. Médiane

En utilisant la fonction « range », obtenez les valeurs suivantes :

a. Taille de la plus grande île
b. Taille de la plus petite île

Mesures de dispersion.

Trouvez les valeurs suivantes pour les îles :

a. Écart-type
b. Quantiles. En utilisant la fonction quantile, obtenez un vecteur comprenant les quantiles suivants :
   i. 0 %, 25 %, 50 %, 75 %, 100 %
   ii. ii) 0,5 %, 95 %.

L'intervalle interquartile.

a) Trouvez l'intervalle interquartile des îles.

Créez un histogramme des îles avec les propriétés suivantes.

A. Indiquer la fréquence de chaque groupe
B. Indiquer la proportion de chaque groupe

Créez des diagrammes en boîte avec les conditions suivantes

C. Incluant les valeurs aberrantes
D. Sans les valeurs aberrantes

6. Chargez l'ensemble de données "sales". Supposons que l'on décide de classer sales$sales_totals en trois groupes – « small, medium, et big » - en fonction du montant des ventes.

Créez une nouvelle variable factorielle ordinale appelée "spender" qui contiendra ces catégories comme suit : pour les ventes totales inférieures à 100, le groupe est appelé « small », supérieur à

100 et inférieur à 500, « medium » et supérieur à 500, il est appelé « big ». Ajoutez la variable "spender" au data frame existant.