Statistique Exploratoire Multidimensionnelle

TP 2

Vous aurez des questions auxquelles vous devrez répondre en utilisant le langage R ou des calculs à la main. Veuillez fournir le code R dans chacune de vos réponses. Le code R doit être complet et fonctionnel.

1. Représentations tabulaires et graphiques

Pour ce sujet, vous utiliserez l'ensemble de données intégrées de R « mtcars » afin de répondre aux points suivants. (10 points)

1. Créez un tableau de contingence, en utilisant R, avec les fréquences absolues pour les attributs « cyl » et « am ». (4 points)
2. Créez un histogramme avec des fréquences absolues pour l'attribut « wt » en utilisant cinq bins. (3 points)
3. Créez un diagramme en boîte pour l'attribut "poids" (3 points).

2. Correlation

On vous donne les vecteurs suivants a = [11, 15, 23, 46, 52, 75] et w = [34, 49, 58, 62, 69, 64], qui représentent respectivement les âges et les poids d'un échantillon de personnes. (15 points)

1. Utilisez un stylo et du papier pour calculer la corrélation entre « a » et « w » en utilisant le coefficient de corrélation de Pearson. Vérifiez votre réponse avec R. Incluez vos calculs, le code R et une interprétation du résultat. (5 points)
2. Utilisez un stylo et du papier pour calculer la corrélation entre a et w en utilisant le coefficient de corrélation de rang de Spearman. Vérifiez votre réponse avec R. Incluez vos calculs, le code R et une interprétation du résultat. (5 points)
3. Dessinez un nuage de points dans R pour vérifier visuellement s'il existe une relation entre « a » (axe des x) et « w » (axe des y). Incluez les étiquettes des deux axes. (5 points)

3. Data Frames

Pour ce sujet, nous utiliserons l'ensemble de données « state.x77 » de R afin de répondre aux points suivants. (15 points)

1. Vérifiez le type de données de l'ensemble de données et assurez-vous qu'il s'agit d'un data frame. Si ce n'est pas le cas, convertissez-le en data frame. (3 points)
2. Créez un nouvel attribut appelé « states » et attribuez-lui les noms de ligne du data frame. Ensuite, supprimez les noms de ligne de l'ensemble de données.

3. Découvrez combien d'États ont un revenu (par habitant) supérieur à 4 300 $ et une population supérieure à 1 000 (en milliers) d'habitants. (3 points)

4. Imprimez les 5 premiers États, qui affichent les revenus les plus élevés, après avoir classé la base de données par ordre décroissant sur la base de l'attribut « Revenu ». (3 points)

5. Créez un nouvel attribut ordinal appelé « frost_cat » qui prend les valeurs « faible », « intermédiaire » et « élevé » correspondant aux intervalles suivants (-1, 30], (30, 90] et (90, 190]. Imprimez les états de la catégorie « faible ». (3 points)