TP3-ACP

Mathura SANTHALINGAM (12212867)

pour créer un bloc de code -> cmd + opt + I pour executer un bloc de code : cmd + entrée

1. Préparation et calcul de l'ACP

Question 1 :

```
# install.packages("FactoMineR")
# install.packages("factoextra")
library(FactoMineR)
library(factoextra)
```

```
## Loading required package: ggplot2
```

```
## Welcome to factoextra!
```

```
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/library/principal-component-methods
```

Question 2 :

```
data("decathlon2")
summary(decathlon2)
```

```
##      X100m         Long.jump        Shot.put       High.jump
##  Min.   :10.44   Min.   :6.800   Min.   :12.68   Min.   :1.860
##  1st Qu.:10.84   1st Qu.:7.210   1st Qu.:14.17   1st Qu.:1.930
##  Median :10.97   Median :7.310   Median :14.57   Median :1.980
##  Mean   :10.99   Mean   :7.365   Mean   :14.54   Mean   :1.998
##  3rd Qu.:11.13   3rd Qu.:7.545   3rd Qu.:15.01   3rd Qu.:2.080
##  Max.   :11.64   Max.   :7.960   Max.   :16.36   Max.   :2.150
##      X400m         X110m.hurdle       Discus         Pole.vault
##  Min.   :46.81   Min.   :13.97   Min.   :37.92   Min.   :4.400
##  1st Qu.:48.70   1st Qu.:14.15   1st Qu.:42.27   1st Qu.:4.660
##  Median :49.20   Median :14.34   Median :44.72   Median :4.900
##  Mean   :49.31   Mean   :14.50   Mean   :44.85   Mean   :4.836
##  3rd Qu.:49.86   3rd Qu.:14.87   3rd Qu.:46.93   3rd Qu.:5.000
##  Max.   :51.16   Max.   :15.67   Max.   :51.65   Max.   :5.400
##     Javeline         X1500m           Rank            Points       Competition
##  Min.   :50.31   Min.   :262.1   Min.   : 1.000   Min.   :7313   Decastar:13
##  1st Qu.:55.32   1st Qu.:271.6   1st Qu.: 4.000   1st Qu.:8000   OlympicG:14
##  Median :57.19   Median :278.1   Median : 7.000   Median :8084
##  Mean   :58.32   Mean   :278.5   Mean   : 7.444   Mean   :8119
##  3rd Qu.:62.05   3rd Qu.:283.6   3rd Qu.:10.500   3rd Qu.:8236
##  Max.   :70.52   Max.   :301.5   Max.   :19.000   Max.   :8893
```

```
ncol(decathlon2)
```

```
## [1] 13
```

Il y a donc 13 variables dans ce jeu de données.

Question 3 : Les variables qui correspondent aux 10 différents sports (situés dans les colonnes 1 à 10) sont : X100m, Long.jump, Shot.put, High.jump, X400m, X110m.hurdle, Discus, Pole.vault, Javeline et X1500m.

```
les23_prems <- decathlon2[1:23, 1:10]
les23_prems
```

	X100m <dbl>	Long.jump <dbl>	Shot.put <dbl>	High.jump <dbl>	X400m <dbl>	X110m.hurdle <dbl>	Discus <dbl>
SEBRLE	11.04	7.58	14.83	2.07	49.81	14.69	43.75
CLAY	10.76	7.40	14.26	1.86	49.37	14.05	50.72
BERNARD	11.02	7.23	14.25	1.92	48.93	14.99	40.87
YURKOV	11.34	7.09	15.19	2.10	50.42	15.31	46.26
ZSIVOCZKY	11.13	7.30	13.48	2.01	48.62	14.17	45.67
McMULLEN	10.83	7.31	13.76	2.13	49.91	14.38	44.41
MARTINEAU	11.64	6.81	14.57	1.95	50.14	14.93	47.60
HERNU	11.37	7.56	14.41	1.86	51.10	15.06	44.99
BARRAS	11.33	6.97	14.09	1.95	49.48	14.48	42.10
NOOL	11.33	7.27	12.68	1.98	49.20	15.29	37.92

1-10 of 23 rows | 1-8 of 11 columns Previous **1** 2 3 Next

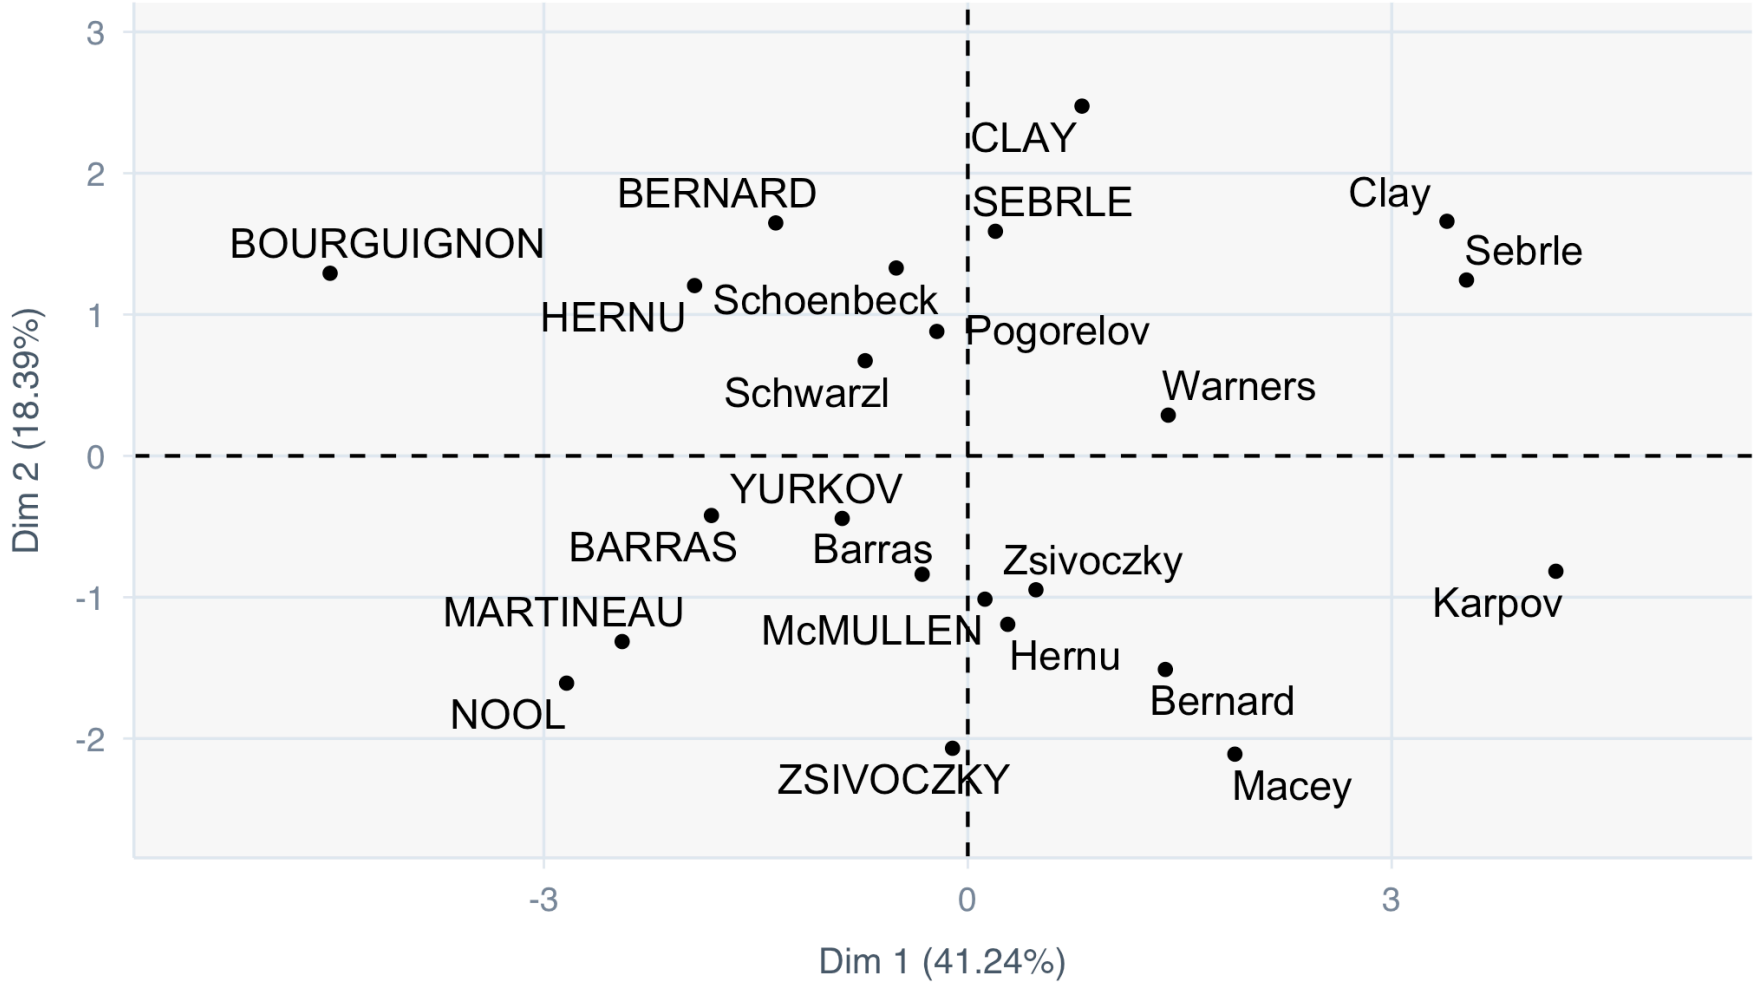
Question 4 :

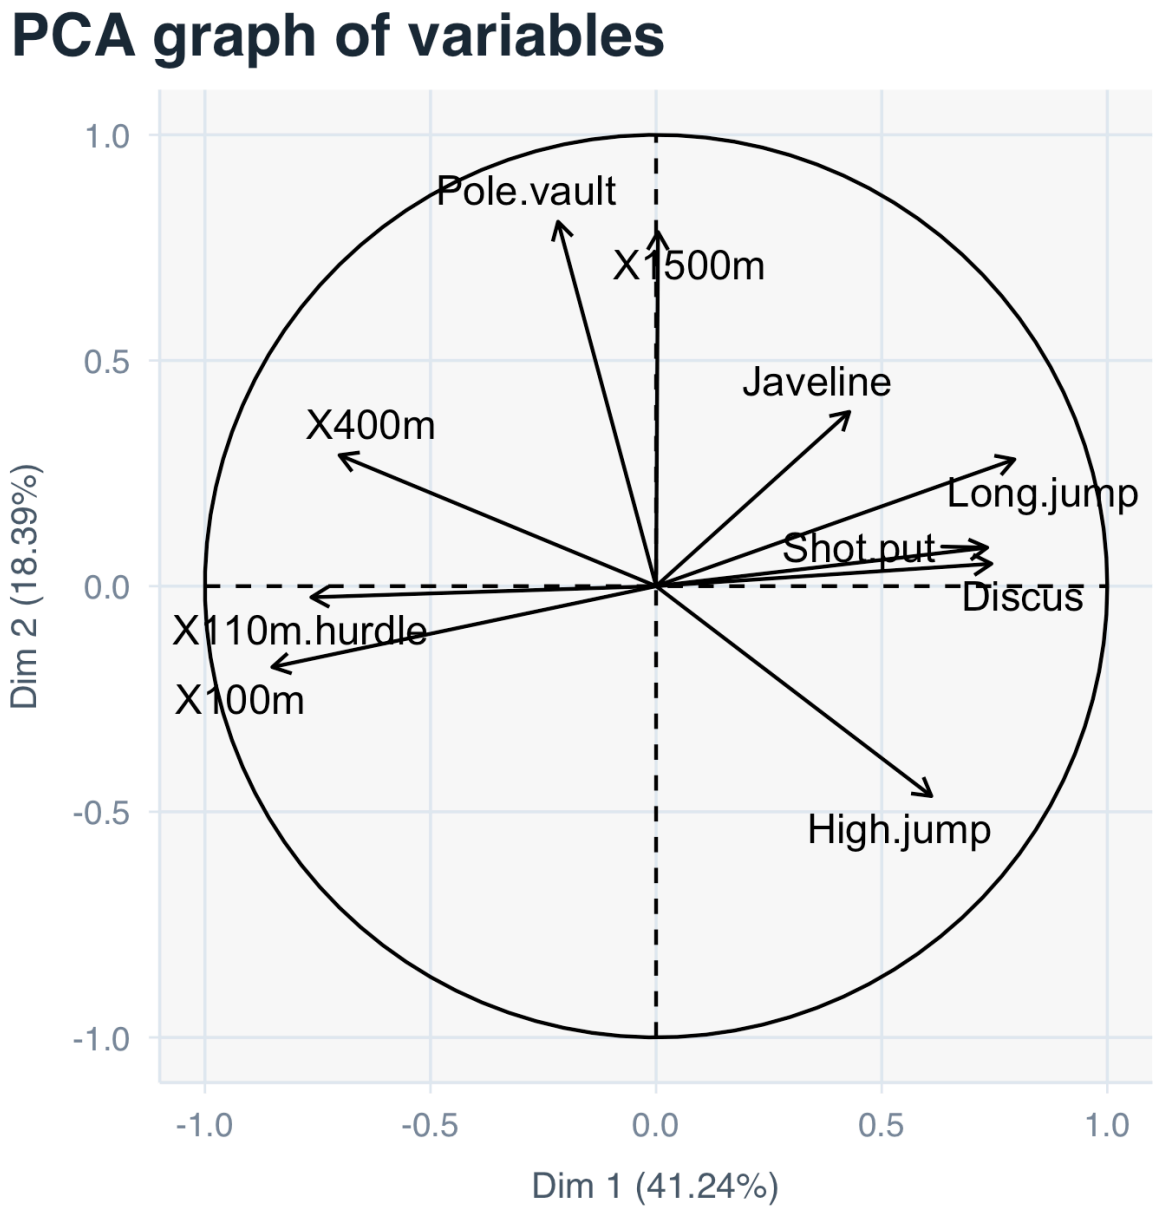
Les paramètres les plus importants de la fonction PCA() du package FactoMineR sont :

- X : un data frame avec les données sur lesquelles l'ACP doit être appliquée
- scale.unit : si TRUE alors les données sont centrées et réduites avant l'ACP (TRUE par défaut)
- ncp : le nombre de dimensions (composantes principales) gardées dans les résultats (5 par défaut)
- graph : si TRUE, les graphiques de base de l'ACP s'affichent automatiquement (TRUE par défaut)

```
decathlon_pca <- PCA(les23_prems, scale.unit = TRUE, graph = TRUE)
```

PCA graph of individuals






```
print(decathlon_pca)
```

```
## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 23 individuals, described by 10 variables
## *The results are available in the following objects:
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

2. Interprétation et visualisation

Question 5 :

- get_eigenvalue() : donne les valeurs propres, le pourcentage de variance expliquée et la variance cumulée pour chaque composante principale -> paramètre important : le résultat de l'ACP
- fviz_eig() : donne un scree plot pour visualiser les valeurs propres ou la proportion de variances -> paramètres importants : objet ACP, addlabels qui affiche les pourcentages sur le graphique et ncp qui est le nombre de dimensions à afficher
- get_pca_ind() : donne les résultats statistiques spécifiques aux individus (coordonnées, la qualité de représentation cos2, les contributions) -> paramètre important : résultalt de PCA
- get_pca_var() : donne les résultats statistiques spécifiques aux variables (coordonnées, cos2, contributions) -> paramètre important : résultalt de PCA

fviz_pca_ind() : trace le graphique représentant les individus dans le nouvel espace des composantes principales -> paramètres importants : X, col.ind (pour colorer les individus), repel (évite le chevauchement des étiquettes)

fviz_pca_var() : trace le cercle des corrélations illustrant les relations entre les variables -> paramètres importants : X, col.var, repel

fviz_pca_biplot() : donne un biplot superposant les individus et les variables sur le même graphique -> paramètres clés : X, repel

Question 6 :

```
valeurs_propres <- get_eigenvalue(decathlon_pca)
print(valeurs_propres)
```

```
##       eigenvalue variance.percent cumulative.variance.percent
## Dim.1  4.1242133        41.242133                    41.24213
## Dim.2  1.8385309        18.385309                    59.62744
## Dim.3  1.2391403        12.391403                    72.01885
## Dim.4  0.8194402         8.194402                    80.21325
## Dim.5  0.7015528         7.015528                    87.22878
```

Question 7 :

```
var_3_prems <- valeurs_propres[3, "cumulative.variance.percent"]
print(var_3_prems)
```

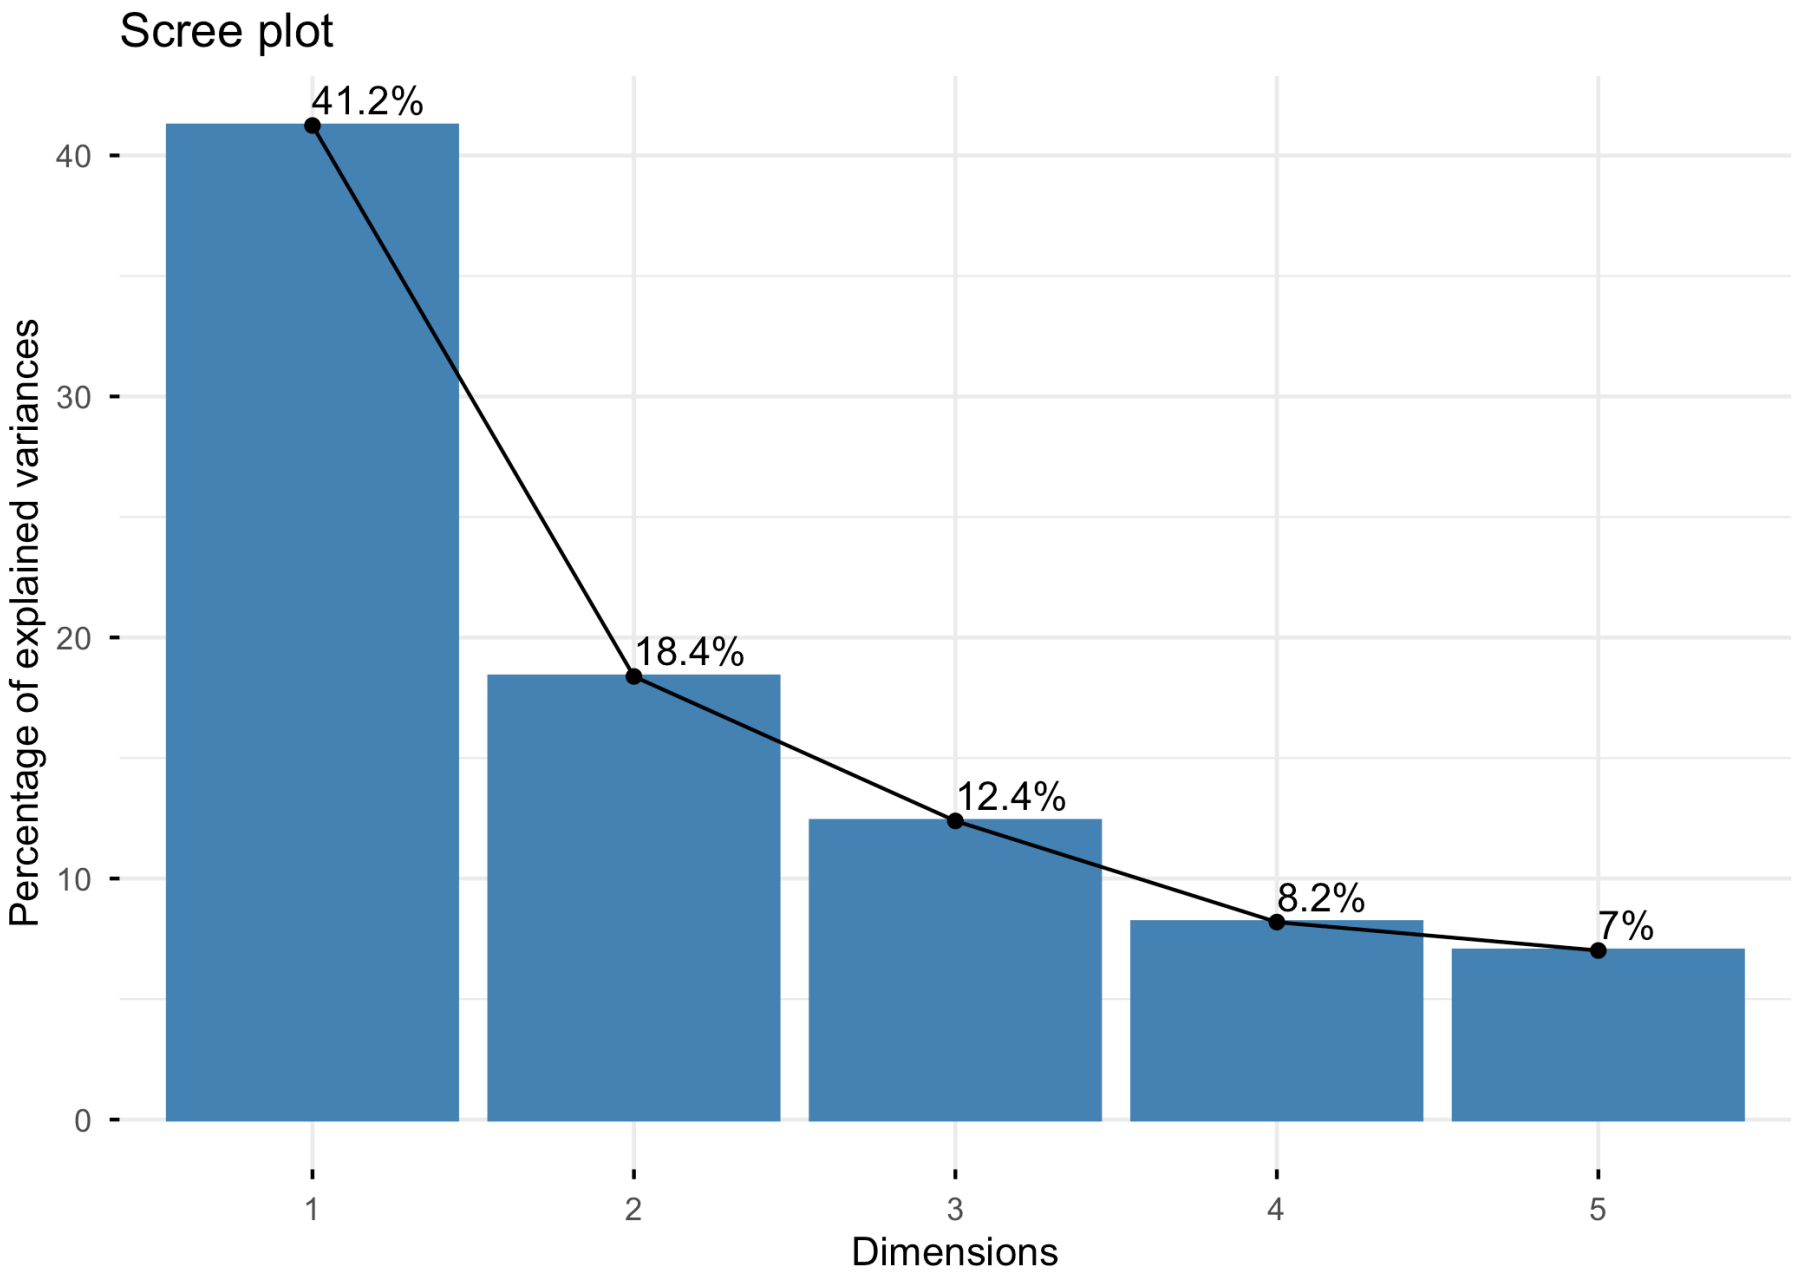
```
## [1] 72.01885
```

Question 8 : D'après la question 6, on voit que la valeur propre de la 4ème composante principale est inférieure à 1 donc elle résume moins d'information qu'une seule variable initiale donc on considère que cette composante principale n'est plus suffisamment significative.

Question 9 :

```
fviz_eig(decathlon_pca, addlabels = TRUE)
```

```
## Warning: This FactoMineR PCA result contains only 5 eigenvalues and does not
## include the complete spectrum. Refit the PCA with a larger `ncp` before drawing
## a complete scree plot.
```



Les dimensions 4 et 5 n'ajoutent que des proportions marginales donc à partir de ce screeplot j'aurais retenu que 3 CP.

Question 10 :

```
matrices <- get_pca_var(decathlon_pca)
print(matrices)
```

```
## Principal Component Analysis Results for variables
##  ===================================================
##   Name       Description
## 1 "$coord"   "Coordinates for the variables"
## 2 "$cor"     "Correlations between variables and dimensions"
## 3 "$cos2"    "Cos2 for the variables"
## 4 "$contrib" "contributions of the variables"
```

```
str(matrices)
```

```
## List of 4
##  $ coord  : num [1:10, 1:5] -0.851 0.794 0.734 0.61 -0.702 ...
##   ..- attr(*, "dimnames")=List of 2
##   .. ..$ : chr [1:10] "X100m" "Long.jump" "Shot.put" "High.jump" ...
##   .. ..$ : chr [1:5] "Dim.1" "Dim.2" "Dim.3" "Dim.4" ...
##  $ cor    : num [1:10, 1:5] -0.851 0.794 0.734 0.61 -0.702 ...
##   ..- attr(*, "dimnames")=List of 2
##   .. ..$ : chr [1:10] "X100m" "Long.jump" "Shot.put" "High.jump" ...
##   .. ..$ : chr [1:5] "Dim.1" "Dim.2" "Dim.3" "Dim.4" ...
##  $ cos2   : num [1:10, 1:5] 0.724 0.631 0.539 0.372 0.492 ...
##   ..- attr(*, "dimnames")=List of 2
##   .. ..$ : chr [1:10] "X100m" "Long.jump" "Shot.put" "High.jump" ...
##   .. ..$ : chr [1:5] "Dim.1" "Dim.2" "Dim.3" "Dim.4" ...
##  $ contrib: num [1:10, 1:5] 17.54 15.29 13.06 9.02 11.94 ...
##   ..- attr(*, "dimnames")=List of 2
##   .. ..$ : chr [1:10] "X100m" "Long.jump" "Shot.put" "High.jump" ...
##   .. ..$ : chr [1:5] "Dim.1" "Dim.2" "Dim.3" "Dim.4" ...
##  - attr(*, "class")= chr [1:2] "factoextra" "pca_var"
```

Question 11 : Un cercle de corrélation est un graphique pour visualiser la projection des variables initiales sur un plan défini par deux composantes principales.

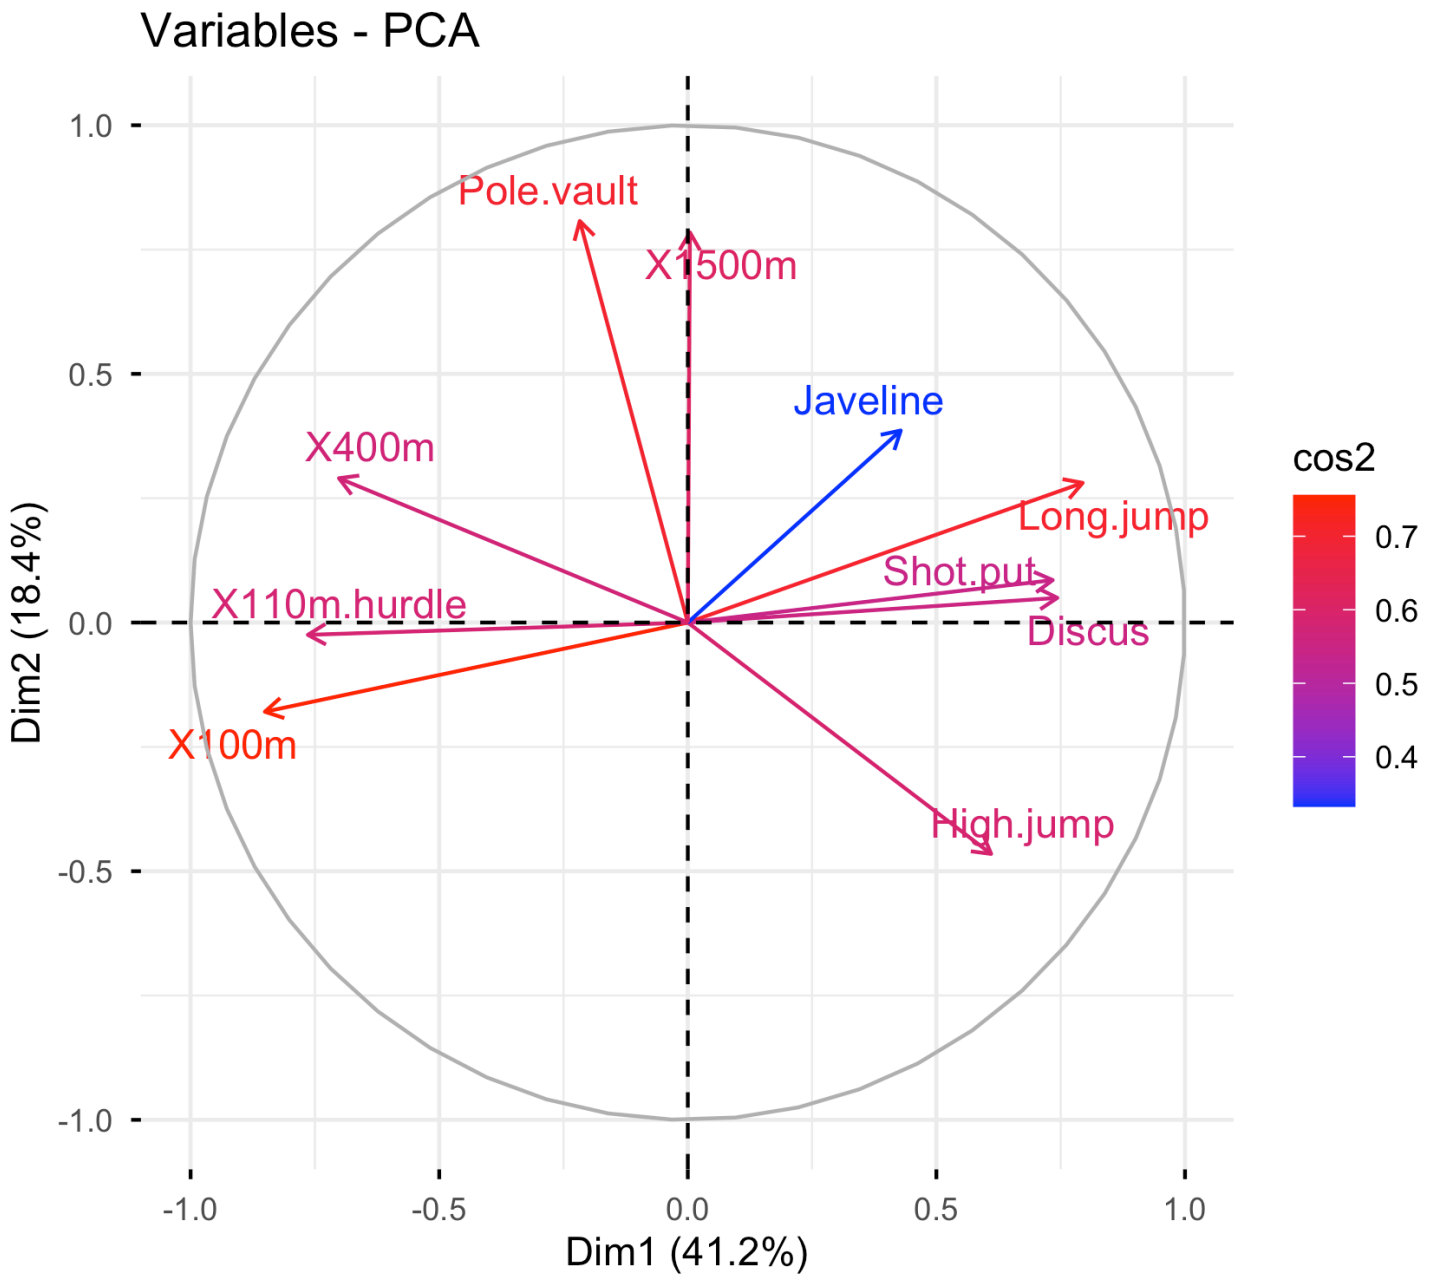
Il permet de lire visuellement plusieurs informations : - corrélation avec les CP : la projection de l'extrémité d'une flèche sur les axes horizontal ou vertical donne la valeur de la corrélation de cette variable avec l'axe. - corrélation entre les variables : l'angle entre deux vecteurs donne leur degré de corrélation : un angle très petit signifie une corrélation positive forte, un angle droit indique une absence de corrélation et un angle plat indique une corrélation négative forte - qualité de représentation : plus la pointe d'une flèche s'approche de la circonférence du cercle (de rayon 1), mieux la variable est représentée et résumée par les deux composantes du graphique

Question 12 : Les données pour tracer le cercle de corrélation sont les coordonnées des variables sur les axes principaux qui sont leurs coefficients de corrélation avec ces axes

Ces informations sont dans la matrice de la question 10 (matrices$cor) (get_pca_var())

Question 13 :

```
fviz_pca_var(decathlon_pca, col.var = "cos2", gradient.cols = c("blue", "red"), repel = TRUE)
```


Variables - PCA
Pole.vault
X1500m
Javeline
X400m
Long.jump
Shot.put
X110m.hurdle
Discus
X100m
High.jump
cos2
0.7
0.6
0.5
0.4
1.0
0.5
0.0
-0.5
-1.0
Dim2 (18.4%)
-1.0
-0.5
0.0
0.5
1.0
Dim1 (41.2%)

Question 14 :

- Corrélation positive des courses : les flèches des épreuves X100m, X400m et X110m.hurdle pointent dans la même direction avec des angles très petits entre elles donc FORTE CORRÉLATION
- Groupe de force/lancer : les variables Shot.put et Discus forment un second groupe très resserré pointant vers la droite
- Indépendance : l'angle entre l'axe des courses de vitesse et la flèche du saut à la perche (Pole.vault) est très proche d'un angle droit donc FAIBLE CORRÉLATION entre ces types d'épreuves
- Qualité de représentation : L'échelle de couleur confirme que la majorité des épreuves sont bien représentées, leurs flèches sont longues, proches de la bordure du cercle et colorées en rouge mais la variable Javeline est moins bien capturée car sa flèche est plus courte et colorée en bleu

Question 15 : La qualité de représentation mesure à quel point une variable initiale est fidèlement projetée sur un axe

La matrice `$cos2` contient le cosinus au carré de l'angle entre le vecteur de la variable d'origine et sa projection sur la composante principale :

- `$cos2` proche de 1 -> la variable est très bien représentée par cette composante
- `$cos2` proche de 0 -> mauvaise représentation sur cet axe La somme des `$cos2` d'une variable sur l'ensemble de toutes les composantes principales est toujours égale à 1.

Question 16 :

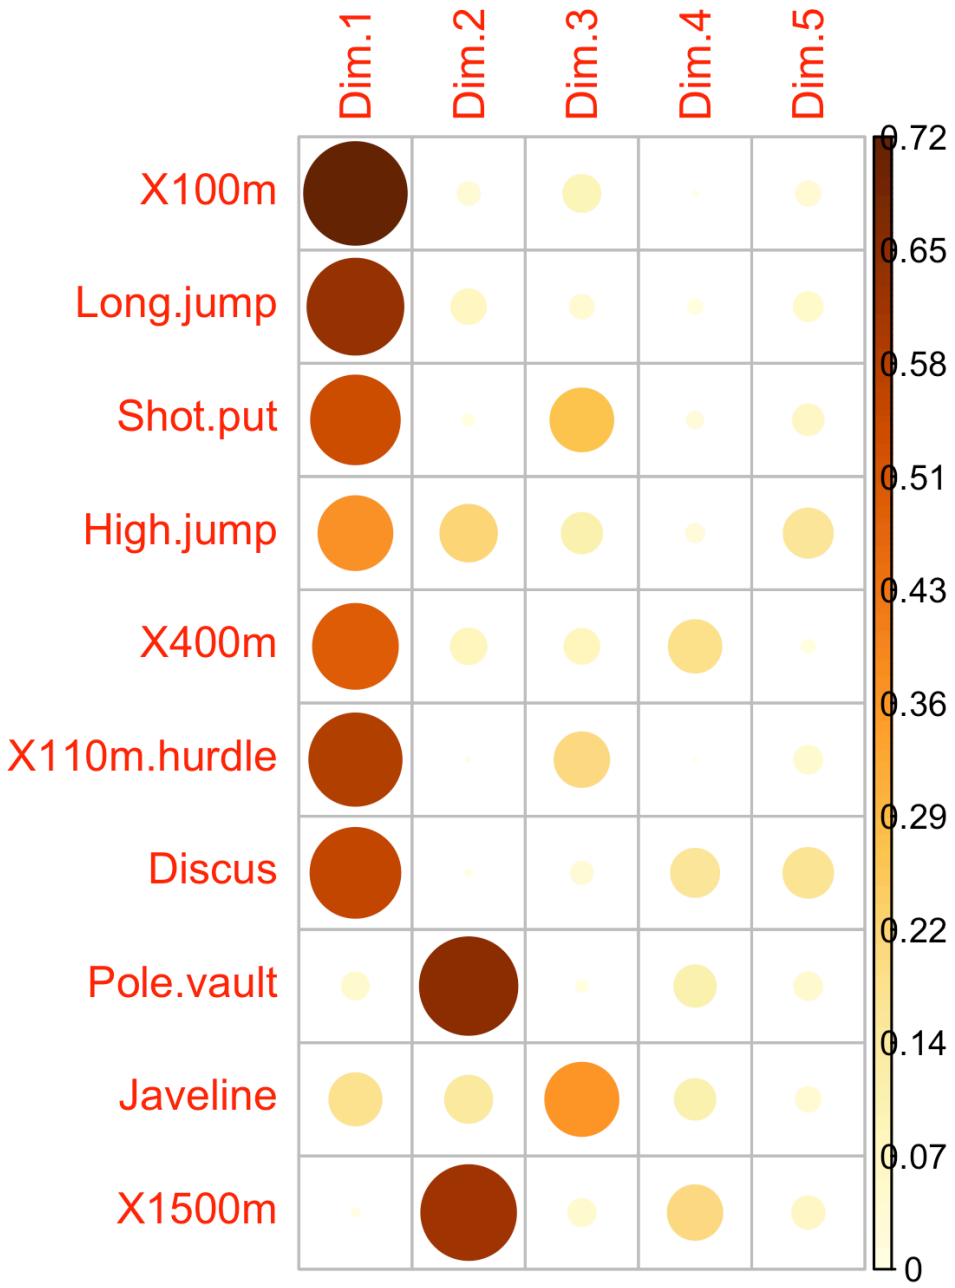
```
# install.packages("corrplot")
library(corrplot)
```

```
## corrplot 0.95 loaded
```

La fonction corrplot() remplace les valeurs numériques des matrices de corrélation par des éléments graphiques (comme des cercles ou des carrés) dont la taille et l'intensité de la couleur sont proportionnelles à la valeur dans la matrice. Cela permet d'identifier les tendances sans lire les chiffres.

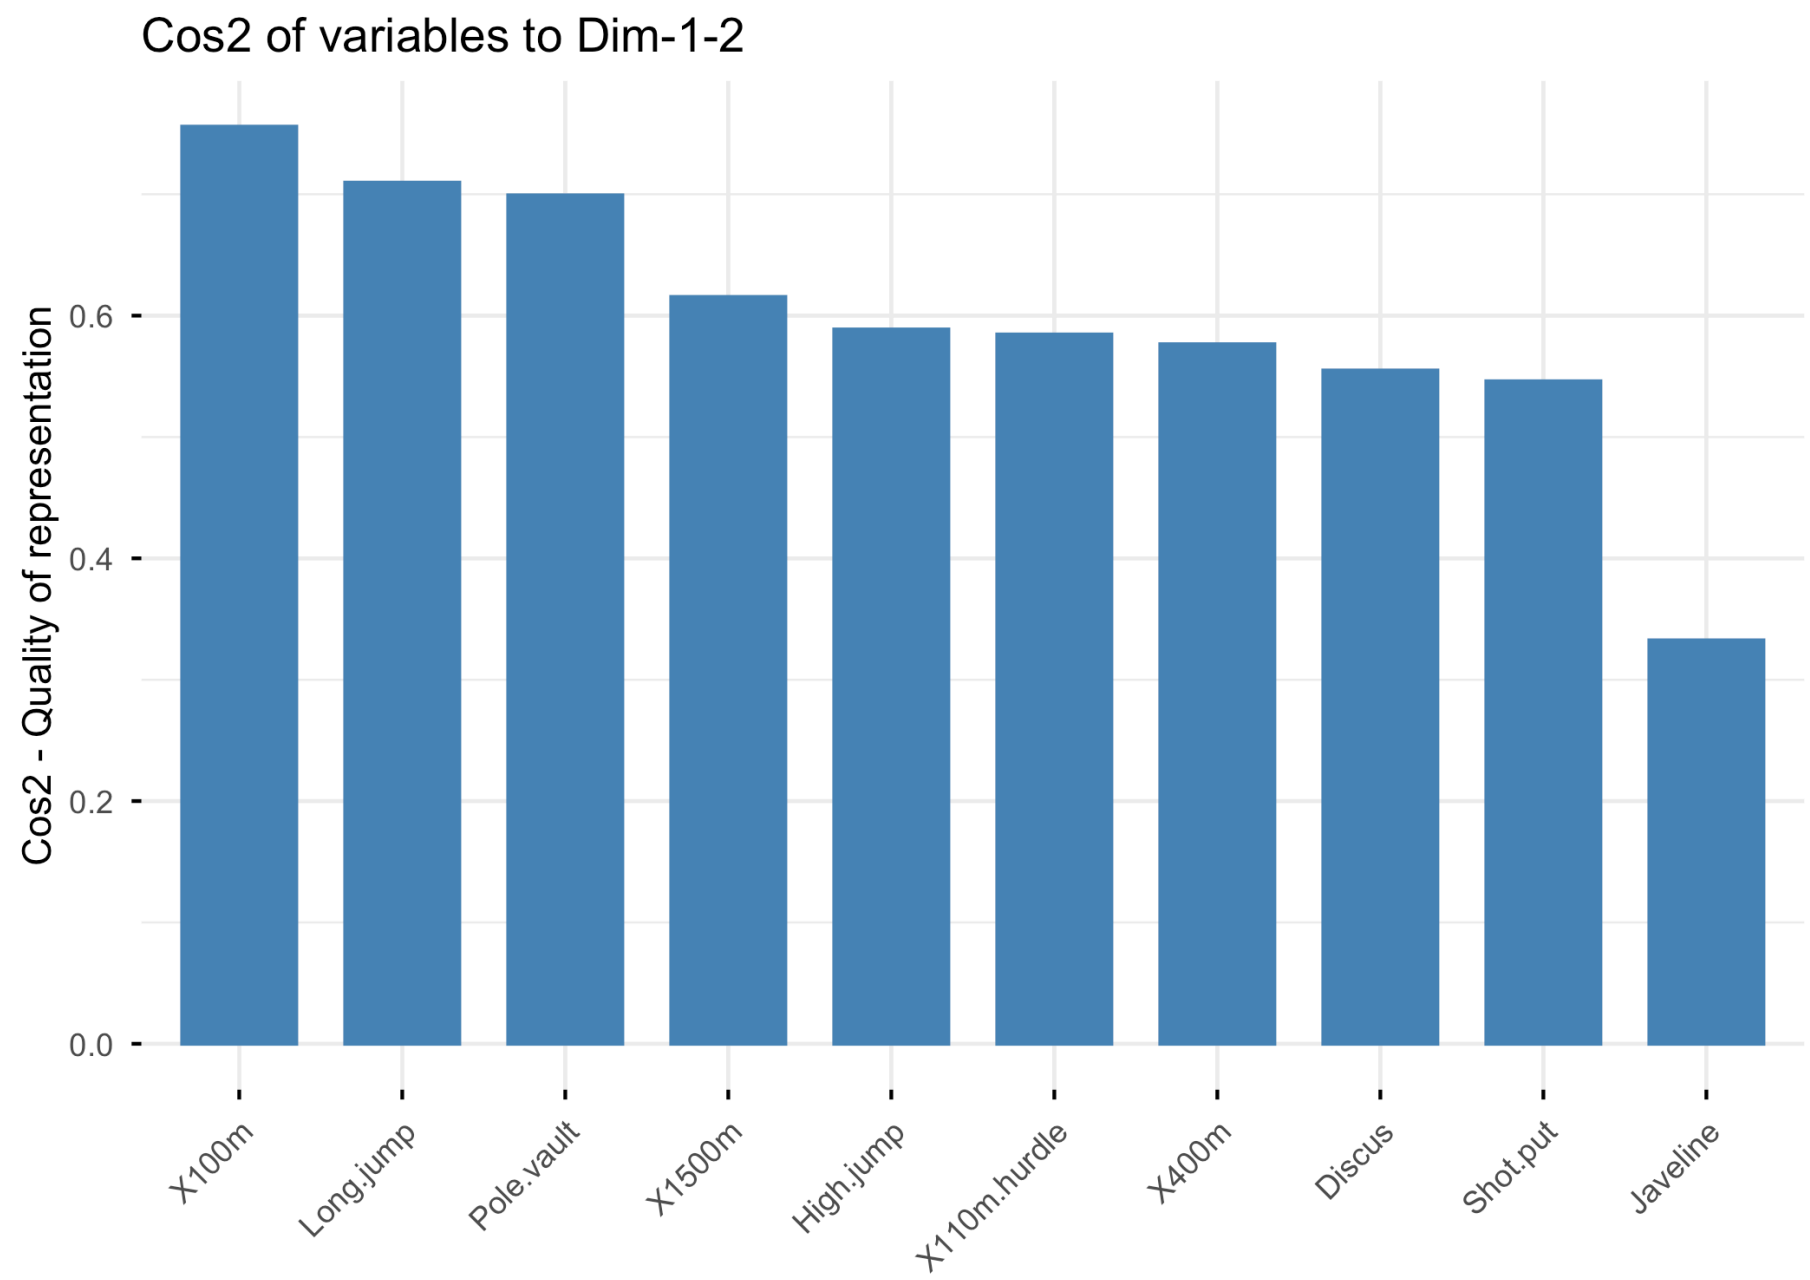
Question 17 :

```
corrplot(matrices$cos2,  method = "circle", is.corr = FALSE)
```


Dim.1
Dim.2
Dim.3
Dim.4
Dim.5
X100m
Long.jump
Shot.put
High.jump
X400m
X110m.hurdle
Discus
Pole.vault
Javeline
X1500m
0.72
0.65
0.58
0.51
0.43
0.36
0.29
0.22
0.14
0.07
0

Question 18 :

```
fviz_cos2(decathlon_pca, choice = "var", axes = 1:2)
```


Cos2 of variables to Dim-1-2
Cos2 - Quality of representation
0.0
0.2
0.4
0.6
X100m
Long.jump
Pole.vault
X1500m
High.jump
X110m.hurdle
X400m
Discus
Shot.put
Javeline

Question 19 :

- Variables les mieux représentées : Les épreuves X100m et Long.jump ont les barres les plus hautes, avec un `$cos^2` supérieur ou égal à 0.7. Elles sont donc très bien résumées par les dimensions 1 et 2.
- Pole.vault : l'épreuve du saut à la perche est en réalité très bien représentée sur ce premier plan, elle se classe en 3ème position des variables les mieux capturées, avec un `cos^2` proche de 0.7
- Variable la moins bien représentée : l'épreuve Javeline est bien la variable la moins bien capturée par ces deux premières dimensions, avec le `$cos^2` le plus faible (autour de 0.35)

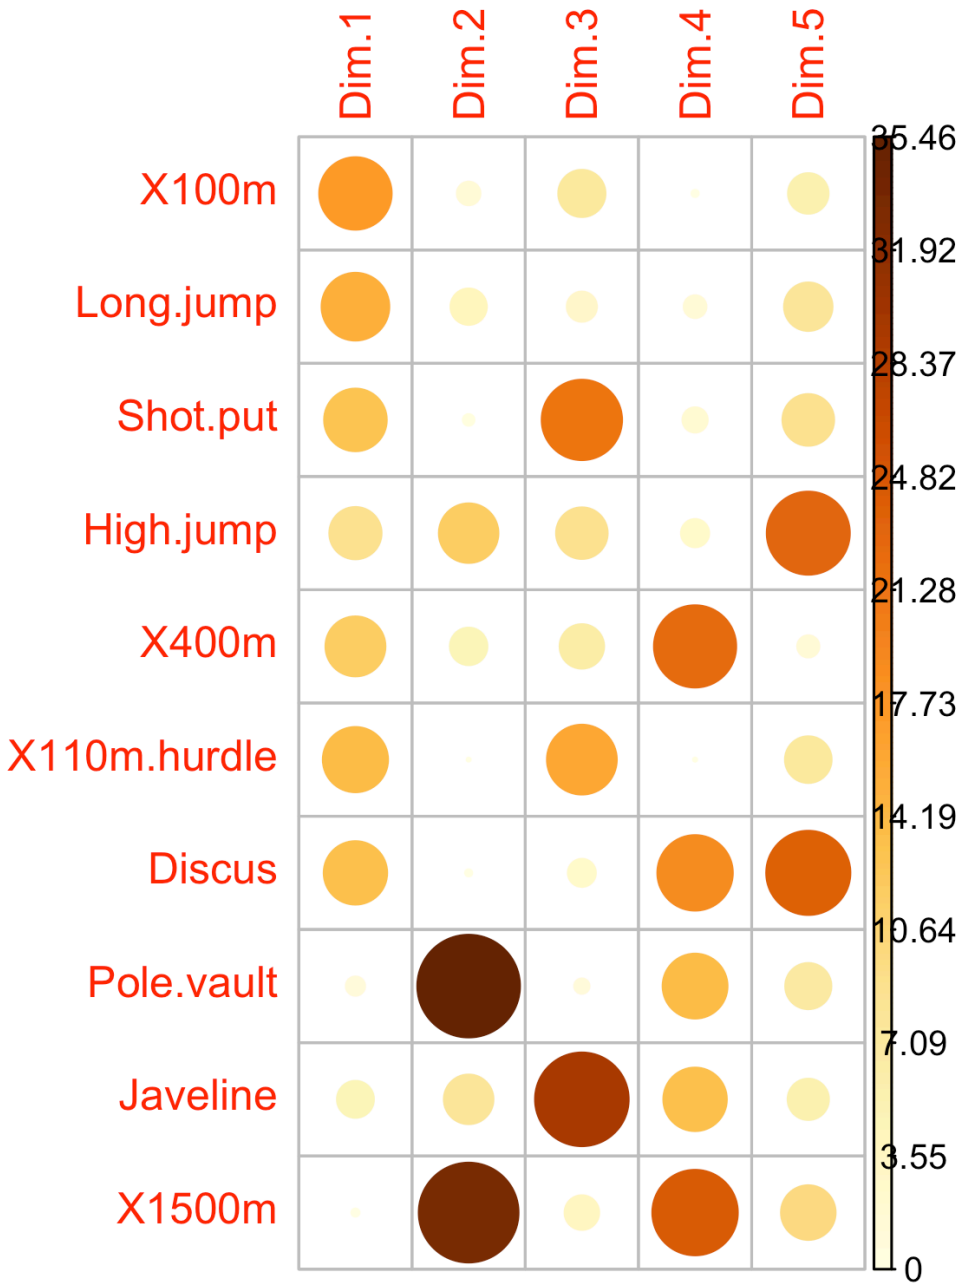
Donc Javeline est la principale variable nécessitant d'autres dimensions pour être correctement expliquée.

```
head(matrices$contrib, 4)
```

```
##               Dim.1      Dim.2     Dim.3     Dim.4     Dim.5
## X100m     17.544293  1.7505098  7.338659 0.1375524  5.389252
## Long.jump 15.293168  4.2904162  2.930094 1.6248594  7.748815
## Shot.put  13.060137  0.3967224 21.620432 2.0140727  8.824401
## High.jump  9.024811 11.7715838  8.792888 2.5498795 23.115504
```

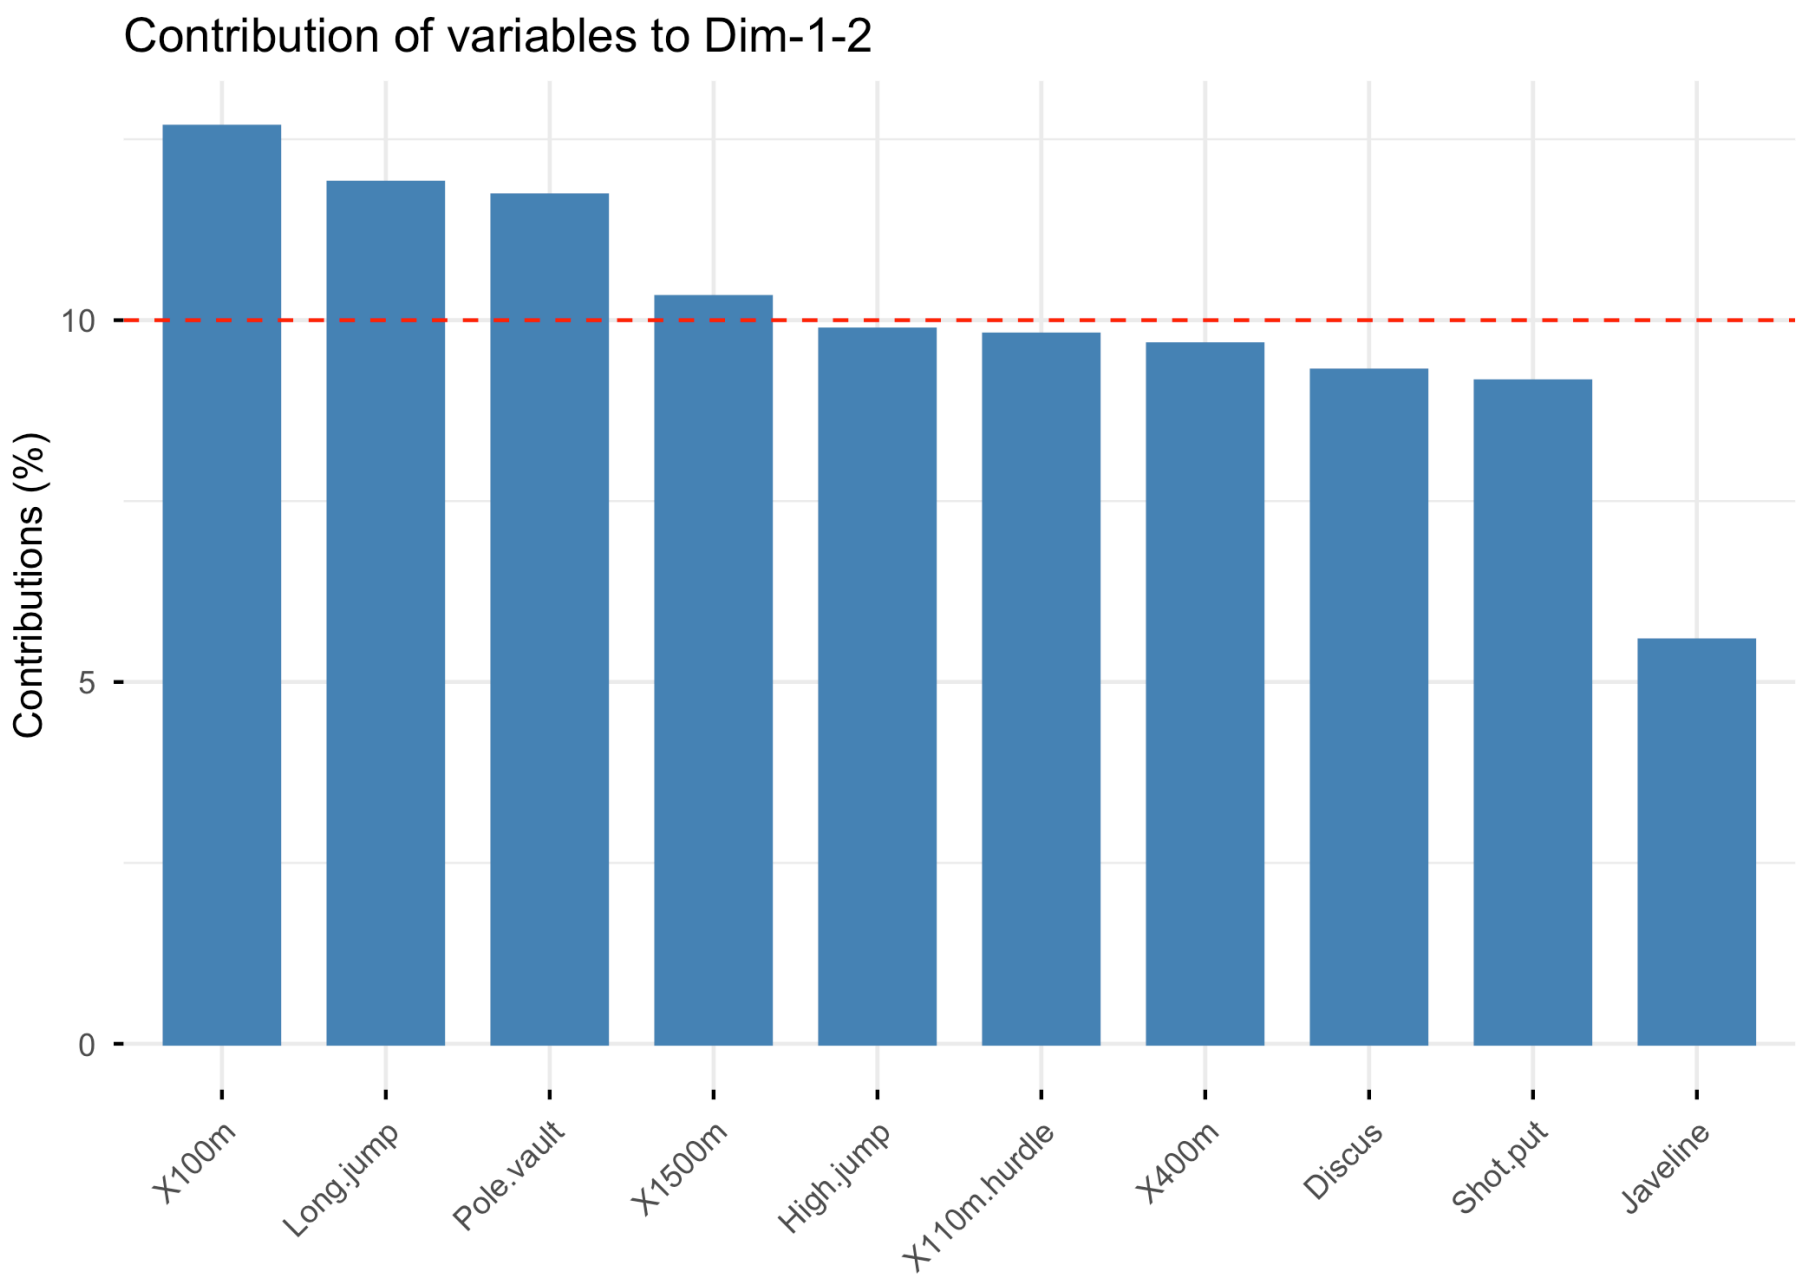
Question 20 :

```
corrplot(matrices$contrib,  is.corr = FALSE, method = "circle")
```


Dim.1
Dim.2
Dim.3
Dim.4
Dim.5
X100m
Long.jump
Shot.put
High.jump
X400m
X110m.hurdle
Discus
Pole.vault
Javeline
X1500m
35.46
31.92
28.37
24.82
21.28
17.73
14.19
10.64
7.09
3.55
0

Question 21 :

```
fviz_contrib(decathlon_pca, choice = "var", axes = 1:2)
```



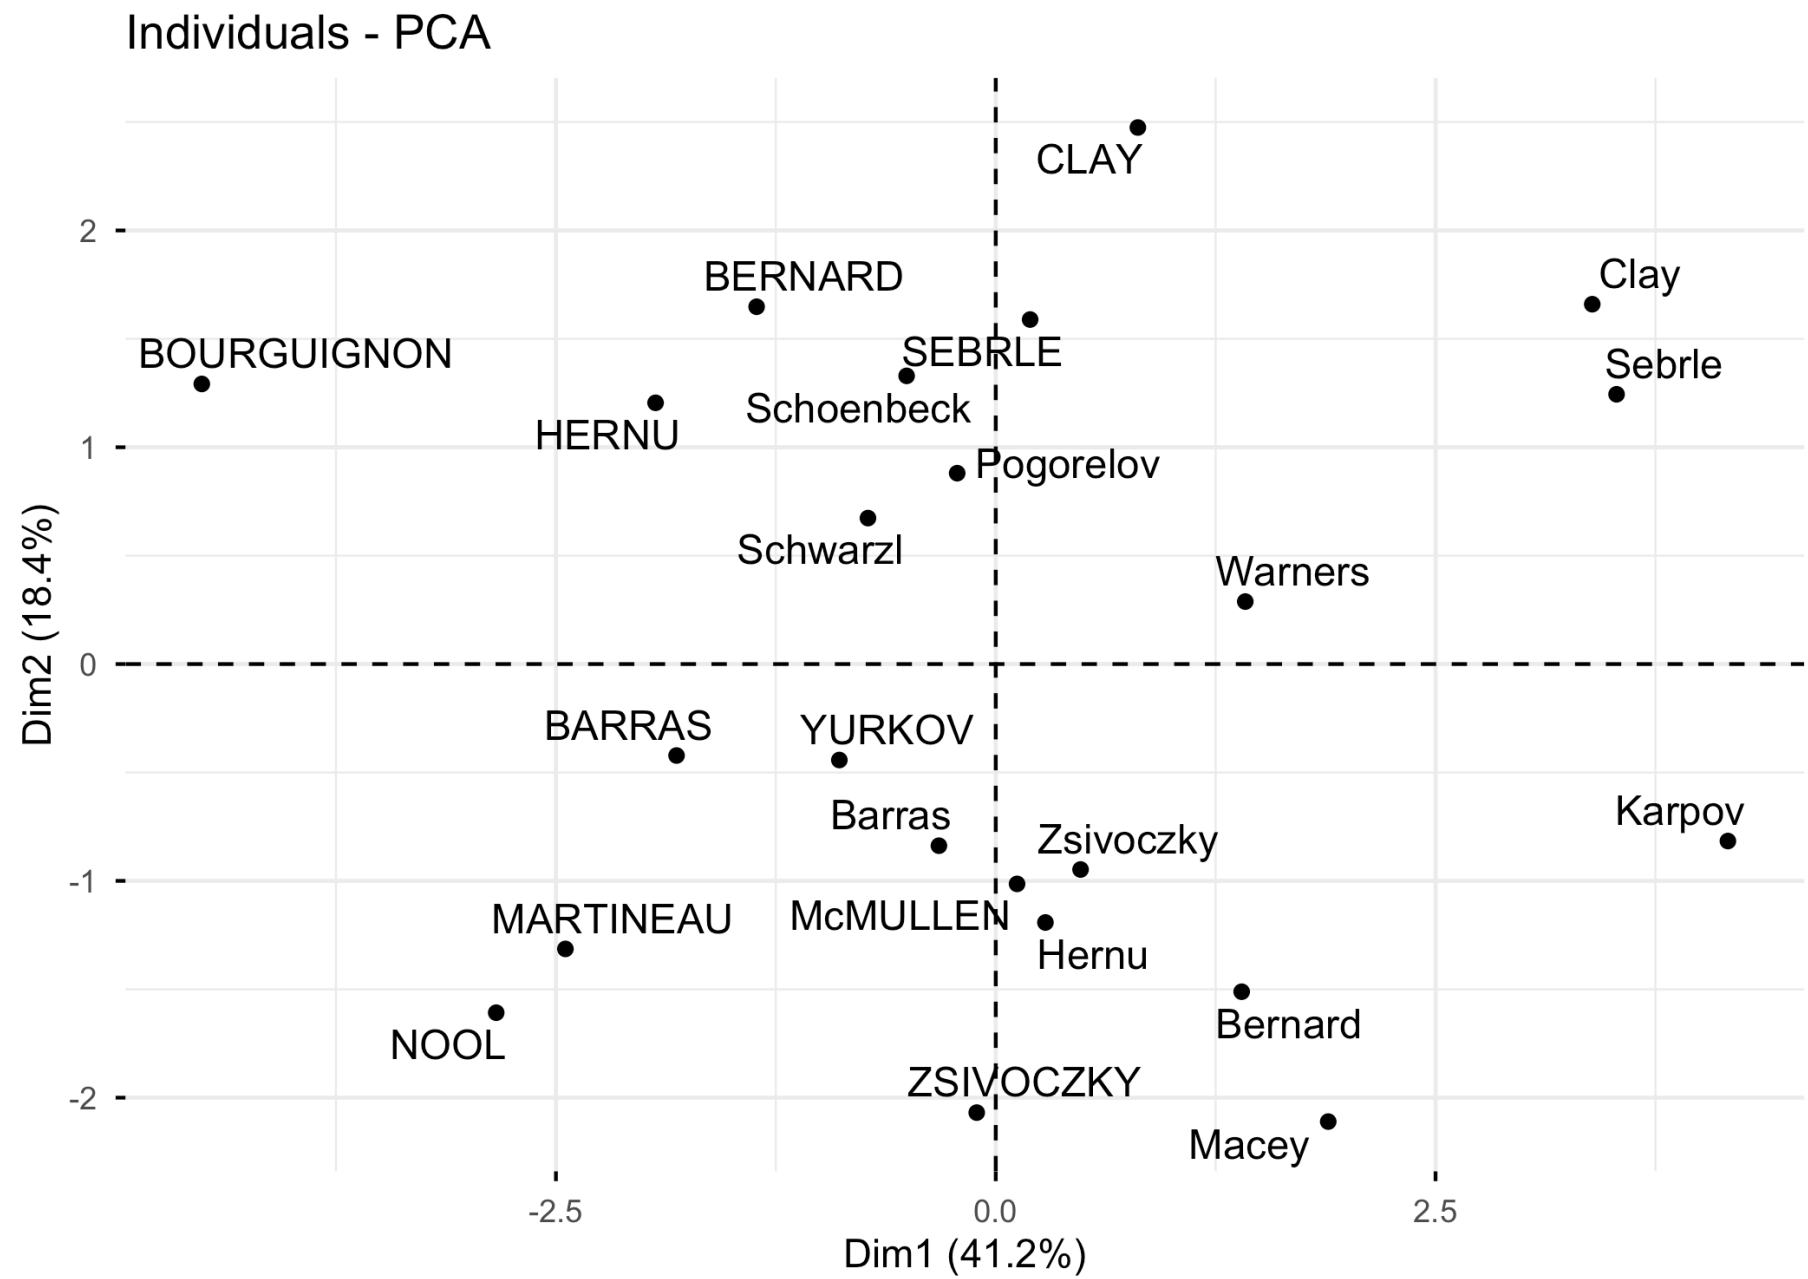
Question 22 : La fonction get_pca_ind() donne une liste de matrices avec tous les résultats pour les individus : - `$coord` : coordonnées spatiales des individus sur chaque CP - `$cos2` : cosinus carré qui quantifie la qualité de représentation de chaque individu - `$contrib` : contributions relatives de chaque individu à la variance de chaque axe

```
individus <- get_pca_ind(decathlon_pca)
individus
```

```
## Principal Component Analysis Results for individuals
##  ===================================================
##   Name       Description
## 1 "$coord"   "Coordinates for the individuals"
## 2 "$cos2"    "Cos2 for the individuals"
## 3 "$contrib" "contributions of the individuals"
```

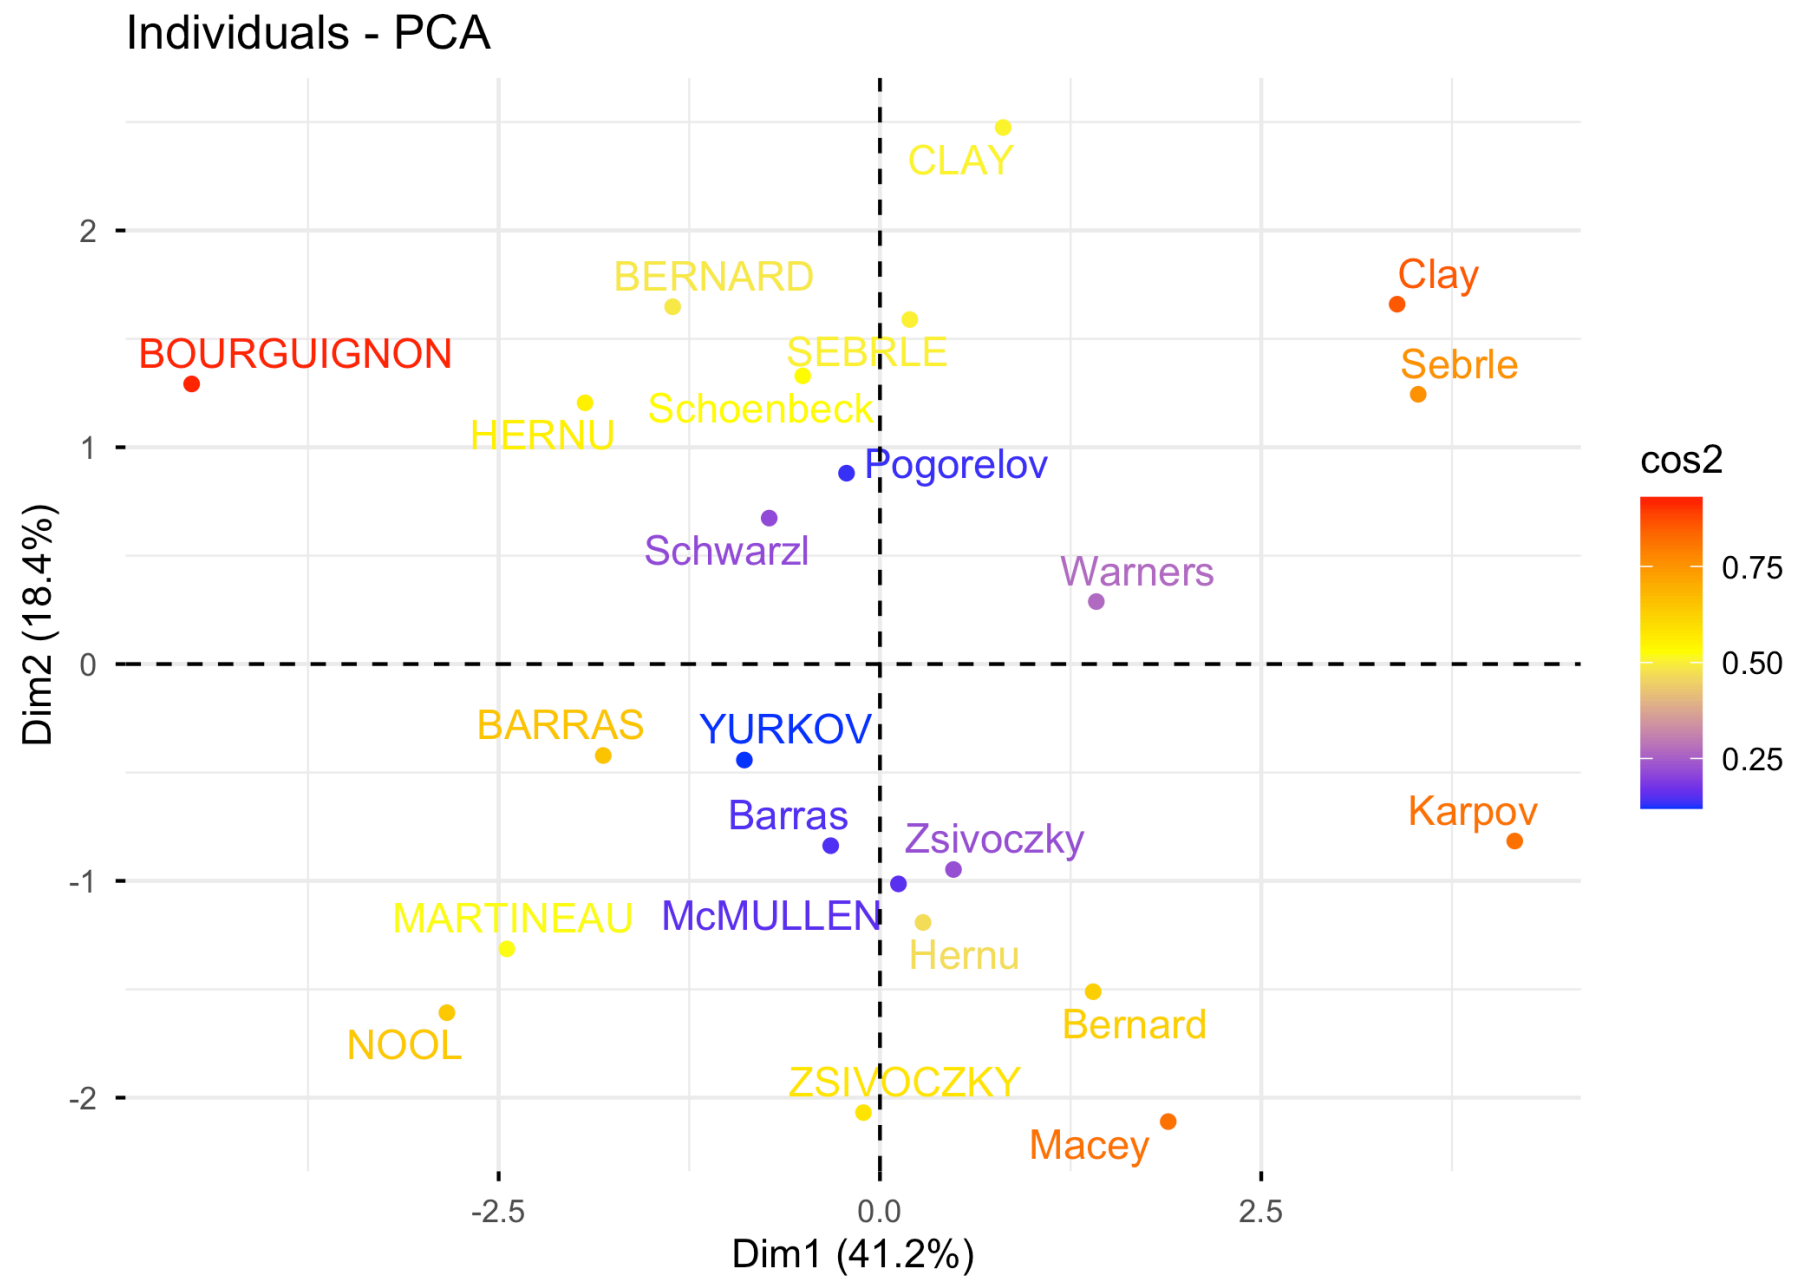
Question 23 :

```
fviz_pca_ind(decathlon_pca, repel = TRUE)
```


Individuals - PCA
CLAY
BERNARD
Clay
BOURGUIGNON
SEBRLE
Sebrle
Schoenbeck
HERNU
Pogorelov
Schwarzl
Warners
BARRAS
YURKOV
Barras
Karpov
Zsivoczky
MARTINEAU
McMULLEN
Hernu
Bernard
NOOL
ZSIVOCZKY
Macey
2
1
0
-1
-2
-2.5
0.0
2.5
Dim2 (18.4%)
Dim1 (41.2%)

Question 24 :

```
fviz_pca_ind(decathlon_pca, col.ind = "cos2", gradient.cols = c("blue", "yellow", "red"), repel = TRUE)
```


Individuals - PCA
CLAY
BERNARD
Clay
BOURGUIGNON
SEBRLE
Sebrle
Schoenbeck
HERNU
Pogorelov
Schwarzl
Warners
BARRAS
YURKOV
Barras
Karpov
Zsivoczky
MARTINEAU
McMULLEN
Hernu
Bernard
NOOL
ZSIVOCZKY
Macey
cos2
0.75
0.50
0.25
Dim2 (18.4%)
Dim1 (41.2%)
2
1
0
-1
-2
-2.5
0.0
2.5

Question 25 :

```
fviz_cos2(decathlon_pca, choice = "ind", axes = 1:2)
```

