Statistique Exploratoire Multidimensionnelle

TP 4

L'ADL

1. Introduction - Techniques de réduction de la dimensionnalité dans R

L'ACP et l'ADL sont toutes deux des techniques de transformation linéaire. Toutefois, l'ACP est une technique de réduction de la dimensionnalité non supervisée, tandis que l'ADL est une technique de réduction de la dimensionnalité supervisée.

L'ACP ne se préoccupe pas des étiquettes de classe. En d'autres termes, l'ACP résume l'ensemble des caractéristiques sans s'appuyer sur la sortie. L'ACP tente de trouver les directions de la variance maximale dans l'ensemble de données. Dans un grand ensemble de caractéristiques, il existe de nombreuses caractéristiques qui ne sont que des duplications d'autres caractéristiques ou qui ont une forte corrélation avec d'autres caractéristiques. Ces caractéristiques sont fondamentalement redondantes et peuvent être ignorées. Le rôle de l'ACP est de trouver ces caractéristiques fortement corrélées ou dupliquées et de proposer un nouvel ensemble de caractéristiques où la corrélation entre les caractéristiques est minimale ou, en d'autres termes, un ensemble de caractéristiques avec une variance maximale entre les caractéristiques. Étant donné que la variance entre les caractéristiques ne dépend pas de la sortie, l'ACP ne prend pas en compte les étiquettes de sortie.

Contrairement à l'ACP, la LDA tente de réduire les dimensions de l'ensemble de caractéristiques tout en conservant les informations qui discriminent les classes de sortie. LDA tente de trouver une limite de décision autour de chaque grappe d'une classe. Elle projette ensuite les points de données dans de nouvelles dimensions de manière à ce que les grappes soient aussi distinctes que possible et que les éléments individuels d'une grappe soient aussi proches que possible du centroïde de la grappe. Les nouvelles dimensions sont classées en fonction de leur capacité à maximiser la distance entre les grappes et à minimiser la distance entre les points de données d'une grappe et leurs centroïdes. Ces nouvelles dimensions constituent les discriminants linéaires de l'ensemble de caractéristiques.

ACP vs LDA : Que choisir pour la réduction de la dimensionnalité ?

Dans le cas de données uniformément distribuées, la LDA est presque toujours plus performante que l'ACP. Toutefois, si les données sont fortement asymétriques (distribution irrégulière), il est conseillé d'utiliser l'ACP, car l'analyse linéaire peut être biaisée en faveur de la classe majoritaire.

Enfin, l'ACP présente l'avantage de pouvoir être appliquée à des données étiquetées ou non, puisqu'elle ne dépend pas des étiquettes de sortie. En revanche, l'analyse discriminante quadratique nécessite des classes de sortie pour trouver des discriminants linéaires et requiert donc des données étiquetées.

Informations sur l'ensemble des données utilisées dans cet exemple:

Ces données sont les résultats d'une analyse chimique de vins cultivés dans la même région d'Italie mais issus de trois cultivars différents. L'analyse a permis de déterminer les quantités de 13 constituants présents dans chacun des trois types de vins.

Les caractéristiques du jeux de données sont les suivants :

Les attributs sont les suivants

1. l'alcool
2. Acide malique
3. Cendres
4. Alcalinité des cendres
5. Magnésium
6. Phénols totaux
7. Flavanoïdes
8. Phénols non flavanoïdes
9. Proanthocyanines
10. Intensité de la couleur
11. Teinte
12. OD280/OD315 des vins dilués
13. Proline

Notre but sera de transformer les données à l'aide de l'ACP et de l'ADL et ensuite de évaluer la performance d'un classifieur SVM à partir les caractéristiques produites par l'ACP et l'ADL.

2. Charger le jeux de données

1. Charger le jeux de données et examiner les premières lignes.
2. Ajouter les noms de colonnes dans le jeux de données en utilisant les noms suivants : 'Customer_Segment', 'Alcohol', 'Malic_Acid', 'Ash', 'Ash_Alkanity', 'Magnesium', 'Total_Phenols', 'Flavanoids', 'Nonflavanoid_Phenols', 'Proanthocyanins', 'Color_Intensity', 'Hue', 'OD280', 'Proline'
3. Mettez la première colonne « Customer_Segment », qui va servir comme les labels (la variable dépendante) des données, à la dernière place.
4. Trouvez le nombre des lignes qui contient des valeurs manquantes et ignorez les dans l'analyse.
5. Créez un résumé des données contenant les valeurs min, 1er quartile, médiane, moyen, 3ème quartile, max.
6. Installez le paquet « caTools » et divisez les données dans 2 ensembles : (1) un training set, qui va contenir 80% des données et (2) un test set, qui va contenir le 20% des données qui restent.
7. Utiliser la méthode « scale » pour normaliser les données (seulement les variables) sauf les labels, qui se trouvent à la dernière colonne. Quelle transformation applique la méthode « scale » aux données ?

3. Construire un model SVM pour la tâche de classification des vins selon leur producteur

1. En utilisant le paquet « e1071 » entrainez un classifieur SVM (linéaire) ayant comme variable dépendent (labels) la variable « Customer_Segment » et comme variables indépendantes autres les autres variables à partir de training set.
2. Prédire le « Customer_Segment » pour le test set.
3. Expliquez ce que c'est et ce qu'elle représente une Matrice de Confusion (Confusion Matrix) ?
4. Expliquez en bref les termes : accuray, precision, recall et f1-score per class.
5. Calculez les métriques : accuray, precision, recall et f1-score per class du test set.

4. Réduction de dimensionalité à l'aide de l'ACP

1. Installez les paquets « caret » et « e1071 ».
2. Calculez et appliquez l'ACP avec 2 Composantes Principales aux training et test set. Sauvegarder les nouvelles données dans deux nouvelles variables (train_set_PCA et test_set_PCA).
3. Arrangez la colonne des labels dans la dernière position des données et imprimez les deux CP.
4. Entrainez un nouveau modèle de classification SVM (linéaire) à partir du nouveau training set.
5. Faites les prédictions des labels à partir du nouveau test set.
6. Calculez et présentez les mesures de performance (Matrice de confusion, accuracy, precision; recall, f1-score per class) du model à partir de 2 CP.
7. Utilisez la méthode xyplot de la librairie « lattice », pour faire un plot de les 2 CP du training set en respectant leur label, c'est-à-dire les points de la même classe doivent avoir le même couleur.
8. Expliquez la fonctionnalité du code ci-dessous. Adaptez le code pour crée le plot à partir du training set, et commentez sur le plot.

```
#library(Rfast)
set = train_set
X1 = seq(min(set[, 1]) - 1, max(set[, 1]) + 1, by = 0.01)
X2 = seq(min(set[, 2]) - 1, max(set[, 2]) + 1, by = 0.01)
grid_set = expand.grid(X1, X2)
colnames(grid_set) = c('PC1', 'PC2')
y_grid = predict(classifier, newdata = grid_set)
plot(set[, -3],
    main = 'SVM (Principal Component Train set)',
    xlab = 'PC1', ylab = 'PC2',
    xlim = range(X1), ylim = range(X2))
#contour(X1, X2, matrix(as.numeric(y_grid), length(X1), length(X2)), add = TRUE)
points(grid_set, pch = '.', col = ifelse(y_grid == 2, 'deepskyblue', ifelse(y_grid == 1,
'springgreen3', 'tomato')))
points(set, pch = 21, bg = ifelse(set[, 3] == 2, 'blue3', ifelse(set[, 3] == 1, 'green4', 'red3')))
```

9. Faites les même deux plots des questions 7 et 8 pour le test set. Commentez sure les résultats de plots en relation de la performance du modèle que vous avez calculez au-dessus.

10. Expliquez pourquoi nous ne pouvions pas faire les deux plots pour le modèle à partir de données originales ?

5. Réduction de dimensionalité à l'aide de l'ALD

Démarrez par les donnez à la fine de la section 2, qui sont normalisées et divisées en train et test set.

1. Utilisez la librairie « MMAS » pour calculez un modèle ALD (lda) à partir du training set.
2. Appliquez le modèle au train et test sets pour obtenir les prédictions.
3. Imprimez les premiers éléments des data frames de prédictions.
4. Conservez seulement les colonnes des data frames des prédictions qui correspondent au 2 Composants Discriminatives (LD1, LD2) ainsi que les labels.
5. Entrainez à partir des données transformées (training data) un modèle SVM et faites les prédictions à partir du test set transformé.
6. Donnez les mesures d'évaluation (accuracy, confusion matrix, precision, recall et F1-score per class) du modèle SVM.
7. Commentez sure les résultats.
8. Visualisez le training set, à l'aide de 2 Composantes Discriminantes en respectant les labels des données.
9. Visualisez les prédictions ainsi que les frontières de décision du test set.
10. Faites les deux visualisations pour le test set également.

Conclusions

Ecrivez les conclusions des expériences que vous avez faites.